

ÉCOLE NATIONALE DES CHARTES  
UNIVERSITÉ PARIS, SCIENCES & LETTRES

---

**Maxime GRIVEAU**

*diplômé de licence histoire, histoire de l'art et archéologie*

**La découvrabilité des contenus  
culturels à l'heure du *big data*  
*patrimonial***

**Cas d'usages à la Radio-télévision Suisse  
(RTS)**

Mémoire pour le diplôme de master  
« Technologies numériques appliquées à l'histoire »

2024



# Résumé

**Résumé :** Ce mémoire, réalisé lors d'un stage à la Radio-Télévision Suisse (RTS) dans le cadre du Master Technologies numériques appliquées à l'histoire (TNAH) de l'École des chartes - PSL, explore la question de la découvrabilité dans le secteur patrimonial. Notion définie comme la « capacité pour un objet à émerger parmi un vaste ensemble à un utilisateur qui n'en aurait pas fait la demande »<sup>1</sup>. Après avoir exploré les enjeux de disponibilité des contenus, leur repérabilité et leur recommandation algorithmique tout en historicisant la notion, le mémoire traite ensuite de l'évolution des interfaces, notamment des catalogues et des visualisations de données, et examine enfin les limites de la notion : écosystème du web, règles institutionnelles et angles morts (accessibilité numérique, explicabilité, et numérique responsable).

**Abstract :** This thesis, conducted during an internship at Radio-Télévision Suisse (RTS) as part of the Master's program in Digital Technologies Applied to History (TNAH) at the École des chartes - PSL (Paris), focuses on the concept of discoverability in the heritage sector, defined as the « ability of an object to emerge from a vast array to a user who has not explicitly requested it ». The study explores content availability, findability, and algorithmic recommendation, providing a historical perspective on the notion. It then addresses the evolution of interfaces, particularly catalogs and data visualizations and finally examines the limits of the concept : the web ecosystem, institutional rules and blind spots (digital accessibility, explainability, and responsible digital practices).

**Mots-clés :** Découvrabilité ; repérabilité ; algorithmes de recommandation ; intelligence artificielle (RAG) ; interfaces ; crowdsourcing ; impact environnemental du numérique ; bulle de filtre ; longue traîne.

---

1. *Stratégie commune de la mission franco-québécoise sur la découvrabilité des contenus culturels francophones / Gouvernement du Québec, URL : <https://www.quebec.ca/gouvernement/ministere/culture-communications/publications/strategie-commune-mission-franco-quebecoise-decouvrabilite-contenus-culturels-francophones> (visité le 19/08/2024).*

**Informations bibliographiques :** Maxime Griveau. La découvrabilité des contenus culturel à l'heure du *big data patrimonial* : cas d'usages à la RTS, mémoire de master « Technologies numériques appliquées à l'histoire », dir. Maxime Challon, École nationale des chartes, 2024.

*Ce document est écrit en utilisant l'orthographe réformée, on ne s'étonnera donc pas, par exemple, de l'absence de l'accent circonflexe sur des mots tels que maître. Voir à ce propos : <https://www.academie-francaise.fr/sites/academie-francaise.fr/files/rectifications.pdf>*

# Remerciements

Mes remerciements vont tout d'abord à Janique Sonderegger, documentaliste spécialisée data au service Données & Archives, qui, pendant toute la durée de mon stage, a su orienter mes réflexions, me fournir des clés de lecture essentielles et les outils adéquats, sans jamais limiter les réflexions et essais que je souhaitais mener.

Je tiens également à remercier Denise Barcella, experte en patrimoine au service Données & Archives et ancienne enseignante à l'Université de Lausanne, pour ses précieuses indications concernant l'histoire du fonds. Nos discussions m'ont par ailleurs été très utiles pour appréhender, ne serait-ce qu'un peu, la complexité des opérations de numérisation et l'histoire des supports conservés à la RTS.

Ce mémoire doit aussi beaucoup à Maxime Challon, ingénieur data à l'Institut national de l'audiovisuel. Je le remercie pour ses précieux conseils quant à la rédaction du mémoire, mais aussi pour les discussions très fructueuses que nous avons eues. Il a toujours su me guider vers la bonne voie sans jamais m'imposer une direction précise, et a fourni des conseils techniques particulièrement pertinents. Pour les mêmes raisons, je souhaite remercier Emmanuelle Bermès pour ses orientations bibliographiques précieuses et ses conseils lors de la réflexion autour du plan.

Je remercie également tous les collègues avec qui j'ai eu le plaisir d'échanger pour construire l'historique des fonds et de leurs métadonnées, ainsi que sur des sujets extrêmement variés qui m'ont permis de grandir, tant professionnellement que personnellement. Je ne peux tous et toutes les citer ici, mais je tiens à exprimer ma gratitude en particulier à : Laure Meuret, Marie Françoise Guex, Alain Freudiger, Gabriel Leon, Pietro et Marielle Renzonnico, Didier Bufflier, Martine Cameroni, Sophie Meyer, Soazig Vaucher, Vincent Seriot, Laurent Guimard, Natacha Farina Groux, Louise-Anne Thévoz, Joëlle Albrecht-Glaisen, Gabrielle Frech, Anne-Isabelle Gomez, Floriane Morattel, Rita Crota Ben Henda et, bien sûr, Guy Druey.

Je souhaite aussi remercier les amis qui ont accepté de prendre le temps de me relire : Jeanne Dugas, Lucile Chatellier-Lang, Alexandra Puillandre, Laurine Roy, Manon Delisle et Maël Jean.

Avant de clore ces remerciements, je tiens à remercier Louis Falissard, Maître de conférences en apprentissage profond à l’Université Paris VIII, et Xavier Huet, Administrateur fonctionnel des archives de la métropole de Lille, pour les échanges que nous avons eus, respectivement sur le clustering des contenus et sur la création de la treemap interactive des contenus.

Enfin, je remercie Paul Wang, qui a su me guider, me poser les bonnes questions, et parfois — souvent — me faire douter, toujours pour le meilleur, relisant chaque phrase, corrigéant chaque virgule, ce mémoire lui doit beaucoup.

# Bibliographie



# Historique et enjeux

*10 millions de documents numérisés dans Gallica / BnF - Site institutionnel*, URL : <https://www.bnf.fr/fr/actualites/10-millions-de-documents-numerises-dans-gallica> (visité le 19/08/2024).

À propos de *data.bnf.fr*, s.d. URL : <https://data.bnf.fr/fr/about> (visité le 16/07/2024).

*About - Schema.org*, URL : <https://schema.org/docs/about.html> (visité le 19/08/2024).

*About Me*, oct. 2017, URL : <https://www.apriljoyner.com/> (visité le 19/08/2024).

ALQUIER (Eleonore), *Journée de présentation de l'institut national de l'audiovisuel (INA)*, janv. 2024.

*API Google Knowledge Graph Search / Knowledge Graph Search API*, URL : <https://developers.google.com/knowledge-graph?hl=fr> (visité le 19/08/2024).

BALLE (Francis), *Sérendipité*, mars 2015, URL : <https://www.radiofrance.fr/franceculture/podcasts/1-alphabet-numerique/serendipite-4636636> (visité le 19/08/2024).

BARCELLA (Denise), *Entretien avec Denise Barcella, experte patrimoine des archives de la RTS et ancienne enseignante de l'université de Lausanne en histoire de la télévision*. Mai 2024.

BASTARD (Irène) et LABORDERIE (Arnaud), *La découvrabilité des collections numériques patrimoniales sous l'angle des usages de Gallica*, Text, juin 2023, URL : [https://bbf.enssib.fr/matieres-a-penser/la-decouvrabilite-des-collections-numeriques-patrimoniales-sous-l-angle-des-usages-de-gallica\\_71295](https://bbf.enssib.fr/matieres-a-penser/la-decouvrabilite-des-collections-numeriques-patrimoniales-sous-l-angle-des-usages-de-gallica_71295) (visité le 19/08/2024).

BERMÈS (Emmanuelle), *Modélisation et requêteage, cours de 2e année de Master technologies numériques appliquées à l'histoire*, 2023.

— "De l'écran à l'émotion, quand le numérique devient patrimoine", Paris, 2024.

BORGES (Jorge Luis), *La bibliothèque de Babel*, 1963, URL : <https://baptiste-tosi.eu/documents/la-bibliothèque-de-babel.pdf> (visité le 19/08/2024).

CARDON (Dominique), « Dans l'esprit du PageRank. Une enquête sur l'algorithme de Google », *Réseaux*, 177–1 (2013), p. 63-95, DOI : 10.3917/res.177.0063.

CHATELAIN (Jean-Marc), « La politesse des livres », dans *La Bibliothèque de l'honnête homme : Livres, lecture et collections en France à l'âge classique*, Paris, 2003 (Conférences et Études), p. 105-144, DOI : 10.4000/books.editionsbnf.2489.

*Cinquante ans de pratiques culturelles en France [CE-2020-2]*, juill. 2020, URL : <https://www.culture.gouv.fr/fr/espace-documentation/statistiques-ministerielles-de-la-culture2/publications/collections-de-synthese/culture-etudes-2007-2024/Cinquante-ans-de-pratiques-culturelles-en-France-CE-2020-2> (visité le 19/08/2024).

CLAES (Arnaud), *Arnaud Claes - Algorithme de service public et autonomie critique : Etude des effets de la contrôlabilité d'un algorithme de recommandation sur l'autonomie critique de ses usagers / UCLouvain*, thèse de doct., Belgique, Louvain-La-Neuve, 2022, URL : <https://uclouvain.be/fr/facultes/espo/evenements/arnaud-claes.html> (visité le 19/08/2024).

CONSEIL DE LA RADIODIFFUSION ET DES TÉLECOMMUNICATIONS CANADIENNES (CRTC) ET L'OFFICE NATIONAL DU FILM DU CANADA (ONF), *Le contenu à l'ère de l'abondance, sommet sur la découvrabilité des contenus culturels canadiens*, 2016, URL : <https://web.archive.org/web/20171027015812/http://decouvrabilite.ca/videos/resume-sommet-decouverabilite/>.

DASGUPTA (Anirban), GHOSH (Arpita), KUMAR (Ravi), OLSTON (Christopher), PANDEY (Sandeepr) et TOMKINS (Andrew), « The discoverability of the web », dans *Proceedings of the 16th international conference on World Wide Web*, Banff Alberta Canada, 2007, p. 421-430, DOI : 10.1145/1242572.1242630.

DURAND (Emmanuel), *L'attaque des clones : la diversité culturelle à l'ère de l'hyperchoix*, Paris, 2016 (Nouveaux débats, 44).

ERTZSCHEID (Olivier), *Économie des biens culturels, cours de 2e année de DUT information et communication option métiers du livre et du patrimoine*, 2019.

— *GPT-4 Omni : Chat Pantin(s)*. Mai 2024, URL : <https://affordance.framasoft.org/2024/05/gpt-4-omni-chat-pantins/> (visité le 19/08/2024).

ERTZSCHEID (Olivier) et GALLEZOT (Gabriel), « Chercher faux et trouver juste, » (juill. 2003).

*Europeana*, URL : <https://www.bnf.fr/fr/europeana> (visité le 19/08/2024).

FREUDIGUER (Alain), *Entretien avec Alain Freudiger, chargé des archives anciennes (RTS)*, mai 2024.

*Get More Eyes on Your Content Using StumbleUpon*, déc. 2012, URL : <https://verticalresponse.com/blog/stumbleupon-gets-great-content-seen/> (visité le 19/08/2024).

GODIN (Christian), « « La culture pour chacun » : une nouvelle politique culturelle ? », *Cités*, 45–1 (2011), p. 164-168, DOI : 10.3917/cite.045.0164.

GOOGLE, *Introducing the Knowledge Graph*, 2012, URL : <https://www.youtube.com/watch?v=mmQ16VGvX-c> (visité le 29/08/2024).

*Histoire*, URL : <https://memoriav.ch/fr/memoriav/histoire/> (visité le 19/08/2024).

*Introduction to clustering / Machine Learning / Google for Developers*, URL : <https://developers.google.com/machine-learning/clustering> (visité le 19/08/2024).

*La Convention de 2005 sur la protection et la promotion de la diversité des expressions culturelles / Diversité des expressions culturelles*, URL : <https://www.unesco.org/creativity/fr/2005-convention> (visité le 19/08/2024).

*La rentrée de Fip*, 2023, URL : [https://www.radiofrance.com/sites/default/files/2022-08/rentrée\\_2223\\_dp\\_fip\\_26082022.pdf](https://www.radiofrance.com/sites/default/files/2022-08/rentrée_2223_dp_fip_26082022.pdf) (visité le 19/08/2024).

LAURA, *5 impacts des réseaux sociaux sur le SEO en 2024 ?* - Redacteur Blog, avr. 2022, URL : <https://www.redacteur.com/blog/impact-reseaux-sociaux-seo/> (visité le 19/08/2024).

« Le ministère pose le cadre de sa nouvelle doctrine : la "culture pour chacun" » (, nov. 2010), URL : [https://www.lemonde.fr/culture/article/2010/11/04/le-ministere-pose-le-cadre-de-sa-nouvelle-doctrine-la-culture-pour-chacun\\_1435445\\_3246.html](https://www.lemonde.fr/culture/article/2010/11/04/le-ministere-pose-le-cadre-de-sa-nouvelle-doctrine-la-culture-pour-chacun_1435445_3246.html) (visité le 19/08/2024).

« Les Français ont confirmé leur retour dans les salles de cinéma en 2023 » (, janv. 2024), URL : [https://www.lemonde.fr/economie/article/2024/01/02/les-francais-ont-confirmé-leur-retour-dans-les-salles-de-cinema-en-2023\\_6208729\\_3234.html](https://www.lemonde.fr/economie/article/2024/01/02/les-francais-ont-confirmé-leur-retour-dans-les-salles-de-cinema-en-2023_6208729_3234.html) (visité le 20/08/2024).

*Loi fédérale sur la radio et la télévision (LRTV) du 24 mars 2006, abroge la loi du 21 juin 1991* (état le 1er janvier 2024), URL : <https://www.fedlex.admin.ch/eli/cc/2007/150/fr> (visité le 19/08/2024).

LUNETEAU (Bastien) et LECOMTE (Valentin), *Penser la découverabilité des contenus culturels*, juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels> (visité le 19/08/2024).

MARX (William), *Le rêve de la bibliothèque parfaite : épisode • 4/10 du podcast Les bibliothèques invisibles / France Culture*, URL : <https://www.radiofrance.fr/franceculture/podcasts/les-cours-du-college-de-france/le-reve-de-la-bibliotheque-parfaite-7100321> (visité le 19/08/2024).

MEURET (Laure), *Entretien avec Laure Meuret, chargée d'archivage de l'information pour le secteur radio (RTS)*, mai 2024.

MICHEL (Géraldine) et LE NAGARD (Emmanuelle), « Favoriser la sérendipité pour des recherches plus créatives », *Décisions Marketing*, 93–1 (2019), p. 5-9, DOI : 10.7193/DM.093.05.09.

MINISTÈRES DE LA CULTURE (FRANCE ET QUÉBEC), *Rapport - Mission franco-qubécoise sur la découverabilité en ligne des contenus culturels francophones*, rapp. tech., France, Québec, Ministère de la Culture, 2020, p. 60, URL : <https://www.culture.gouv.fr/Media/medias-creation-rapide-ne-pas-supprimer/Rapport-Mission-franco->

quebecoise-sur-la-decouvrabilite-en-ligne-des-contenus-culturels-francophones.pdf.

MÜLLER (Jörg) et SCHREIBER (Amandine), « Les sorties culturelles des Français après deux années de Covid-19 », *Culture études*, 6–6 (2022), p. 1-20, DOI : 10.3917/cule.226.0001.

PELLEGRIN (Julie), *Les politiques culturelles et leur mise en oeuvre, cours de 3e année de licence histoire, histoire de l'art et archéologie, parcours médiation et conservation des patrimoines*, Nantes, 2022.

PLOUVIEZ (Mélanie), *Philosophie de l'héritage : le projet Philherit*, Paris, France, juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels>.

POISSENOT (Claude), *Vers une politique culturelle de la demande ? - Livres Hebdo*, URL : <https://www.livreshebdo.fr/article/vers-une-politique-culturelle-de-la-demande> (visité le 19/08/2024).

PONCET (Olivier), *Archivistique moderne, cours de première année de Master Technologies numériques appliquées à l'histoire*, 2022.

*Premier direct radio - rts.ch - Divers*, URL : <https://www.rts.ch/archives/tv/divers/3469563-premier-direct-radio.html> (visité le 19/08/2024).

*Présentation du fonctionnement du balisage de données structurées / Google Search Central / Documentation / Google for Developers*, URL : <https://developers.google.com/search/docs/appearance/structured-data/intro-structured-data?hl=fr#search-appearance> (visité le 19/08/2024).

PRONGUÉ (Dominique), *Le hasard des archives ou les archives du hasard, Les archives sonores de la Radio Suisse Romande. Comment une radio de service public a constitué ses archives*, rapp. tech., Lausanne, Suisse, Radio Suisse Romande (RSR), 2009, p. 129, URL : [https://web.archive.org/web/20160303182936/http://de.memoria.ch/dokument/news/events/le\\_hasard\\_des\\_archives\\_prongue\\_rsr\\_2009.pdf](https://web.archive.org/web/20160303182936/http://de.memoria.ch/dokument/news/events/le_hasard_des_archives_prongue_rsr_2009.pdf).

*Re/penser les politiques culturelles : la créativité au cœur du développement, Rapport mondial Convention 2005, 2018 - UNESCO Digital Library*, URL : <https://unesdoc.unesco.org/ark:/48223/pf0000260601> (visité le 22/08/2024).

REZZONICO (Marielle), *Entretien avec Marielle Rezzonico, chargée de valorisation des archives*, juin 2023.

*Roland Pièce raconte l'inauguration de l'émetteur du Champ-de-l'Air à Lausanne*, audio, sept. 1939, URL : <https://www.rts.ch/archives/1939/audio/roland-piece-raconte-l-inauguration-de-l-emetteur-du-champ-de-l-air-a-lausanne-25836167.html> (visité le 19/08/2024).

SANDRI (Eva), *Record. La sérendipité sur Internet : également documenta... – Cygne noir – Érudit*, URL : <https://www.erudit.org/en/journals/cygnenoir/2013-n1-cygnenoir07153/1090992ar/abstract/> (visité le 19/08/2024).

SONDEREGGER (Janique), *Entretien avec Janique Sonderegger, premier lien du cercle Data Management, service données et archives (RTS)*, mai 2024.

*Stratégie commune de la mission franco-qubécoise sur la découvrabilité des contenus culturels francophones / Gouvernement du Québec*, URL : <https://www.quebec.ca/gouvernement/ministere/culture-communications/publications/strategie-commune-mission-franco-quebecoise-decouvrabilite-contenus-culturels-francophones> (visité le 19/08/2024).

VALLOTON (François), *Les jeunes années de la radio en Suisse romande - SSR Suisse Romande*, URL : [https://ssrsr.ch/a\\_la\\_une/les-jeunes-annees-de-la-radio-en-suisse-romande/](https://ssrsr.ch/a_la_une/les-jeunes-annees-de-la-radio-en-suisse-romande/) (visité le 19/08/2024).

WARESQUIEL (Emmanuel de), *Dictionnaire des politiques culturelles de la France depuis 1959*, Paris, 2001.

*Web sémantique et modèle de données*, URL : <https://data.bnf.fr/fr/semanticweb> (visité le 18/07/2024).

WINDHAGER (Florian), SALISU (Saminu), SCHREDER (Günther) et MAYR (Eva), « Orchestrating Overviews : A Synoptic Approach to the Visualization of Cultural Collections », *Open Library of Humanities*, 4–2 (août 2018), DOI : 10.16995/olh.276.



# Nouvelles interfaces

AUTEUR ( sans), *Internet n'est pas assez développé pour former l'IA, mais une solution existe : les fausses données*, Forbes France, 29 juill. 2024, URL : <https://www.forbes.fr/technologie/internet-nest-pas-assez-developpe-pour-former-lia-mais-une-solution-existe-les-fausses-donnees/> (visité le 19/08/2024).

BERMÈS (Emmanuelle), « Vers de nouveaux catalogues ? Propos introductif », dans *Vers de nouveaux catalogues*, ISSN : 0184-0886, Paris, 2016 (Bibliothèques), p. 9-12, DOI : 10.3917/elec.berme.2016.01.0009.

— *Le futur de la recherche documentaire : RAG time ! / Figoblog*, Figoblog, 30 mars 2024, URL : <https://figoblog.org/2024/03/30/le-futur-de-la-recherche-documentaire-rag-time/> (visité le 19/08/2024).

BRUNET (Isabelle), CAPOT (Stéphane), BUSER (Marc) et MOREAU (Charles), *les archives du Lot-et-Garonne en route vers le IIIF*, Journée d'étude internationale IIIF, 30 nov. 2023.

CARRÉ-MARILLONNET (Fabien) et AYMONIN (David), « Transition bibliographique : 7 ans plus tard, où en sommes-nous ? », 357-7 (2022), Publisher : Serda Archimag, p. 36-37, DOI : 10.3917/arma.357.0036.

*Chronicling America Maps and Visualizations - National Digital Newspaper Program (Library of Congress)*, URL : <https://www.loc.gov/ndnp/data-visualizations/> (visité le 19/08/2024).

CLAVEY (Martin), *La BNF : un réservoir de données pour les IA*, Next, 27 juin 2024, URL : <https://next.ink/142051/la-bnf-un-reservoir-de-donnees-pour-les-ia/> (visité le 19/08/2024).

DRIBAULT DUJARDIN (Claire Marie), FACKLER (Dominique) et PICHON (Jeannette), « L'évolution des pratiques de description des archives documentaires de l'Institut national de l'audiovisuel (INA) à l'ère du numérique » (, 2020), Publisher : Persée - Portail des revues scientifiques en SHS, DOI : 10.3406/gazar.2020.5948.

DÜRING (Marten), BUNOUT (Estelle) et GUIDO (Daniele), « Transparent generosity. Introducing the *impresso* interface for the exploration of semantically enriched historical

- newspapers », *Historical Methods : A Journal of Quantitative and Interdisciplinary History*, 57–1 (2 janv. 2024), p. 20-40, DOI : 10.1080/01615440.2024.2344004.
- EHRMANN (Maud), « Explorer la presse numérisée : le projet Impresso », 129/2021 (27 nov. 2021), p. 159-173, URL : <https://infoscience.epfl.ch/handle/20.500.14299/185588> (visité le 19/08/2024).
- Entraîner une intelligence artificielle avec des données générées par IA conduit à l'absurde - Le Temps*, URL : <https://www.letemps.ch/sciences/entrainer-une-ia-avec-des-donnees-d-ia-conduit-a-l-absurde?srsltid=AfmB0opRmg411Q16bXgFanx2YVuh7h6o3CeuU> (visité le 19/08/2024).
- Etats-Unis : un Américain noir arrêté à tort à cause de la technologie de reconnaissance faciale*, URL : [https://www.lemonde.fr/international/article/2020/06/24/un-americain-noir-arrete-a-tort-a-cause-de-la-technologie-de-reconnaissance-faciale\\_6044073\\_3210.html](https://www.lemonde.fr/international/article/2020/06/24/un-americain-noir-arrete-a-tort-a-cause-de-la-technologie-de-reconnaissance-faciale_6044073_3210.html) (visité le 19/08/2024).
- FOUCAULT (Michel), *L'archéologie du savoir*, Paris, 2008 (Tel, 354).
- GILMAN (Benjamin Ives), « Museum Fatigue », *The Scientific Monthly*, 2–1 (1916), Publisher : American Association for the Advancement of Science, p. 62-74, URL : <https://www.jstor.org/stable/6127> (visité le 19/08/2024).
- HACHOUR (Hakim), « De la fouille à la visualisation de données : un processus interprétatif », *I2D - Information, données & documents*, 52–2 (2015), Place : Paris Publisher : A.D.B.S., p. 42-43, DOI : 10.3917/i2d.152.0042.
- impresso / Media Monitoring of the Past*, URL : <https://impresso-project.ch/app/> (visité le 19/08/2024).
- La révolte des abricots de 1953 : des citoyens saxonains revalorisent un épisode de l'histoire agricole valaisanne*, Canal9, Section : ACTUALITÉS, 25 sept. 2018, URL : <https://canal9.ch/fr/la-revolte-des-abricots-de-1953-des-citoyens-saxonains-revalorisent-un-episode-de-lhistoire-agricole-valaisanne/> (visité le 19/08/2024).
- LAPÔTRE (Raphaëlle), « Visualiser les données du catalogue », dans *Vers de nouveaux catalogues*, ISSN : 0184-0886, Paris, 2016 (Bibliothèques), p. 37-47, DOI : 10.3917/elec.berme.2016.01.0037.
- LERESCHE (Françoise), « La Transition bibliographique », dans *Vers de nouveaux catalogues*, ISSN : 0184-0886, Paris, 2016 (Bibliothèques), p. 49-67, DOI : 10.3917/elec.berme.2016.01.0049.
- LIEM (Johannes), KUSNICK (Jakob), BECK (Samuel), WINDHAGER (Florian) et MAYR (Eva), *A Workflow Approach to Visualization-Based Storytelling with Cultural Heritage Data*, 17 oct. 2023, arXiv : 2310.13718[cs], URL : <http://arxiv.org/abs/2310.13718> (visité le 19/08/2024).
- MESGUICH (Véronique), « 5. De nouveaux chemins pour accéder aux ressources », dans *Bibliothèques : le Web est à vous*, ISSN : 0184-0886, Paris, 2017 (Bibliothèques), p. 105-

- 143, URL : <https://www.cairn.info/bibliotheques-le-web-est-a-vous--9782765415213-p-105.htm> (visité le 19/08/2024).
- MILLER (Matt), *The Networked Catalog / The New York Public Library*, 31 juill. 2014, URL : <https://www.nypl.org/blog/2014/07/31/networked-catalog> (visité le 19/08/2024).
- NÉROULIDIS (Ariane), *Le crowdsourcing appliqué aux archives numériques : concepts, pratiques et enjeux*, Mémoire de Master, LYON, Université de Lyon, ENSSIB, 2015, URL : <https://www.enssib.fr/bibliotheque-numerique/documents/66008-le-crowdsourcing-applique-aux-archives-numeriques-concepts-pratiques-et-enjeux.pdf> (visité le 19/08/2024).
- NOEL (William), *William Noel : Revealing the lost codex of Archimedes / TED Talk*, 12 mai 2021, URL : [https://www.ted.com/talks/william\\_noel\\_revealing\\_the\\_lost\\_codex\\_of\\_archimedes?subtitle=en](https://www.ted.com/talks/william_noel_revealing_the_lost_codex_of_archimedes?subtitle=en) (visité le 19/08/2024).
- Overall Aims – Intavia*, URL : <https://web.archive.org/web/20231207162031/https://intavia.eu/overall-aims/> (visité le 19/08/2024).
- Penser la découvervabilité des contenus culturels, juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels> (visité le 19/08/2024).
- PILLAUD (Hervé), « Et si l'intelligence artificielle nous faisait changer de logique ? », *Paysans & société*, 405-3 (2024), Place : Paris Publisher : Revue Paysans et Société, p. 25-33, DOI : 10.3917/pes.405.0025.
- PLOUVIEZ (Mélanie), *Philosophie de l'héritage : le projet Philherit*, Penser la découvervabilité des contenus culturels, 20 juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels>.
- POUPEAU (Gautier), « La donnée : nouvelle perspective pour les bibliothèques », dans *Vers de nouveaux catalogues*, ISSN : 0184-0886, Paris, 2016 (Bibliothèques), p. 159-171, DOI : 10.3917/elec.berme.2016.01.0159.
- POUYLLAU (Stéphane) et OLLAMA (LLAMA2 +), *Quels usages du “Retrieval-augmented generation” en SHS ?*, HN Lab Log, Publisher : HN Lab, 17 mars 2024, URL : <https://hnlab.huma-num.fr/blog/2024/03/17/RAG/> (visité le 19/08/2024).
- ROBINEAU (Régis) et SAJDAK (Cécile), *Le programme IIIF 360 pour les archives*, Journée d'étude internationale IIIF, 30 nov. 2023.
- SHEN (Jeffrey J.), *A Generous Interface for the Discoverability of Text Collections*, Accepted : 2023-07-31T19:38:10Z, Thesis, Massachusetts Institute of Technology, 2023, URL : <https://dspace.mit.edu/handle/1721.1/151417> (visité le 19/08/2024).
- VANEVAR BUSH, « As we may think », *Life Magazine* (oct. 1945), p. 112-114, URL : [https://worrydream.com/refs/Bush\\_1945\\_-\\_As\\_We\\_May\\_Think\\_\(Life\\_Magazine\).pdf](https://worrydream.com/refs/Bush_1945_-_As_We_May_Think_(Life_Magazine).pdf) (visité le 21/08/2024).

WINDHAGER (Florian), FEDERICO (Paolo), MAYR (Eva), SCHREDER (Günther) et SMUC (Michael), « A Review of Information Visualization Approaches and Interfaces to Digital Cultural Heritage Collections » ().

- « Visualization of Cultural Heritage Collection Data : State of the Art and Future Challenges », *IEEE Transactions on Visualization and Computer Graphics*, 25–6 (1<sup>er</sup> juin 2019), p. 2311-2330, DOI : 10.1109/TVCG.2018.2830759.
- « Orchestrating Overviews : A Synoptic Approach to the Visualization of Cultural Collections », *Open Library of Humanities*, 4–2 (13 août 2018), p. 9, DOI : 10.16995/olh.276.

# Limites de la notion

- Accessibilité numérique / Mon Parcours Handicap*, URL : <https://www.monparcourshandicap.gouv.fr/accessibilite-numerique> (visité le 19/08/2024).
- ADMINAT, *Et si l'accessibilité numérique et le SEO étaient lié ?*, Product for Good, 1<sup>er</sup> sept. 2023, URL : <https://productforgood.fr/et-si-laccessibilite-numerique-et-le-seo-etais-lie> (visité le 19/08/2024).
- « Aux Etats-Unis, Internet Archive poursuivi en justice par des maisons d'édition » (, 21 mars 2023), URL : [https://www.lemonde.fr/pixels/article/2023/03/21/aux-etats-unis-internet-archive-poursuivi-en-justice-par-des-maisons-d-edition\\_6166381\\_4408996.html](https://www.lemonde.fr/pixels/article/2023/03/21/aux-etats-unis-internet-archive-poursuivi-en-justice-par-des-maisons-d-edition_6166381_4408996.html) (visité le 19/08/2024).
- BAKSHY (Eytan), MESSING (Solomon) et ADAMIC (Lada A.), « Exposure to ideologically diverse news and opinion on Facebook », *Science*, 348–6239 (juin 2015), p. 1130-1132, DOI : [10.1126/science.aaa1160](https://doi.org/10.1126/science.aaa1160).
- BENGHOZI (Pierre-Jean) et BENHAMOU (Françoise), « Longue traîne : levier numérique de la diversité culturelle ? », *Culture prospective*, 1–1 (2008), Place : Paris Publisher : Ministère de la Culture - DEPS, p. 1-11, DOI : [10.3917/culp.081.0001](https://doi.org/10.3917/culp.081.0001).
- BERMÈS (Emmanuelle), *Des parcours de sens dans le Centre Pompidou virtuel*, 1<sup>er</sup> janv. 2013, URL : <https://bbf.enssib.fr/consulter/bbf-2013-05-0052-013%20> (visité le 19/08/2024).
- BESNEHARD (Éléonore), « Évaluer une interface documentaire augmentée : étude de cas sur le projet ANR Archival » () .
- BLOCH (Isabelle), *Les nouveaux enjeux de l'IA*, Polytechnique Insights, 2021, URL : <https://www.polytechnique-insights.com/dossiers/digital/les-nouveaux-enjeux-delia/> (visité le 19/08/2024).
- BOURREAU (Marc), MAILLARD (Sisley) et MOREAU (François), « Une analyse économique du phénomène de la longue traîne dans les industries culturelles », *Revue française d'économie*, XXX–2 (2015), p. 179-216, DOI : [10.3917/rfe.152.0179](https://doi.org/10.3917/rfe.152.0179).
- Bulles de filtre et chambres d'écho - Fondation Descartes*, URL : <https://www.fondationdescartes.org/2020/07/bulles-de-filtre-et-chambres-decho/> (visité le 19/08/2024).

CANADIEN (Patrimoine), *Rapport — Rencontre internationale sur la diversité des contenus à l’ère numérique*, mai 2019, URL : <https://www.canada.ca/fr/patrimoine-canadien/services/diversite-contenus-ere-numerique/strategie-mobilisation-internationale/rapport.html> (visité le 25/08/2024).

« Ce qu'il faut savoir sur Cambridge Analytica, la société au cœur du scandale Facebook » (, 22 mars 2018), URL : [https://www.lemonde.fr/pixels/article/2018/03/22/ce-qu-il-faut-savoir-sur-cambridge-analytica-la-societe-au-c-ur-du-scandale-facebook\\_5274804\\_4408996.html](https://www.lemonde.fr/pixels/article/2018/03/22/ce-qu-il-faut-savoir-sur-cambridge-analytica-la-societe-au-c-ur-du-scandale-facebook_5274804_4408996.html) (visité le 19/08/2024).

« Comprendre les quotas de chansons francophones à la radio » (, 22 avr. 2016), URL : [https://www.lemonde.fr/les-decodeurs/article/2016/04/22/comprendre-les-quotas-de-chansons-francophones-a-la-radio\\_4907025\\_4355770.html](https://www.lemonde.fr/les-decodeurs/article/2016/04/22/comprendre-les-quotas-de-chansons-francophones-a-la-radio_4907025_4355770.html) (visité le 19/08/2024).

*Découvrabilité en ligne des contenus culturels francophones*, 15 mai 2024, URL : <https://www.culture.gouv.fr/catalogue-des-demarches-et-subventions/appels-a-projets-candidatures/dcouvrabilite-en-ligne-des-contenus-culturels-francophones> (visité le 19/08/2024).

*Directive (UE) 2019/790 du Parlement européen et du Conseil du 17 avril 2019 sur le droit d'auteur et les droits voisins dans le marché unique numérique et modifiant les directives 96/9/CE et 2001/29/CE (Texte présentant de l'intérêt pour l'EEE.)* 17 avr. 2019, URL : <http://data.europa.eu/eli/dir/2019/790/oj/fra> (visité le 19/08/2024).

DURAND (Emmanuel), « Chapitre 1 - L’ère de l’hyperchoix », dans *L’attaque des clones*, Paris, 2016 (Nouveaux Débats), p. 19-28, URL : <https://www.cairn.info/1-attaque-des-clones--9782724619805-p-19.htm> (visité le 19/08/2024).

— « Chapitre 5 - Le nouvel âge de la diversité », dans *L’attaque des clones*, Paris, 2016 (Nouveaux Débats), p. 73-88, URL : <https://www.cairn.info/1-attaque-des-clones--9782724619805-p-73.htm> (visité le 19/08/2024).

EPSTEIN (Robert) et ROBERTSON (Ronald E.), « The search engine manipulation effect (SEME) and its possible impact on the outcomes of elections », *Proceedings of the National Academy of Sciences*, 112–33 (août 2015), DOI : 10.1073/pnas.1419828112.

ERTZSCHEID (Olivier), *Du Web sémantique au Web synthétique*, oct. 2023, URL : <https://affordance.framasoft.org/2023/10/du-web-semantique-au-web-synthetique/> (visité le 23/08/2024).

FARCHY (Joëlle) et TALLEC (Steven), « De l’information aux industries culturelles, l’hypothèse chahutée de la bulle de filtre », *Questions de communication*, 43–1 (2023), Place : Nancy Publisher : Éditions de l’Université de Lorraine, p. 241-268, URL : <https://www.cairn.info/revue-questions-de-communication-2023-1-page-241.htm> (visité le 19/08/2024).

GARRETT (R. Kelly), « Politically motivated reinforcement seeking : Reframing the selective exposure debate », *Journal of Communication*, 59–4 (2009), p. 676-699, DOI : 10.1111/j.1460-2466.2009.01452.x.

GOËTA (Samuel), « Fred Turner, Aux sources de l'utopie numérique. De la contre-culture à la cyberculture, Stewart Brand un homme d'influence : Trad. de l'anglais par Laurent Vannini, Caen, C&F Éd., 2012, 432 p. » *Questions de communication*–23 (31 août 2013), p. 493-495, DOI : 10.4000/questionsdecommunication.8619.

*Google devient client de Wikipédia*, 22 juin 2022, URL : <https://www.lefigaro.fr/flash-eco/google-devient-client-de-wikipedia-20220622> (visité le 19/08/2024).

GROSSETTI (Quentin), DU MOUZA (Cédric) et TRAVERS (Nicolas), « Community-Based Recommendations on Twitter : Avoiding the Filter Bubble », dans 2019, p. 212-227, DOI : 10.1007/978-3-030-34223-4\_14.

GUILLARD (Valérie), *Chapitre 3. De la sobriété à la sobriété énergétique, numérique, matérielle / Cairn.info*, Paris, 2021 (Comment consommer avec sobriété ?), URL : <https://www-cairn-info.proxy.charters.psl.eu/comment-consommer-avec-sobriete--9782807331891-page-55.htm> (visité le 19/08/2024).

*Hyperchoix et prescription culturelle*, URL : <https://www.fabula.org/actualites/64314/colloque-international-hyperchoix-et-prescription-culturelle.html> (visité le 19/08/2024).

KAPLAN (Frédéric), *Quand les mots valent de l'or*, Le Monde diplomatique, 1<sup>er</sup> nov. 2011, URL : <https://www.monde-diplomatique.fr/2011/11/KAPLAN/46925> (visité le 19/08/2024).

LAUGÉE (Françoise), *La « viralité » ou l'illusion d'hyperchoix : « l'information qu'il nous faut »*, La revue européenne des médias et du numérique, Section : Articles & chroniques, 21 mars 2013, URL : <https://la-rem.eu/2013/03/la-viralite-ou-lillusion-dhyperchoix-linformation-quil-nous-faut/> (visité le 19/08/2024).

*Le CCfr et le signalement du patrimoine*, URL : <https://www.bnf.fr/fr/le-ccfr-et-le-signalement-du-patrimoine> (visité le 25/08/2024).

*Les algorithmes publics : enjeux et obligations* / [guides.etalab.gouv.fr/algorithmes/guide/#\\_2-les-enjeux-des-algorithmes-publics](https://guides.etalab.gouv.fr/algorithmes/guide/#_2-les-enjeux-des-algorithmes-publics) (visité le 19/08/2024).

*Les personnes handicapées en France*, 2022, URL : <https://drees.solidarites-sante.gouv.fr/sites/default/files/2022-12/AAS22-Fiche%2019%20-%20Les%20personnes%20handicap%C3%A9es%20en%20France.pdf> (visité le 19/08/2024).

LESSIG (Lawrence), *Code is Law – Traduction française du célèbre article de Lawrence Lessig – Framablog*, Framblog.org, janv. 2000, URL : <https://framablog.org/2010/05/22/code-is-law-lessig/> (visité le 19/08/2024).

MARTIN-STOCKER (Tristan) et DELABRE (Cyrille), *Penser la découvrabilité des contenus culturels*, juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels> (visité le 19/08/2024).

MAXWELL (Winston), « Comment améliorer l'explicabilité et la responsabilité des algorithmes ? », *Les cahiers Louis Bachelier* (, 2020).

NITOT (Tristan), *La loi de Moore est morte et c'est une bonne nouvelle - OCTO Talks!*, OCTO Talks!, 27 juin 2024, URL : <https://blog.octo.com/la-loi-de-moore-est-mort-e-t-c'est-une-bonne-nouvelle> (visité le 19/08/2024).

*Notion d'accessibilité numérique - RGAA*, URL : <https://accessibilite.numerique.gouv.fr/obligations/notions-accessibilite-numerique/> (visité le 19/08/2024).

OURY (Antoine), *Condamnée, Internet Archive retire 500 000 livres de sa bibliothèque*, URL : <https://actualitte.com/article/117813/droit-justice/condamnee-internet-archive-retire-500-000-livres-de-sa-bibliotheque> (visité le 19/08/2024).

*Plan de numérisation : les collections en ligne*, URL : <https://www.culture.gouv.fr/Thematiques/Musees/Pour-les-professionnels/Conserver-et-gerer-les-collections/Numeriser-les-collections/Plan-de-numerisation-les-collections-en-ligne> (visité le 25/08/2024).

*Pourquoi ChatGPT est une bombe environnementale*, Le Nouvel Obs, Section : Economie, 18 sept. 2023, URL : <https://www.nouvelobs.com/economie/20230918.OBS78305/pourquoi-chatgpt-est-une-bombe-environnementale.html> (visité le 19/08/2024).

*Quelle est la part du numérique dans les émissions mondiales de gaz à effet de serre en 2024 ?, URL : <https://ekwateur.fr/blog/enjeux-environnementaux/emissions-co2-numerique/>* (visité le 19/08/2024).

ROCHEFORT (Mathilde), *OpenAI n'utilise plus les données des clients de son API pour former ses modèles*, mai 2023, URL : <https://siecledigital.fr/2023/05/09/openai-api-formation-modeles/> (visité le 21/08/2024).

RODRIGUEZ (Ashley), *Netflix divides its 93 million users around the world into 1,300 “taste communities”*, mars 2017, URL : <https://qz.com/939195/netflix-nflx-divides-its-93-million-users-around-the-world-not-by-geography-but-into-1300-taste-communities> (visité le 22/08/2024).

ROUVROY (Antoinette) et BERNS (Thomas), « Gouvernementalité algorithmique et perspectives d'émancipation. Le disparate comme condition d'individuation par la relation ? », *Réseaux*, 177–1 (2013), Place : Paris Publisher : La Découverte, p. 163-196, DOI : 10.3917/res.177.0163.

SERREL (Mathilde), *Algorithmes : comment sortir de sa "bulle culturelle" ? / France Culture*, URL : <https://www.radiofrance.fr/franceculture/podcasts/le->

billet-culturel/algorithmes-comment-sortir-de-sa-bulle-culturelle-7342064 (visité le 19/08/2024).

TEXIER (Bruno), + 48% : *l'intelligence artificielle pèse lourd dans le bilan carbone de Google* / Archimag, 3 juill. 2024, URL : <https://www.archimag.com/numerique-responsable/2024/07/03/48-intelligence-artificielle-pese-lourd-bilan-carbone-google-0> (visité le 19/08/2024).

TUFEKCI (Zeynep), « Opinion | YouTube, the Great Radicalizer », *The New York Times* (, mars 2018), URL : <https://www.nytimes.com/2018/03/10/opinion/sunday/youtube-politics-radical.html> (visité le 22/08/2024).

*Valorisation d'archives multimédia : Compréhension automatique multimodale du langage pour de nouvelles interfaces intelligentes de médiation et de transmission des savoirs*, Agence nationale de la recherche, URL : <https://anr.fr/Projet-ANR-19-CE38-0011> (visité le 19/08/2024).



# Encyclopédies et statistiques

À propos - *notreHistoire.ch*, URL : <https://notrehistoire.ch/pages/a-propos> (visité le 19/08/2024).

« Algorithme », *Wikipédia* (, août 2024), URL : <https://fr.wikipedia.org/w/index.php?title=Algorithme&oldid=217643543> (visité le 19/08/2024).

« ARPANET », *Wikipédia* (, juill. 2024), URL : <https://fr.wikipedia.org/w/index.php?title=ARPANET&oldid=217010020> (visité le 19/08/2024).

*Centre national de ressources linguistiques et textuelles (CNRTL : Définition de INTERFACE*, URL : <https://www.cnrtl.fr/lexicographie/interface> (visité le 19/08/2024).

*CNRTL : Définition de CATALOGUE*, URL : <https://cnrtl.fr/definition/academie9/catalogue> (visité le 19/08/2024).

*Data growth worldwide 2010-2025 / Statista*, URL : <https://www.statista.com/statistics/871513/worldwide-data-created/> (visité le 19/08/2024).

*DIGITAL REPORT - LES DERNIERS CHIFFRES DU NUMÉRIQUE - OCTOBRE 2023 - We Are Social France*, URL : <https://wearesocial.com/fr/blog/2023/10/digital-report-les-derniers-chiffres-du-numerique-octobre-2023/> (visité le 19/08/2024).

*Droit d'auteur en France — Wikipédia*, URL : [https://fr.wikipedia.org/wiki/Droit\\_d'auteur\\_en\\_France](https://fr.wikipedia.org/wiki/Droit_d'auteur_en_France) (visité le 19/08/2024).

*Explicabilité (IA)*, URL : <https://www.cnil.fr/fr/definition/explicabilite-ia> (visité le 19/08/2024).

*Internet et réseaux sociaux : nombre d'utilisateurs 2024 / Statista*, URL : <https://www.statista.com/statistiques/1350675/nombre-utilisateurs-internet-reseaux-sociaux-monde/> (visité le 19/08/2024).

*L.H.O.O.Q. - Centre Pompidou*, URL : <https://www.centre Pompidou.fr/fr/ressources/oeuvre/c5pXdk6> (visité le 19/08/2024).

*Le médium c'est le message — Wikipédia*, URL : [https://fr.wikipedia.org/wiki/Le\\_m%C3%A9dium\\_c%27est\\_le\\_message](https://fr.wikipedia.org/wiki/Le_m%C3%A9dium_c%27est_le_message) (visité le 19/08/2024).

*Loi de Moore* — Wikipédia, URL : [https://fr.wikipedia.org/wiki/Loi\\_de\\_Moore](https://fr.wikipedia.org/wiki/Loi_de_Moore) (visité le 19/08/2024).

« Ludification », Wikipédia (, juill. 2024), URL : <https://fr.wikipedia.org/w/index.php?title=Ludification&oldid=217012791> (visité le 19/08/2024).

« Portail web », Wikipédia (, juill. 2024), URL : [https://fr.wikipedia.org/w/index.php?title=Portail\\_web&oldid=217196741](https://fr.wikipedia.org/w/index.php?title=Portail_web&oldid=217196741) (visité le 19/08/2024).

*Qu'est-ce que le digital labor ?*, URL : <https://larevuedesmedias.ina.fr/quest-ce-que-le-digital-labor> (visité le 19/08/2024).

*Search Engine Market Share France / Statcounter Global Stats*, URL : <https://gs.statcounter.com/search-engine-market-share/all/france> (visité le 19/08/2024).

*Sérendipité / Académie française*, URL : <https://www.academie-francaise.fr/serendipite> (visité le 19/08/2024).

*Tour de Babel* — Wikipédia, URL : [https://fr.wikipedia.org/wiki/Tour\\_de\\_Babel](https://fr.wikipedia.org/wiki/Tour_de_Babel) (visité le 19/08/2024).

« Transistor », Wikipédia (, juill. 2024), URL : <https://fr.wikipedia.org/w/index.php?title=Transistor&oldid=217237046> (visité le 19/08/2024).

« Utilisation d'Internet », Wikipédia (, avr. 2024), URL : [https://fr.wikipedia.org/w/index.php?title=Utilisation\\_d%27Internet&oldid=214019107](https://fr.wikipedia.org/w/index.php?title=Utilisation_d%27Internet&oldid=214019107) (visité le 19/08/2024).

*Web 2.0* — Wikipédia, URL : [https://fr.wikipedia.org/wiki/Web\\_2.0](https://fr.wikipedia.org/wiki/Web_2.0) (visité le 19/08/2024).

# Introduction

« L'univers (que d'autres appellent la Bibliothèque), se compose d'un nombre indéfini [...] de galeries hexagonales, avec au centre de vastes puits d'aération bordés par des balustrades très basses. [...] vingt longues étagères, à raison de cinq par côté, couvrent tous les murs moins deux [...]. Chacun des murs de chaque hexagone porte cinq étagères ; chaque étagère comprend trente-deux livres, tous de même format ; chaque livre a quatre cent dix pages ; chaque page, quarante lignes, et chaque ligne, environ quatre-vingts caractères noirs<sup>2</sup>. »

Dans sa nouvelle, Jorge Luis Borges décrit son « rêve de bibliothèque » : une bibliothèque presque infinie contenant toutes les combinaisons possibles de 23 des lettres de l'alphabet combinées avec l'espace et le point. Rêve car elle contient tous les livres parus, disparus, à paraître, ainsi que toutes leurs interprétations, les réfutations des interprétations, dans toutes les langues, mêmes inconnues, mais aussi l'histoire de votre vie, passée, présente, ou future<sup>3</sup>.

Mais comme le décrit William Marx dans son cours du collège de France consacré au « rêve de la bibliothèque parfaite », ce rêve tourne vite au cauchemar, celui de la masse, cette bibliothèque n'est pas ordonnée, pas classée, « les nombres s'y multiplient au-delà du raisonnable »<sup>4</sup>. Combien de pages contenant d'incompréhensibles suites de caractères vous faudra-t-il consulter pour trouver le récit de votre vie ? Combien de livres devrez-vous ouvrir dans cette bibliothèque finie mais contenant  $1.956 \times 10^{1834097}$  livres pour y retrouver les œuvres disparues d'Eschyle ? Combien de kilomètres devrez-vous parcourir dans cet espace plus grand que l'univers connu pour y trouver ne serait-ce qu'un livre qui aurait du sens ? La bibliothèque de Babel exprime ainsi le débordement du langage, punition divine

2. Jorge Luis Borges, *La bibliothèque de Babel*, 1963, URL : <https://baptiste-tosi.eu/documents/la-bibliothèque-de-babel.pdf> (visité le 19/08/2024), p. 1.

3. William Marx, *Le rêve de la bibliothèque parfaite : épisode • 4/10 du podcast Les bibliothèques invisibles / France Culture*, URL : <https://www.radiofrance.fr/franceculture/podcasts/les-cours-du-college-de-france/le-reve-de-la-bibliothèque-parfaite-7100321> (visité le 19/08/2024).

4. *Ibid.*

infligée aux humains dans le mythe éponyme<sup>5</sup>. Elle se transforme en cauchemar non pas du fait de sa volumétrie mais par l’absence de classement, par l’impossibilité de retrouver quoi que ce soit dans cette bibliothèque gouvernée par les nombres : « nombre indéfini de galeries hexagonales contenant chacune 20 étagères contenant chacune 32 livres contenant chacun 410 pages contenant chacune 40 lignes contenant chacune 80 caractères. »

Publiée en 1941, *La bibliothèque de Babel* n’a jamais cessée d’être actuelle, une quantité d’information immense gouvernée par les nombres, écrasants et impossibles à imaginer : on fait assez rapidement le parallèle avec le web, ses Zettaoctets de données<sup>6</sup>, immense lac dans lequel il est facile de se perdre et où le problème majeur que posait la bibliothèque de Borges, celui de la place prise par ces milliards de milliards de livres n’existe (presque) plus. Ainsi a émergé en 2016 la notion de Découvrabilité<sup>7</sup> : « capacité qu’a un objet à être repéré parmi un vaste ensemble d’autres contenus, en particulier par une personne qui n’en faisait pas précisément la recherche. »<sup>8</sup> qui peut se résumer en trois mots : disponibilité d’abord, repérabilité ensuite, et enfin, recommandation. Les questions posées par la notion, celles de se repérer dans l’immensité documentaire, ne sont pas neuves, Borges les posait déjà en 1941. Ce sont les réponses qui le sont : tout en posant le problème de la masse, le web – et plus largement les technologies de l’information et de la communication – viennent aussi offrir la solution en mettant à notre disposition un arsenal de possibilités de classement que sont les index, moteurs de recherche et autres algorithmes de recommandation.

Cette problématique de la masse se pose aussi de façon exacerbée dans les institutions patrimoniales qui ont (on y reviendra en détails) depuis plusieurs années numérisé, parfois massivement, leurs fonds générant elles aussi une masse qu’il devient difficile d’appréhender. Tel est le cas de la Radio Télévision Suisse (RTS), institution créée en 2011 suite à la fusion de la Télévision Suisse Romande (TSR) et de la Radio Suisse Romande (RSR), réunies en une seule entité d’entreprise (RTS) membre de la Société suisse de Radiodiffusion (SSR) qui en compte trois autres, correspondant aux langues nationales Suisses : la SRF (Schweizer Radio und Fernsehen) pour l’allemand, la RSI (Radiotelevisione svizzera) pour l’italien et la RTR (Radiotelevisiun Svizra Rumantscha) pour le romanche. En une dizaine d’années, la RTS a numérisé la totalité des 680 000 heures d’archives radiophoniques et des 220 000 heures d’archives télévisuelles qu’elle conservait. Une telle masse documentaire pose là aussi la question de la découvrabilité : comment

5. *Tour de Babel* — Wikipédia, URL : [https://fr.wikipedia.org/wiki/Tour\\_de\\_Babel](https://fr.wikipedia.org/wiki/Tour_de_Babel) (visité le 19/08/2024).

6. Un zettaoctet correspond à un million de téraoctets (To) ou un milliard de gigaoctets (Go)

7. Nous verrons que si le terme francophone est né en 2016, les questions posées par la découvrabilité ne sont pas neuves

8. *Stratégie commune de la mission franco-qubécoise sur la découvrabilité des contenus culturels francophones / Gouvernement du Québec...*

faire en sorte que les utilisateurs, documentalistes, chargés de la valorisation d'un tel fonds s'y retrouvent ?

Si l'objet du stage effectué à la RTS (pour une durée de quatre mois entre avril et juillet 2024) était au départ de réfléchir à la visualisation des données, un état de l'art réalisé sur le sujet ainsi que des entretiens menés avec une dizaine de personnes utilisatrices du fonds (documentalistes et producteurs de télévision) ont permis de faire émerger un fort besoin d'améliorer la découvrabilité de ce dernier. Les différents chemins parcourus en vue de remplir cet objectif ont donné lieu à l'écriture d'une preuve de concept (POC) sur le domaine (annexée au présent mémoire) mais aussi à une réflexion plus large sur la notion de découvrabilité. Ainsi, au long de ce mémoire nous poserons la question suivante : « Dans un secteur patrimonial où la numérisation a pris une place considérable : quelle importance revêt la notion de découvrabilité et quelles sont ses limites ? » À laquelle nous répondrons en prenant des exemples tirés de notre expérience à la RTS mais aussi d'ailleurs.

Nous commencerons par plonger dans les enjeux autour de la notion de découvrabilité que sont la disponibilité, la repérabilité et la recommandation. Ce sera aussi l'occasion de tenter d'historiciser la découvrabilité : de quoi est-elle le reflet et à quelles questions semble-t-elle répondre ? Afin d'aborder la repérabilité, et tout au long de ce mémoire, nous nous appuierons sur des éléments vus pendant le stage, ainsi, nous ferons un état des fonds conservés par l'institution ainsi que de leurs métadonnées. Nous évoquerons ensuite la recommandation en passant par l'importance, très patrimoniale, de la notion de sérendipité. La deuxième partie tentera d'aller plus loin en explorant la question des interfaces favorisant la découvrabilité, ces dernières nous semblent en effet capitales dans le cas patrimonial. Ce sera l'occasion de parcourir les transformations des catalogues, l'importance de la visualisation de l'information et ce que nous intitulons les « nouvelles interfaces » et les nouvelles pratiques qui en découlent. Nous terminerons notre mémoire par poser la question des limites et des problématiques, pour cela nous proposerons un état du Web en tant qu'écosystème favorisant ou non la découvrabilité. Nous explorerons ensuite les questions institutionnelles autour de la formation des agents et des réglementations etacheverons ce mémoire par une réflexion sur les angles morts de la notion de découvrabilité que sont l'accessibilité numérique, les enjeux écologiques et ceux d'explicabilité algorithmique.



## Première partie

### Partie 1 : Historique et enjeux de la découvrabilité



# Chapitre 1

## Aux origines était la disponibilité

### 1. La nouvelle bibliothèque de Babel : vers un Big data patrimonial

Depuis plus de vingt ans, les institutions patrimoniales ont massivement numérisé leurs collections. Si l'utopie de recréation d'une « Bibliothèque d'Alexandrie 2.0 » s'est rapidement révélée irréaliste<sup>1</sup>, il n'en reste pas moins que le volume de données numérisées est devenu colossal. Cela est encore plus vrai dans le domaine du patrimoine audiovisuel : les institutions occidentales se sont retrouvées, au tournant des années 2000, face à des problématiques de dégradations des supports très importantes, notamment à cause du tristement célèbre « syndrome du vinaigre »<sup>2</sup>. Il a donc fallu numériser ; mais la dégradation des supports n'est pas la seule raison de ces programmes de numérisation massifs, et il nous semble ici intéressant de détailler les autres. En premier lieu, il faut évoquer qu'ils ont eu lieu à une période où la société elle-même se « numérisait » : il y a eu une demande forte de la part des citoyens d'accès à ce qu'ils considéraient comme « leur patrimoine »<sup>3</sup> ; qui plus est — dans le cas de la RTS — la mise à disposition de quelques fragments de la collection avait créé un engouement qui a permis de donner une impulsion au programme de numérisation ; il faut ensuite ajouter à cela un besoin d'accès multiple aux mêmes documents, c'est le cas à la RTS évidemment (plusieurs émissions avaient souvent besoin de réutiliser les mêmes images d'illustration), mais c'est encore plus le cas pour des do-

1. Emmanuelle Bermès, *"De l'écran à l'émotion, quand le numérique devient patrimoine"*, Paris, 2024, p. 20.

2. « Le syndrome du vinaigre est le phénomène de dépolymérisation spontanée qui se produit dans les films pour la photographie ou le cinéma, par dégradation de l'acétate en acide acétique, causant ainsi la détérioration du support des œuvres. » - Wikipédia, Syndrome du vinaigre

3. Marielle Rezzonico, *Entretien avec Marielle Rezzonico, chargée de valorisation des archives*, juin 2023.

cuments tels que l'État civil, massivement numérisé par les archives départementales en France. Pour terminer, et c'est loin d'être anodin, il faut ajouter à toutes ces raisons le fait que « c'était possible »<sup>4</sup> : l'arrivée de technologies de stockage de masse (LTO)<sup>5</sup> et de chaînes de numérisation plus rapides et efficaces rendaient la numérisation réalisable et soutenable financièrement. Ce mouvement qui a eu lieu dans les institutions audiovisuelles est un exemple assez extrême : peu d'institutions ont numérisé la totalité de leur patrimoine même si la volonté de le faire n'a pas manqué. Elle s'est heurtée à la réalité des métiers et à l'intérêt d'une telle opération<sup>6</sup>.

Loin d'être les seules à produire des données massives, les institutions patrimoniales suivent le mouvement initié par les géants du web, et notamment Google qui en 2005 annonce à la foire du livre de Francfort le projet « Ocean » qui vise à numériser intégralement les collections de six puis seize bibliothèques partenaires<sup>7</sup>, créant un véritable électrochoc qui a marqué l'intensification des volumes numérisés pour tous les acteurs, privés ou publics.<sup>8</sup>

Les données disponibles sur le web, au tournant des années 2010, deviennent donc massives. S'il est très délicat de donner des chiffres sur ce volume, qui de toute manière sont inintelligibles, on estime généralement qu'en 2010 1,2 zettaoctet<sup>9</sup> ont été produits contre 64 Zo en 2020 et sur ce même volume, environ 5% seraient conservés soit 3,2 Zo<sup>10</sup>. Le secteur patrimonial est loin d'être responsable de cette augmentation, c'est plutôt l'essor du web dit 2.0 : celui des blogs, des réseaux sociaux, de l'interactivité<sup>11</sup> décrit en 2009 par Benjamin Bayard dans une phrase qui est devenue célèbre : « L'imprimerie a permis au peuple de lire, internet va lui permettre d'écrire » à qui il faut imputer cette production documentaire massive (suivi de nos jours par les objets connectés). Cette surabondance documentaire sans précédent pose évidemment des questions de découvrabilité, et plus encore de recherchabilité. De fait, dès 2007, un article intitulé « The discoverability of the web »<sup>12</sup> pose la question du pourcentage de pages renvoyées par un moteur de recherche sur un sujet donné par rapport aux sources utiles : face à la masse grandissante de contenus

---

4. Denise BARCELLA, *Entretien avec Denise Barcella, experte patrimoine des archives de la RTS et ancienne enseignante de l'université de Lausanne en histoire de la télévision*. Mai 2024.

5. Pour linear tape open, méthode de stockage magnétique permettant de stocker de grands volumes de données de façon plus pérenne que sur disque dur

6. E. Bermès, "De l'écran à l'émotion, quand le numérique devient patrimoine"..., p. 21.

7. Olivier Ertzscheid, *Économie des biens culturels, cours de 2e année de DUT information et communication option métiers du livre et du patrimoine*, 2019.

8. E. Bermès, "De l'écran à l'émotion, quand le numérique devient patrimoine"...

9. Un zettaoctet correspond à un million de téraoctets (To) ou un milliard de gigaoctets(Go)

10. *Data growth worldwide 2010-2025 / Statista*, URL : <https://www.statista.com/statistics/871513/worldwide-data-created/> (visité le 19/08/2024).

11. *Web 2.0 — Wikipédia*, URL : [https://fr.wikipedia.org/wiki/Web\\_2.0](https://fr.wikipedia.org/wiki/Web_2.0) (visité le 19/08/2024).

12. Anirban Dasgupta, Arpita Ghosh, Ravi Kumar, Christopher Olston, Sandeep Pandey et Andrew Tomkins, « The discoverability of the web », dans *Proceedings of the 16th international conference on World Wide Web*, Banff Alberta Canada, 2007, p. 421-430, DOI : 10.1145/1242572.1242630.

sur le web, comment garantir la pertinence et l'efficacité des moteurs de recherche ? C'est bien là un signe que l'enjeu de découvrabilité n'est pas intrinsèque au secteur public et patrimonial.

Dans tous les cas, les volumes de données sont tels qu'on peut parler, dans notre cas de *big data patrimonial* : 10 millions de documents sur Gallica, la bibliothèque numérique de la Bibliothèque nationale de France<sup>13</sup>, 53 millions sur Europeana<sup>14</sup>, portail européen regroupant les bibliothèques numériques du continent, 1 million d'heures de programmes numérisés à la RTS<sup>15</sup>, 28 millions à l'Institut national de l'audiovisuel (INA) totalisant 80 pétaoctets de données<sup>16</sup>. Il devient totalement impossible pour l'humain d'appréhender les collections numérisées de façon globale (rendant leur consultation fastidieuse), qui plus est dans un contexte où les institutions patrimoniales sont loin d'être les seules à proposer du contenu en ligne : la bataille est rude pour capter l'attention des utilisateurs.

## 2. Quand la « Fatigue muséale » rencontre « l'économie de l'attention »

En 1916, Benjamin Ives Gilman posait le concept de Fatigue muséale<sup>17</sup>, fatigue ressentie par le visiteur d'un musée explorant une vaste collection. S'il est vrai que l'article originel est plus focalisé sur la posture du visiteur : souvent obligé de s'accroupir, de se baisser, pour regarder des objets parfois de tailles très réduites dans des vitrines aux reflets problématiques ; on peut étendre cette notion à une fatigue mentale dans laquelle le visiteur serait plongé par une trop grande abondance d'informations et d'objets riches à la fois visuellement et sémantiquement et par le manque de visibilité globale d'une collection, rendant sa compréhension épuisante<sup>18</sup>.

D'une part, comme noté plus haut, on a des collections patrimoniales massivement mises en ligne et qui génèrent une Fatigue muséale, car impossibles à appréhender dans

13. 10 millions de documents numérisés dans Gallica / BnF - Site institutionnel, URL : <https://www.bnf.fr/fr/actualites/10-millions-de-documents-numerises-dans-gallica> (visité le 19/08/2024).

14. Europeana, URL : <https://www.bnf.fr/fr/europeana> (visité le 19/08/2024).

15. Janique Sonderegger, *Entretien avec Janique Sonderegger, premier lien du cercle Data Management, service données et archives (RTS)*, mai 2024.

16. Eleonore Alquier, *Journée de présentation de l'institut national de l'audiovisuel (INA)*, janv. 2024.

17. Benjamin Ives Gilman, « Museum Fatigue », *The Scientific Monthly*, 2–1 (1916), Publisher : American Association for the Advancement of Science, p. 62-74, URL : <https://www.jstor.org/stable/6127> (visité le 19/08/2024).

18. Florian Windhager, Saminu Salisu, Günther Schreder et Eva Mayr, « Orchestrating Overviews : A Synoptic Approach to the Visualization of Cultural Collections », *Open Library of Humanities*, 4–2 (août 2018), DOI : 10.16995/olh.276, pp. 1-2.

leur ensemble et de l'autre, une ressource qui se raréfie : l'attention. Cette dernière est placée au centre du modèle économique du web si bien qu'on vient à parler d'une « Économie de l'attention » en reprenant le concept posé par Herbert Simon en 1971 et bien étudié en France par Yves Citton qui le définit comme un modèle fondé, non pas sur la rareté de l'offre face à la demande, mais tout à fait le contraire : la chose rare est ici la capacité de réception du public, son attention<sup>19</sup>. Donc dans un monde où l'offre est pléthorique, c'est ici la demande qui est précieuse. Cela constitue une véritable rupture pour les politiques culturelles et surtout en France, et il nous semble important de revenir sur cela en détails.

Pour ce faire, il nous faut remonter à la création du ministère de la Culture en 1959. La politique mise en œuvre alors était celle de l'offre ; André Malraux partait en effet du postulat que la médiation était inutile. Il considérait en effet que les œuvres étaient performatives et permettaient à leur regardeur de se transcender<sup>20</sup>. Cette approche s'observe notamment par une politique de l'offre, matérialisée par la création dans chaque département des maisons de la culture pour que, selon André Malraux : « n'importe quel enfant de seize ans, si pauvre soit-il, puisse avoir un véritable contact avec son patrimoine national et avec la gloire de l'esprit de l'humanité »<sup>21</sup>. Si l'arrivée au pouvoir de la gauche en 1981 et de Jack Lang au ministère de la Culture fait changer les politiques culturelles notamment du point de vue de la création qui s'ouvre aux cultures du monde et aux cultures dites alternatives (fondation du festival international de théâtre de rue d'Aurillac en 1986)<sup>22</sup> on voit poindre la remise en cause d'un art performatif ne nécessitant pas de médiation avec la mise en place de l'EAC (éducation artistique et culturelle). Le tournant majeur se situe vers 2010. Cela coïncide d'ailleurs avec le phénomène de « big data patrimonial » décrit plus haut, Frédéric Mitterrand, récemment nommé rue de Valois, veut rompre avec la politique de la « culture pour tous », fondée sur l'offre et avance l'idée d'une « culture pour chacun »<sup>23</sup> qui se voudrait plus volontaire en allant vers les personnes dites éloignées de la culture. Si à l'époque son discours avait été très fortement décrié par les acteurs culturels, force est de constater, comme le relève Claude Poissenot<sup>24</sup>, que

---

19. Emmanuel Durand, *L'attaque des clones : la diversité culturelle à l'ère de l'hyperchoix*, Paris, 2016 (Nouveaux débats, 44), Citton Yves, « pour une écologie de l'attention », Paris, Seuil, 2014, p. 16 *in.*

20. Christian Godin, « « La culture pour chacun » : une nouvelle politique culturelle ? », *Cités*, 45-1 (2011), p. 164-168, DOI : 10.3917/cite.045.0164, §3.

21. Emmanuel de Waresquel, *Dictionnaire des politiques culturelles de la France depuis 1959*, Paris, 2001, Entrée « (cité dans) maison de la culture ».

22. *Ibid.*

23. « Le ministère pose le cadre de sa nouvelle doctrine : la "culture pour chacun" » (, nov. 2010), URL : [https://www.lemonde.fr/culture/article/2010/11/04/le-ministere-pose-le-cadre-de-sa-nouvelle-doctrine-la-culture-pour-chacun\\_1435445\\_3246.html](https://www.lemonde.fr/culture/article/2010/11/04/le-ministere-pose-le-cadre-de-sa-nouvelle-doctrine-la-culture-pour-chacun_1435445_3246.html) (visité le 19/08/2024).

24. Claude Poissenot, *Vers une politique culturelle de la demande ? - Livres Hebdo*, URL : <https://www.livreshebdo.fr/article/vers-une-politique-culturelle-de-la-demande> (visité le 19/08/2024).

plusieurs actions ont été mises en œuvre dans ce sens ces dernières années, et notamment le Pass Culture, dont l'objectif est de donner à voir aux jeunes une grande variété de contenus culturels en leur proposant d'en choisir un certain nombre via des crédits : l'argent public est donc placé du côté de la demande, pour la stimuler et non plus de l'offre et c'est un changement fondamental.

Le tournant de l'année 2010 fait donc émerger deux problèmes : celui d'une surabondance de l'offre et celui, concomitant, d'une raréfaction de la demande que des collections massives fatiguent rapidement. C'est à ces deux problématiques que semble vouloir répondre la notion de découvrabilité que nous tâcherons d'historiciser dans la prochaine partie.

### 3. La naissance de la découvrabilité

Il est difficile de donner une date précise à la naissance de la notion de découvrabilité tant que les questions qu'elle pose sont anciennes : comment naviguer dans le milliard de documents d'archives conservées avant la Révolution en France ?<sup>25</sup> Que répondre à Michelet qui, déjà en 1869, se plaignait d'être « inondé de journaux, de romans et d'un déluge de papier » ?<sup>26</sup> Il nous faut en revanche noter qu'elle s'est cristallisée au tournant des années 2010, moment où les institutions patrimoniales, et plus généralement le web, voient leur volume documentaire décupler. Ce qui change fondamentalement ici, c'est que les technologies de l'information et de la communication, en posant le problème de la masse, laissent aussi entrevoir une solution au travers de la notion de découvrabilité. Cette dernière est aussi liée à la crainte d'une perte de diversité culturelle accentuée par le web et ses effets de viralité et de bulle de filtre (sur lesquels nous reviendrons). Ainsi, en 2005, l'UNESCO publie une déclaration sur la diversité culturelle qui exprime la crainte que les technologies de l'information et de la communication renforcent un déséquilibre de visibilité des cultures minoritaires par rapport aux cultures déjà majoritaires :

« Constatant que les processus de mondialisation, facilités par l'évolution rapide des technologies de l'information et de la communication, s'ils créent les conditions inédites d'une interaction renforcée entre les cultures, représentent aussi un défi pour la diversité culturelle, notamment au regard des risques de déséquilibres entre pays riches et pays pauvres, »<sup>27</sup>

---

25. Olivier Poncet, *Archivistique moderne, cours de première année de Master Technologies numériques appliquées à l'histoire*, 2022.

26. E. Bermès, "De l'écran à l'émotion, quand le numérique devient patrimoine"..., p. 47.

27. *La Convention de 2005 sur la protection et la promotion de la diversité des expressions culturelles / Diversité des expresions culturelles*, URL : <https://www.unesco.org/creativity/fr/2005-convention>

Au moment où les pouvoirs publics constatent d'une part l'échec partiel de la politique de l'offre et envisagent de se tourner vers une politique de la demande, et d'autre part reconnaissent la difficulté de se démarquer sur le Web au milieu d'une multitude de contenus, il devient essentiel pour eux d'assurer leur visibilité. Ce n'est donc pas un hasard si l'évènement considéré comme fondateur de la notion de découvrabilité s'est tenu pendant la même décennie, en 2016 au Canada, et a eu pour sous-titre « le contenu à l'ère de l'abondance ». Il a été organisé par Le Conseil de la radiodiffusion et des télécommunications canadiennes (CRTC) et l'Office national du film du Canada (ONF)<sup>28</sup>, illustrant le lien — dans les politiques culturelles — entre découvrabilité et contenus audiovisuels (secteur souvent qualifié de privilégié, comme on le verra dans notre partie 3 sur les règlementations).

En France, si la pandémie<sup>29</sup> a clairement mis en avant la notion de découvrabilité, l'élément activateur semble être la grande enquête sur les pratiques culturelles de 2018 qui notait un « essor considérable des pratiques culturelles numériques » et qui consacrait dans le même temps une fréquentation des lieux culturels en hausse « surtout après [l'âge de] 40 ans » et une montée en puissance dans la population la plus jeune des pratiques culturelles numériques, quelles qu'elles soient : écoute de musique, jeux vidéos, mais aussi visionnage de films. Ainsi, la consommation quotidienne de télévision et de vidéos est en baisse pour toutes les catégories d'âges si l'on s'intéresse uniquement au linéaire,<sup>30</sup> mais en hausse si on y ajoute la consommation de vidéos en ligne.<sup>31</sup> D'où, probablement, le projet de lancement de la mission sur la découvrabilité en avril 2019 (planifiée avant la pandémie), qui rend un rapport sur la notion en novembre 2020.<sup>32</sup> C'est effectivement un moment où l'inquiétude pour les institutions culturelles de ne pas retrouver leur public du fait de changements d'habitudes (télétravail, digitalisation), est très présente et où les confinements successifs déplacent les pratiques culturelles vers le web. Prenons l'exemple des salles de cinéma, dont la fréquentation avait chuté en 2022(à la fin des restrictions sanitaires) un niveau inférieur à 40% de ce qu'elle était en 2019. La crainte de la perte

---

(visité le 19/08/2024).

28. Conseil de la radiodiffusion et des télécommunications canadiennes (CRTC) et l'Office national du film du Canada (ONF), *Le contenu à l'ère de l'abondance, sommet sur la découvrabilité des contenus culturels canadiens*, 2016, URL : <https://web.archive.org/web/20171027015812/http://decouvrabilite.ca/videos/resume-sommet-decouverabilite/>, Ironie du sort, le site originellement lié au sommet est indisponible mais a été sauvegardé sur Internet Archive.

29. Celle du Covid-19

30. La télévision/radio dite linéaire est celle qui est suivie en direct en tant que flux, elle se différencie de la consommation à la demande où le téléspectateur/auditeur regarde/écoute les programmes selon son choix, en ligne

31. *Cinquante ans de pratiques culturelles en France [CE-2020-2]*, juill. 2020, URL : <https://www.culture.gouv.fr/fr/espace-documentation/statistiques-ministerielles-de-la-culture2/publications/collections-de-synthese/culture-etudes-2007-2024/Cinquante-ans-de-pratiques-culturelles-en-France-CE-2020-2> (visité le 19/08/2024), p. 24.

32. *Stratégie commune de la mission franco-qubécoise sur la découvrabilité des contenus culturels francophones / Gouvernement du Québec...*

du public était très présente et il était essentiel que les salles de cinéma et leurs contenus (notamment le cinéma francophone) restent visibles alors que les pratiques culturelles avaient été déplacées en ligne.<sup>33</sup> Il faut toutefois aujourd’hui nuancer les craintes exprimées en 2022 ; l’année 2023 a montré que les salles noires regagnaient en vitalité pour atteindre un niveau de recettes presque équivalent à celui d’avant la crise sanitaire.<sup>34</sup> Les pratiques culturelles en ligne ont pris une importance capitale et il fallait pour les pouvoirs publics disposer d’outils pour promouvoir « les contenus culturels francophones ».

On l’a vu, l’émergence de la notion de découvrabilité découle d’un long processus et se veut une réponse aux enjeux de surabondance des contenus sur le web dans un contexte attentionnel raréfié. Nous avons décrit le premier enjeu du triptyque de la découvrabilité : la disponibilité, et avant de passer au deuxième – la repérabilité – il nous faut décrire le fonds conservé à la RTS, ce dernier exemplifie, en effet, très bien les processus mis en oeuvre par les institutions patrimoniales en matière de disponibilité.

---

33. Jörg Müller et Amandine Schreiber, « Les sorties culturelles des Français après deux années de Covid-19 », *Culture études*, 6–6 (2022), p. 1-20, DOI : 10.3917/cule.226.0001, §1 et §2.

34. « Les Français ont confirmé leur retour dans les salles de cinéma en 2023 » (, janv. 2024), URL : [https://www.lemonde.fr/economie/article/2024/01/02/les-francais-ont-confirmé-leur-retour-dans-les-salles-de-cinema-en-2023\\_6208729\\_3234.html](https://www.lemonde.fr/economie/article/2024/01/02/les-francais-ont-confirmé-leur-retour-dans-les-salles-de-cinema-en-2023_6208729_3234.html) (visité le 20/08/2024).



# Chapitre 2

## Un fonds massif aux métadonnées complexes : état des fonds conservés par la Radio-Télévision Suisse (RTS)

Afin de pouvoir y faire référence dans cette partie et dans les suivantes, il nous semble opportun de décrire de façon détaillée l'histoire du fonds de la RTS et de ses métadonnées. Nous nous appuierons ensuite, quand nous le jugerons pertinent, sur cette description pour étayer notre propos par des exemples tirés des pratiques locales et des expérimentations menées pendant notre stage.

### 1. Un « dépôt légal » audiovisuel en Suisse ?

Si en France, depuis 1992, l'INA (Institut national de l'audiovisuel) a la charge d'un dépôt légal intégral des flux audiovisuels, ce n'est pas le cas en Suisse, malgré le fait que l'article 21 de la loi fédérale sur la radio et la télévision (LRTV) soit intitulé « dépôt légal »<sup>1</sup>. En effet, le décret d'application (Ordonnance sur la radio et la télévision, ORTV) dans sa section « dépôt légal » réduit le champ à la conservation durable des émissions. Il est ici important de différencier les programmes, qui sont un ensemble d'émissions rassemblées (on parle de « grille des programmes »), et les émissions, qui sont donc un sous-ensemble contenu dans un programme<sup>2</sup>. Si l'on s'en tient à la définition de l'ORTV,

1. *Loi fédérale sur la radio et la télévision (LRTV) du 24 mars 2006, abroge la loi du 21 juin 1991 (état le 1er janvier 2024)*, URL : <https://www.fedlex.admin.ch/eli/cc/2007/150/fr> (visité le 19/08/2024).

2. « L'emploi du mot programme comme synonyme d'émission est impropre, un programme étant une grille regroupant plusieurs émissions. » - Wikipédia, émission, consulté le 18/07/2024

la RTS est tenue de conserver uniquement les émissions, éliminant de facto tout ce qui n'est pas inclus dedans, par exemple les publicités ou encore la météo. En revanche, la RTS est tenue de conserver depuis 1984, pendant quatre mois, tous les programmes diffusés à l'antenne pour vérification par l'Autorité indépendante d'examen des plaintes en matière de radiotélévision (AIEP).

Maintenant que le cadre légal, de jure, est posé, plongeons dans les fonds, de facto : comprendre leur histoire et celle de leurs métadonnées est indispensable pour cerner les enjeux autour de leur découvrabilité.

## 2. Le fonds radio et ses métadonnées

### a. L'origine de la Radiodiffusion en Suisse romande

En 1922, un émetteur radio fut installé — et quelle poésie — au « Champ-de-l'Air » près de Lausanne, initialement destiné à l'aviation pour la ligne Lausanne-Paris, fournissant des messages météorologiques et des avis de départ aux vols. Roland Pièce, pionnier de la radiodiffusion en Suisse, raconte : « Pour faire passer agréablement le voyage aux passagers, j'ai déjà eu l'idée de leur transmettre des disques de gramophones »<sup>3</sup>. La première émission eut lieu en octobre 1922, lors de l'inauguration de la station du Champ-de-l'Air, où un concert fut organisé pour les autorités présentes. Après les discours, les hymnes retentirent avec la particularité que l'orchestre était diffusé, tel un Chant dans l'air, sur des haut-parleurs, marquant ainsi la naissance de la radiodiffusion en Suisse romande<sup>4</sup>. La Suisse fait donc partie des pionniers de la radiodiffusion en Europe dès 1922, aux côtés de la France (émetteur de la tour Eiffel), de la BBC et de nombreuses initiatives aux États-Unis<sup>5</sup>. En 1931, l'inauguration de l'émetteur de Sottens a marqué une étape cruciale dans l'histoire de la radiodiffusion en Suisse romande<sup>6</sup>. La même année, le Conseil fédéral s'empare du sujet et crée la SSR (Société Suisse de Radiodiffusion et Télévision) en tant qu'organisation faitière des chaines et émetteurs locaux, c'est le début d'une diffusion plus régulière des émissions. À cette époque, les deux principales stations romandes, Radio Genève et Radio Lausanne (qui fusionneront en 1964), devaient se partager les

3. Roland Pièce raconte l'inauguration de l'émetteur du Champ-de-l'Air à Lausanne, audio, sept. 1939, URL : <https://www.rts.ch/archives/1939/audio/roland-piece-raconte-l-inauguration-de-l-emetteur-du-champ-de-l-air-a-lausanne-25836167.html> (visité le 19/08/2024).

4. *Ibid.*

5. François Vallotton, *Les jeunes années de la radio en Suisse romande - SSR Suisse Romande*, SSR Suisse Romande, mai 2022, URL : [https://ssrsr.ch/a\\_la\\_une/les-jeunes-annees-de-la-radio-en-suisse-romande/](https://ssrsr.ch/a_la_une/les-jeunes-annees-de-la-radio-en-suisse-romande/) (visité le 19/08/2024).

6. *Premier direct radio - rts.ch - Divers*, URL : <https://www.rts.ch/archives/tv/divers/3469563-premier-direct-radio.html> (visité le 19/08/2024).

créneaux horaires d'une même fréquence<sup>7</sup>.

## b. Histoire du fonds et de ses lacunes

Aux prémisses de la radio (1922 en Suisse romande), les émissions étaient diffusées en direct sans conservation de documents. Ce n'est qu'au cours des années 1930, avec le développement de la technologie des disques 78T à gravure directe, qu'il est devenu possible d'enregistrer les émissions, non pas pour constituer une archive, un patrimoine, mais pour permettre leur rediffusion<sup>8</sup>.

Dans les années 1950, la bande magnétique supplante progressivement les disques 78 tours en tant que principal support d'enregistrement. Ce format a été utilisé jusqu'à la fin des années 1990, avant l'adoption des supports numériques tels que les CD-Rom et les disques magnétooptiques (MOD). À partir de 2003, la production et l'archivage des programmes radiophoniques se sont entièrement numérisés<sup>9</sup>, ce qui ne veut pas dire que tout est conservé, seuls 20 à 30 % des documents sont alors archivés et documentés, souvent à la demande des directeurs adjoints de la rédaction ou des producteurs ou suivant des critères tels que : « Dans 25 ans on en parle », « Suissitude », « commercialisable », « rare », « vie de tous les jours », « déclarations importantes », « illustrations »...<sup>10</sup>.

Les fonds sont le reflet de l'histoire de la radiodiffusion en Suisse romande, marquée par une diffusion sur deux sites principaux, Lausanne et Genève. Jusqu'en 1998, les archives étaient constituées séparément par les radios d'alors : Radio-Lausanne et Radio-Genève (réunies en 1964 sous le nom de Radio Suisse Romande [RSR]). Ce n'est qu'après la réunification des services de documentation des deux studios à Lausanne en 1998 que le fonds a été unifié. Sa volumétrie est aujourd'hui de 680 000 heures<sup>11</sup>.

---

7. Id., *Les jeunes années de la radio en Suisse romande - SSR Suisse Romande* SSR Suisse Romande...

8. Dominique Prongué, *Le hasard des archives ou les archives du hasard, Les archives sonores de la Radio Suisse Romande. Comment une radio de service public a constitué ses archives*, rapp. tech., Lausanne, Suisse, Radio Suisse Romande (RSR), 2009, p. 129, URL : [https://web.archive.org/web/20160303182936/http://de.memoria.ch/dokument/news/events/le\\_hasard\\_des\\_archives\\_prongue\\_rsr\\_2009.pdf](https://web.archive.org/web/20160303182936/http://de.memoria.ch/dokument/news/events/le_hasard_des_archives_prongue_rsr_2009.pdf), p. 26.

9. *Ibid.*, p. 27.

10. Laure Meuret, *Entretien avec Laure Meuret, chargée d'archivage de l'information pour le secteur radio (RTS)*, mai 2024.

11. J. Sonderegger, *Entretien avec Janique Sonderegger, premier lien du cercle Data Management, service données et archives (RTS)...*

### c. La numérisation du fonds radiophonique

*On se référera à l'annexe A pour une chronologie détaillée des supports conservés par la RTS*

Comme le fonds télévisuel, celui de la radio a été numérisé au tournant des années 2000, d'abord les 78 tours, car leur dégradation faisait craindre des pertes irrémédiables, à partir de 1995 (copiés sur CDR puis numérisés) ; puis les bandes magnétiques dans le cadre du projet NumA (numérisation accélérée) en 2006, qui visait à numériser 25 % du fonds en 3 ans<sup>12</sup>. Deux autres projets ont vu le jour sous l'impulsion d'institutions souhaitant conserver « leurs » archives : l'Orchestre de la Suisse romande, le Canton de Fribourg (projet Patrimoine sonore fribourgeois) et le canton du Jura (projet Jura)<sup>13</sup>.

À l'heure actuelle, l'immense majorité du fonds a été numérisé grâce à des partenariats avec l'association MemoriAV (association fondée en 1995 pour la préservation du patrimoine audiovisuel suisse)<sup>14</sup> et de la fondation Fonsart (fondée en 2005 par la RTS)<sup>15</sup> ; en revanche l'intégration des métadonnées dans les outils documentaires reste lacunaire, ce qui fait que les anciennes cartothèques sont parfois encore utiles pour certaines parties du fonds et périodes et qu'une bonne connaissance du fonds est indispensable pour s'y retrouver.

### d. Métadonnées du fonds radiophonique

L'une des difficultés concernant le fonds radiophonique est l'extrême hétérogénéité de ses métadonnées. Ces dernières sont le reflet des multiples campagnes de numérisation, des histoires « séparées » de Radio Genève et Radio Lausanne jusqu'en 1998 et enfin, des changements d'outils et de pratiques documentaires. On tâchera d'en faire une description chronologique et d'expliquer les diverses migrations à chaque fois qu'elles sont intervenues afin de documenter au mieux les incohérences et lacunes actuelles.

Commençons par les cartothèques, qui étaient à l'origine au nombre de deux, une pour chacune des radios. Les deux étaient séparées entre les disques commerciaux (musique) et les enregistrements d'émissions sur bandes magnétiques (parlé)<sup>16</sup>. Poursuivons

---

12. D. Prongué, *Le hasard des archives ou les archives du hasard, Les archives sonores de la Radio Suisse Romande. Comment une radio de service public a constitué ses archives...*, p. 20.

13. Eadem.

14. *Histoire*, URL : <https://memoriav.ch/fr/memoriav/histoire/> (visité le 19/08/2024).

15. Alain Freudiger, *Entretien avec Alain Freudiger, chargé des archives anciennes (RTS)*, mai 2024.

16. D. Prongué, *Le hasard des archives ou les archives du hasard, Les archives sonores de la Radio*

avec les bases de données Ge-Arch et La-Arch, ce sont les inventaires des fonds 78 tours des deux radios romandes réalisés au moment des numérisations évoquées<sup>17</sup>.

Elles ont été numérisées au cours des années et réparties entre différentes bases de données hébergées localement, il faudra attendre 2003 et la mise en place de SIRANAU (Système Intégré Radiophonique d’Archivage Numérique Audio) pour que les métadonnées soient rassemblées au sein du même outil, qui permet en outre de jouer directement les archives numérisées. Ce logiciel contient donc l’ensemble des métadonnées et données du fonds radiophonique (qui ont été ajoutées au fur et à mesure des numérisations)<sup>18</sup>. Ce n’est pas sans poser un problème de cohérence puisque le niveau hiérarchique le plus haut dans SIRANAU est l’émission, qu’il est parfois très difficile de relier à la matérialité des supports : notamment des 78 tours à gravure directe qui étaient utilisés par paire. On enregistrait sur l’un, quand une face se terminait, on passait à l’autre, puis on tournait le premier : et ainsi de suite. Ce qui a pour conséquence d’avoir des programmes « éclatés » sur plusieurs supports et avec parfois une face contenant un morceau d’un programme et, sur l’autre, un programme tout à fait différent.

Avec la fusion en 2011 de la RSR (Radio suisse romande) et de la TSR (Télévision Suisse romande), un projet de fusion entre les outils documentaires de la Télévision (Gico) et de la Radio (SIRANAU) a été lancé, il devrait voir le jour prochainement.

### **3. Le fonds télévisuel et ses métadonnées**

#### **a. Histoire du fonds et de ses lacunes**

*On se référera à l’annexe A pour une chronologie détaillée des supports conservés par la RTS*

Le fonds télévisuel de la RTS commence avec les débuts de la diffusion en 1954. Aujourd’hui, il totalise environ 220 000 heures d’enregistrements, soit directement numériques (depuis le passage au support LTO en 2008), soit issus de la numérisation des fonds réalisée entre 2004 et 2014. Ce fonds, loin d’être monolithique, reflète l’histoire technique, institutionnelle et humaine de la RTS. Une analyse détaillée est essentielle pour comprendre son évolution et ses lacunes, tant au niveau du contenu qu’au niveau des métadonnées.

---

*Suisse Romande. Comment une radio de service public a constitué ses archives..., pp. 34-37.*

17. *Ibid.*, p. 33.

18. *Ibid.*, p. 37.

Plusieurs facteurs peuvent expliquer la non-conservation de certaines émissions :

### **Techniques :**

Les couts de stockage étaient très élevés avant la généralisation des cassettes Betacam en 1987, ce qui entraînait le réenregistrement sur des bandes avec effacement des anciennes émissions. L'archivage était en conséquence, cher et réduit à l'essentiel. Enfin, l'évolution rapide des supports de stockage (14 supports différents depuis la création de la RTS) rendait difficile la lecture des supports anciens.<sup>19</sup>

### **Organisationnels :**

Le service Données et archives (d'abord Téléthèque puis Documentation et archives) était initialement un service de documentation, comme en témoigne la première « Directive concernant l'archivage des émissions à la RTSR » du 1er avril 1981. Celle-ci établissait des critères de sélection basés sur cinq fonctions : vente/échange d'émissions, réutilisation, recours au contenu informatif, mise à disposition de copies à des tiers, et conservation pendant les quatre mois légaux (voir plus haut) ; des critères documentaires et non patrimoniaux. La conservation de certaines émissions a ainsi été jugée peu utile, notamment les émissions pour enfants, le sport, et les émissions de divertissement (jeux). Aussi, pour certains documents, on ne conserve que le « clean feed » (sans le son et sans incrustations à l'écran), car l'objectif de la conservation était la réutilisation des images. Par ailleurs, avant 1959, la RTS ne disposait pas d'appareil de captation des émissions en direct (kinoscope), et dépendait donc de la SRF à Zurich pour l'enregistrement. Certaines archives sont en conséquence conservées à la SRF, comme le Téléjournal diffusé depuis Zurich jusqu'en 1981 avec un commentaire romand. Enfin, le flux télévisuel n'a jamais été conservé, seulement les émissions, ce qui rend rare la conservation de séquences comme les publicités ou les passages d'antenne par des speakerines.<sup>20</sup>

### **Humains :**

Les facteurs sont ici multiples : oubli d'enclenchement des magnétoscopes pour l'enregistrement des émissions ; documents prêtés et non rendus, ou mal conservés (proche des fenêtres !). Notons que l'informatisation des années 1980 a permis une meilleure préservation des archives, les commandes et la gestion des cassettes étant dès lors supervisées par des documentalistes qui assuraient leur retour et leur préservation systématique. La notion de « patrimoine audiovisuel » n'est apparue que dans les années 2000, activée no-

---

19. D. BARCELLA, *Entretien avec Denise Barcella, experte patrimoine des archives de la RTS et ancienne enseignante de l'université de Lausanne en histoire de la télévision....*

20. *Ibid.*

tamment par l'anniversaire de la télévision en 2004, moment coïncidant avec l'initiative de numérisation massive du fonds.<sup>21</sup>

## b. La numérisation du fonds télévisuel

Entre 2004 et 2014, 90 % des 120 000 cassettes, représentant la majorité des supports physiques conservés, ont été numérisées. Cette initiative peut s'expliquer par plusieurs aspects. Tout d'abord, la digitalisation de la société a entraîné une demande forte de la part des citoyens d'accès à leurs archives. Une petite partie du fonds avait déjà été numérisée et mise en ligne, et son succès avait été fulgurant<sup>22</sup>.

Ensuite, le vieillissement des supports a été un facteur crucial : les films ont été touchés par le syndrome du vinaigre, qui a fini par se propager et contaminer les cassettes stockées dans le même dépôt. De plus, les appareils de lecture devenaient rapidement obsolètes. Les besoins documentaires étaient également importants ; il arrivait souvent que plusieurs émissions nécessitent le même document en même temps, notamment lors de commémorations. La digitalisation permettait alors de multiplier les canaux de diffusion.<sup>23</sup>

La conscience accrue de cette problématique et de l'importance du patrimoine audiovisuel était partagée par Gilles Marchand, directeur de la RTS à l'époque. De plus, l'engagement de Didier Bufflier, expert en restauration, a mis en lumière les problèmes de conservation importants. Enfin, les évolutions technologiques, notamment avec l'arrivée des LTO, ont rendu possible le stockage à moindres coûts des documents numérisés.<sup>24</sup>

Avec la fin du projet de numérisation en 2014, la direction a souhaité jeter les supports devenus inutiles. Cependant, l'association MemoriAV a alarmé la RTS, soulignant qu'en l'absence de contrôle qualité, jeter les supports serait une erreur. Ainsi, un contrôle qualité a été lancé, assisté par l'intelligence artificielle qui détecte les potentielles erreurs, ensuite vérifiées manuellement par des civilistes (le service civil est l'alternative offerte aux hommes suisse ne désirant pas faire leur service militaire).<sup>25</sup>

Toutefois, tout n'a pas été numérisé à cette époque. Il reste entre 5 et 10 % des supports à numériser, principalement le sport, car la RTS n'est que rarement propriétaire

---

21. *Ibid.*

22. M. Rezzonico, *Entretien avec Marielle Rezzonico, chargée de valorisation des archives...*

23. D. BARCELLA, *Entretien avec Denise Barcella, experte patrimoine des archives de la RTS et ancienne enseignante de l'université de Lausanne en histoire de la télévision....*

24. *Ibid.*

25. *Ibid.*

des images diffusées, comme c'est le cas pour le Tour de France, et ce patrimoine est mal considéré. Par ailleurs, les supports difficiles à numériser sont restés de côté, étant les plus problématiques et mal conservés. Certaines cassettes Betacam ont été contaminées par le vinaigre (qui touchait le fonds des films 16 mm) et d'autres Betacam ont vu leur liant magnétique mal vieillir (*sticky shed syndrome*). Enfin, certaines cassettes étaient en prêt ou perdues lors de l'opération, bien que beaucoup aient été retrouvées lors des déménagements des locaux de la RTS à Genève pour cause de travaux.<sup>26</sup>

### c. Métadonnées du fonds télévisuel

Depuis la création du fonds, celui-ci était constitué de fiches catalographiques. L'informatisation a débuté dans les années 1980 avec le passage au logiciel « Gesima » (pour Gestion des images), dont le nom illustre bien l'objectif : retrouver aisément des archives afin de pouvoir les réutiliser pour illustrer un nouveau sujet. Ce logiciel fonctionnait selon le principe de la « méthode point-trait » héritée des fiches catalographiques qui consiste à séparer les différents champs par des signes de ponctuation particuliers, le programme se charge ensuite de ventiler dans les différents champs les informations saisies.<sup>27</sup> En 2014, la RTS a adopté le logiciel GICO (Gestion des Images et des Contenus), remplaçant ainsi le système précédent, Gesima. Le passage à GICO a nécessité un processus de mapping – c'est-à-dire de conversion et d'association des données d'un format à un autre – qui a utilisé la ponctuation existante pour structurer les informations dans les nouveaux champs de données.

En 2014, la RTS a adopté le logiciel GICO (Gestion des Images et des Contenus), remplaçant ainsi le système précédent, Gesima. Le passage à GICO a nécessité un processus de *mapping* – c'est-à-dire de conversion et d'association des données d'un format à un autre – qui a utilisé la ponctuation existante pour structurer les informations dans les nouveaux champs de données.

Contrairement à Gesima, qui utilisait une structure ”à plat”, GICO organise les données selon une hiérarchie claire :

1. **Collection** : par exemple, « Temps présent » ;
2. **Programme** : par exemple, « émission du 18 mars 2015 » ;
3. **Sujet** : par exemple, « récolte du vin dans le Lavaux » ;
4. **Séquence** : par exemple, « belles images Lavaux, train passant ».

---

26. *Ibid.*

27. *Ibid.*

Les séquences, créées subjectivement par les documentalistes ou générées automatiquement par les intelligences artificielles lors de la détection de visages ou de voix, représentent un niveau purement documentaire destiné à faciliter la réutilisation des contenus.

## Gesima et Gico, deux logiques bien différentes

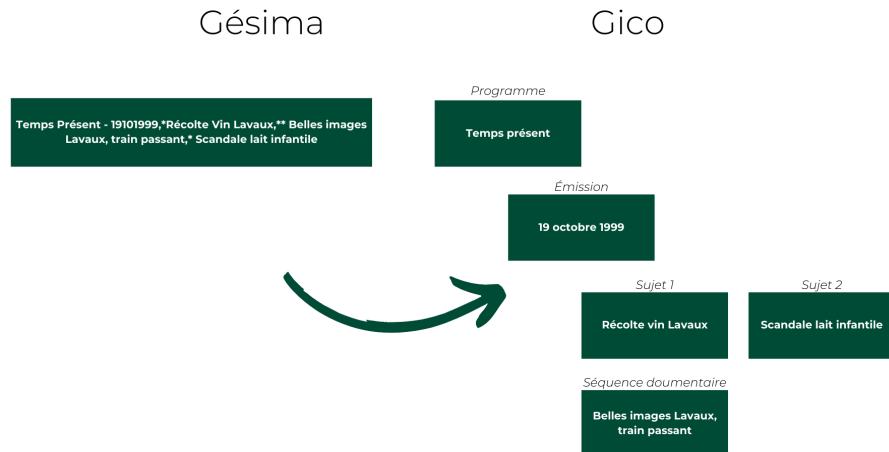


FIGURE 1 – La logique « à plat » de Gesima et la logique hiérarchique de GICO (illustration réalisée par nos soins)

Durant le *mapping*, les différentes séquences au sein d'une même émission, préalablement séparées par des astérisques sous Gesima, ont été converties en nouveaux niveaux de séquence dans GICO. Cependant, cette méthode présente des limites, notamment parce que Gesima transformait certains champs en majuscules automatiquement et limitait le nombre de caractères, rendant certaines entrées difficiles à comprendre.

De plus, un problème spécifique lié à ce changement de système est que les notices importées de Gesima vers GICO contiennent souvent des doublons dans leurs résumés. Cela résulte de l'ancienne méthode de catalogage appelée "point tiret", où chaque séquence était séparée par un astérisque. Il est aussi important de noter que les dates étaient saisies de manière très variée, ajoutant un niveau supplémentaire de complexité à la gestion des données dans le nouveau système.<sup>28</sup>

28. J. Sonderegger, *Entretien avec Janique Sonderegger, premier lien du cercle Data Management, service données et archives (RTS)...*

Umid et durée	HD	Ratio	QC	Gesima	Livré le	Type	Synthèse	Version	Parties	Support	Format	Couleur
ZB044574/04 00:00:42	Non	4/3		ZBC01		Clean Feed	ITR	3	1/1	Numérique	IMX (SD)	Oui
99LM6831/04 00:00:42	Non	4/3		LMM02	05.08.1999	Clean Feed	ITR	2	1/1	Physique	Cassette Betacam SP	Oui
99LM6830/04 00:00:42	Non	4/3		LMM01	05.08.1999	Clean Feed	ITR	1	1/1	Physique	Cassette Betacam SP	Oui

FIGURE 2 – Exemple de fiche importée depuis l’outil GESIMA, on observe bien l’ancienne structuration des dates, des champs en majuscules et les problématiques que cela peut créer (information en double voire en triple)

Le basculement vers GICO a non seulement amélioré l’efficacité du moissonnage de métadonnées depuis divers canaux, mais a également transformé la manière dont les archives sont gérées et exploitées. D’abord, l’intégration des *time codes*<sup>29</sup> a permis un accès rapide et précis aux séquences spécifiques, optimisant ainsi le processus de réutilisation des contenus. En 2019, l’arrivée des données de production depuis l’outil Open Média et depuis Watson, la base de données de la programmation, malgré quelques problèmes d’encodage, a enrichi les métadonnées disponibles, facilitant une meilleure contextualisation et recherche des archives.

En 2022, l’introduction d’outils d’intelligence artificielle de reconnaissance des locu-

29. Un time code est un repère temporel placé sur un fichier, par exemple placé sur une séquence. Cela donne la possibilité d’y accéder de façon rapide. Par exemple si j’ai un time code à 5 minutes 33 lié à la séquence « belles images Lavaux, train passant », un simple clic me permettra d’y accéder

teurs par leurs voix et de reconnaissance faciale a permis d’automatiser considérablement la description des archives, réduisant ainsi le temps consacré par les documentalistes à ces tâches. Cependant, bien que ces avancées technologiques aient augmenté la rapidité du traitement documentaire, elles ont également introduit un volume significatif de bruit documentaire, nécessitant une vigilance accrue dans le filtrage et la vérification des données générées automatiquement.

Ces innovations ont donc eu un double effet : simplification certaines opérations de documentation tout en complexifiant la surveillance de la qualité des métadonnées. Ces évolutions soulignent l’importance d’une stratégie de gestion des données bien équilibrée, capable de tirer parti des technologies avancées tout en maintenant l’intégrité et la précision des archives.<sup>30</sup>

---

30. *Ibid.*



# Chapitre 3

## Être repéré dans un vaste ensemble : la repérabilité

### 1. Naviguer dans l'océan du web : l'importance du référencement

« Le meilleur moyen de cacher un cadavre, c'est de le mettre en page 2 des résultats sur Google »<sup>1</sup>, cette phrase, quoique assez provocante, illustre assez bien l'importance pour un contenu d'être placé en tête des résultats de recherche. Pour ce faire, les professionnels de ce qu'on appelle le référencement utilisent deux stratégies : le SEO (Search Engine Optimization), l'optimisation de la page pour qu'elle soit mieux affichée dans les résultats de recherche, et le SMO (Social Media Optimization), l'optimisation du contenu sur les réseaux sociaux pour qu'il génère plus de clics et soit plus vu (on parle de facteurs sociaux). C'est là le premier enjeu autour de la repérabilité : pour qu'un contenu patrimonial ou un site soit repéré, il faut avant tout qu'il soit bien placé dans les résultats de recherche. Nous diviserons notre propos sur ce sujet en deux temps : d'abord « parler aux machines », où nous évoquerons les enjeux techniques spécifiques aux contenus patrimoniaux pour leur référencement ; puis « parler aux humains », où nous évoquerons les enjeux de communication et de valorisation.

---

1. Il est très difficile de trouver un auteur à cette citation, très présente sur le web chez les professionnels du référencement. Elle a été lue sur <https://www.linkedin.com/pulse/le-meilleur-endroit-pour-cacher-un-cadavre-est-%C3%A0-la-page-loubier-/> sans pouvoir l'attribuer avec certitude à l'auteur de l'article.

## Parler aux machines

« Rendre une information découvertable, dans un monde numérique, c'est la rendre accessible sous forme de données, la lier à d'autres informations pour que nos traces numériques se déplient, à l'image des réseaux de neurones dans le corps humain »<sup>2</sup>.

Cette citation éclaire sur l'importance de ce que nous appelons un dialogue avec les machines, qui est le premier levier vers la découverbarilité (en plus de celui de la disponibilité des ressources en ligne déjà mentionné). Si une ressource n'est pas visible sur les moteurs de recherche, elle aura des chances moindres d'être découverte. Il nous faut donc évoquer les enjeux techniques du référencement, et pour cela, nous devons d'abord comprendre le fonctionnement des moteurs de recherche. Nous nous focaliserons ici sur Google, car il concentre environ 90 % de part de marché<sup>3</sup> et que son fonctionnement illustre celui de tous les autres moteurs de recherche.

Ce qui a fait la popularité de Google dès sa création en 1998, c'est son algorithme (*PageRank*) qui a très sensiblement amélioré les résultats des recherches sur le web d'alors, où l'habitude était plutôt d'utiliser des annuaires tels que Yahoo, car les résultats des moteurs de recherche d'alors n'étaient que peu pertinents et très facilement falsifiables. Les créateurs de sites créaient par exemple, sous leur page web, une page blanche avec des milliers d'occurrences du terme auquel ils souhaitaient être associés pour être placés en tête des résultats<sup>4</sup>.



FIGURE 3 – L'interface de Yahoo qui était au départ un annuaire

2. Josée Plamondon, *Bien documenter pour favoriser la découverte en ligne : travailler avec les métadonnées*, rapp. tech., Canada, Fondation Jean-Pierre Perreault, 2019, <https://numerique.banq.qc.ca/patrimoine/details/52327/4020619>, pp. 13-14, cité dans *Rapport - Mission franco-qubécoise sur la découverbarilité en ligne des contenus culturels francophones*, Ministères de la Culture de la France et du Québec, France, Québec, Ministère de la Culture, 2020, p. 60, <https://www.culture.gouv.fr/Media/medias-creation-rapide-ne-pas-supprimer/Rapport-Mission-franco-quebecoise-sur-la-decouvrabilite-en-ligne-des-contenus-culturels-francophones.pdf>.

3. *Search Engine Market Share France / Statcounter Global Stats*, URL : <https://gs.statcounter.com/search-engine-market-share/all/france> (visité le 19/08/2024).

4. Dominique Cardon, « Dans l'esprit du PageRank. Une enquête sur l'algorithme de Google », *Réseaux*, 177-1 (2013), p. 63-95, DOI : 10.3917/res.177.0063, § 4.

L'efficacité de *PageRank* est possible grâce à son utilisation d'une science inventée par Eugène Garfield : la scientométrie, au départ pour faciliter le travail des chercheurs et révéler les associations entre articles scientifiques, et les classer par nombre de citations reçues<sup>5</sup>. Traduit dans le domaine du web, plus une page a de liens pointant vers elle (on utilise souvent le terme de *backlinks*), plus elle sera considérée comme centrale sur un sujet et donc pertinente. Ce principe fondamental de l'algorithme de Google a depuis été complété par un nombre impressionnant et toujours mouvant de critères, estimés à plusieurs centaines : mots-clés présents sur la page, confiance accordée au site, facteurs sociaux, temps de chargement<sup>6</sup>... Google ne communique jamais sur ces critères afin d'éviter des pratiques d'optimisation abusives, leur conseil est toujours le même : « faites le nécessaire pour satisfaire au mieux les internautes qui visitent votre site web et ne vous préoccupiez pas inutilement des algorithmes ou des paramètres utilisés par Google pour le classement »<sup>7</sup>. En plus de produire du contenu de qualité et utile pour les internautes, Google recommande aussi des pratiques techniques et notamment l'utilisation de « données structurées ». Pour illustrer leur importance, nous allons prendre l'exemple du projet data.bnf.fr de la Bibliothèque nationale de France (BnF).

### a. Data.bnf.fr : sortir les données du web profond

Lancé en 2009, le projet data.bnf.fr a pour objectifs de favoriser la visibilité des données de la Bibliothèque nationale de France (BnF) sur le web ; de casser les silos que constituent les multiples catalogues de l'institution en les regroupant en un point d'entrée unique ; de « faciliter la réutilisation des métadonnées par des tiers » ; de « contribuer à la coopération et l'échange de métadonnées par la création de liens entre des ressources structurées et de confiance »<sup>8</sup>. En bref, de « rendre les données de la Bibliothèque nationale de France plus utiles sur le web ». Pour ce faire, data.bnf.fr utilise le modèle IFLA-LRM (ex. FRBR) qui est structuré synthétiquement comme suit : l'œuvre d'un auteur est manifestée dans une édition, elle-même matérialisée dans un item. Par exemple, « Notre-Dame de Paris » de Victor Hugo est manifesté dans une traduction anglaise qui est éditée chez *Penguin Classics* et matérialisée dans un livre<sup>9</sup>.

---

5. *Ibid.*, § 5.

6. O. Ertzscheid, *Économie des biens culturels, cours de 2e année de DUT information et communication option métiers du livre et du patrimoine...*

7. *Présentation du fonctionnement du balisage de données structurées / Google Search Central / Documentation / Google for Developers*, URL : <https://developers.google.com/search/docs/appearance/structured-data/intro-structured-data?hl=fr#search-appearance> (visité le 19/08/2024).

8. *À propos de data.bnf.fr*, s.d. URL : <https://data.bnf.fr/fr/about> (visité le 16/07/2024).

9. E. Bermès, *Modélisation et requêtage, cours de 2e année de Master technologies numériques appliquées à l'histoire*, 2023.

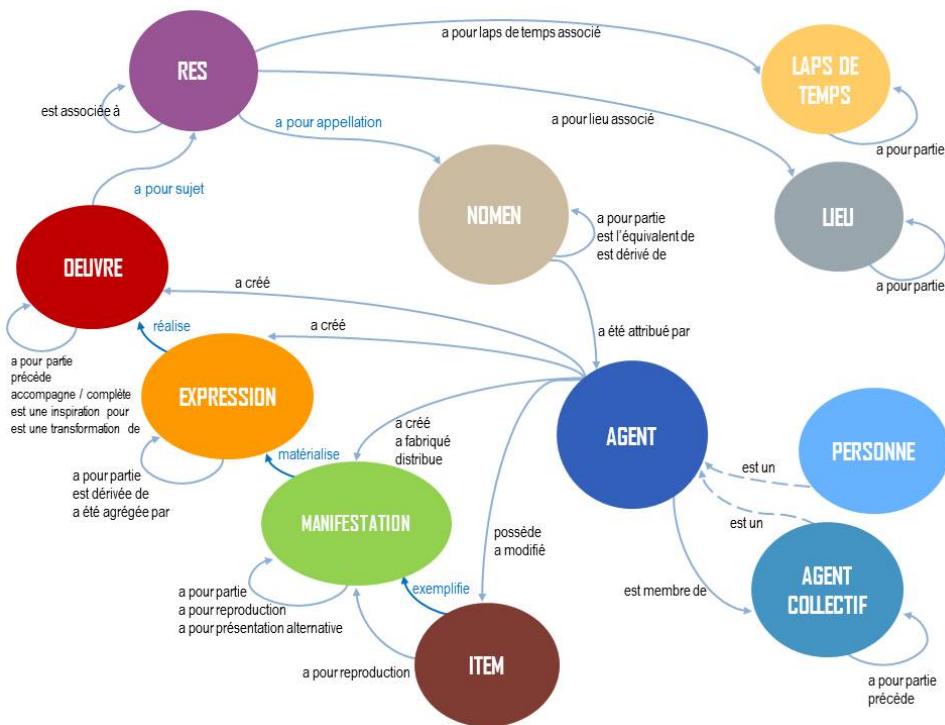


FIGURE 4 – Illustration schématique du modèle FRBR/LRM

Depuis : <https://data.bnf.fr/fr/semanticweb>

Le site (data.bnf.fr) va donc puiser dans les différentes sources de données de la BnF, qui sont dans différents formats de données : XML-EAD, Intermarc, etc. pour ensuite les structurer selon le modèle de graph-RDF (Resource Description Framework) qui est structuré en triplets : sujet, prédicat et objet. Cela donne en suivant notre exemple de tout à l'heure : Victor Hugo (sujet) a écrit (prédicat) « Notre-Dame de Paris » (objet). L'avantage d'utiliser RDF est que l'usage des triplets facilite l'interconnexion et le partage, le modèle est souvent utilisé avec des ontologies, qui sont des descriptions formelles des concepts et des relations dans un domaine particulier, afin de standardiser et structurer les données. Cela améliore l'interopérabilité entre différentes bases de données et systèmes, et optimise le référencement des données sur le web, car cela rend plus claire leur structure pour un moteur de recherche<sup>10</sup>. Cela permet aussi de tirer partie des fonctionnalités spéciales de recherche et notamment du *knowledge graph* de Google qui utilise ces triplets RDF pour créer des réseaux sémantiques d'entités et de relations, permettant à Google d'interconnecter les informations et de fournir des réponses précises et contextuelles aux utilisateurs lors de leurs recherches<sup>11</sup> (on parle de réponse zéro clic, voir figure 4 pour un exemple).

10. *Web sémantique et modèle de données*, URL : <https://data.bnf.fr/fr/semanticweb> (visité le 18/07/2024).

11. Google, *Introducing the Knowledge Graph*, 2012, URL : <https://www.youtube.com/watch?v=mmQ16VGvX-c> (visité le 29/08/2024).

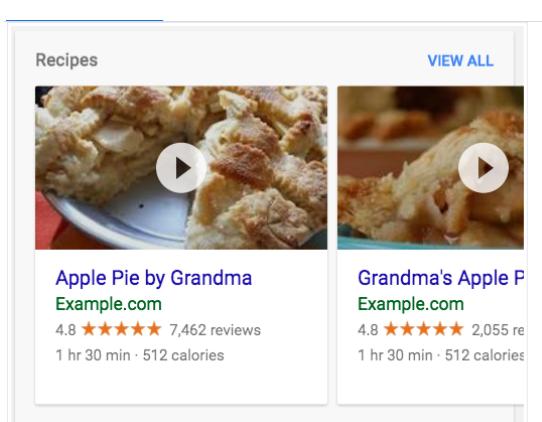


FIGURE 5 – Affichage pour l'utilisateur grâce aux données du *knowledge graph*

Depuis : <https://developers.google.com/search/docs/appearance/structured-data/intro-structured-data?hl=fr#search-appearance>

```

<html>
  <head>
    <title>Apple Pie by Grandma</title>
    <script type="application/ld+json">
    {
      "@context": "https://schema.org/",
      "@type": "Recipe",
      "name": "Apple Pie by Grandma",
      "author": "Elaine Smith",
      "image": "https://images.edges-general Mills.com/56459281-0fe6-4d9d-984f-385c9488d824.jpg",
      "description": "A classic apple pie.",
      "aggregateRating": {
        "@type": "AggregateRating",
        "ratingValue": "4.8",
        "reviewCount": "7402",
        "bestRating": "5",
        "worstRating": "1"
      },
      "prepTime": "PT30M",
      "totalTime": "PT1H30M",
      "recipeYield": "8",
      "nutrition": {
        "@type": "NutritionInformation",
        "calories": "612 calories"
      },
      "recipeIngredient": [
        "1 box refrigerated pie crusts, softened as directed on box",
        "6 cups thinly sliced, peeled apples (6 medium)"
      ]
    }
  </script>
</head>
<body>
</body>
</html>

```

FIGURE 6 – Les données en question, affichage pour les machines

Par ailleurs, pour encore favoriser le référencement, data.bnf.fr utilise l'ontologie schema.org, créée justement par Google, Microsoft (Bing) et Yahoo (entre autres)<sup>12</sup> afin d'améliorer l'indexation des données. Le site met aussi en oeuvre son équivalent pour les réseaux sociaux, OpenGraph Protocol). De plus, data.bnf.fr expose ses données au format JSON-LD, qui permet encore d'améliorer l'indexation.<sup>13</sup>.

En plus de favoriser l'indexation des ressources, data.bnf.fr utilise des identifiants uniques pour chaque ressource (URI), pérennes, qui permettent aux autres bases de données de pointer vers data.bnf.fr, et inversement. Par exemple, sur Wikidata, qui est structuré selon les mêmes principes que data.bnf.fr, la page Victor Hugo pointe vers la notice du Catalogue général de la Bibliothèque grâce à son identifiant et cette dernière pointe vers l'identifiant Wikidata de l'auteur. Outre le fait que cela génère des *backlinks*, cela permet aux moteurs de recherche de comprendre que le Victor Hugo de Wikidata est le même que celui de la Bibliothèque nationale et donc de lier entre elles les données.

On l'a vu, en « parlant aux machines », data.bnf.fr a permis à ses ressources de sortir du web profond. Projet précurseur, il a été suivi par le Service interministériel des archives de France qui a lancé en 2017 le portail France archives, lequel met en œuvre les mêmes principes en ajoutant la fédération des fonds sur tout le territoire (ce que fait le Catalogue collectif de France pour la Bibliothèque nationale de France). Force est de constater que les deux projets améliorent grandement le référencement. Si je tape

12. *About - Schema.org*, URL : <https://schema.org/docs/about.html> (visité le 19/08/2024).

13. *Présentation du fonctionnement du balisage de données structurées / Google Search Central / Documentation / Google for Developers...*

par exemple « capitale du Dauphiné », c'est un extrait de Gallica qui m'est proposé par Google ; si un utilisateur fait la recherche suivante : « archives Simone Veil », France Archives, le portail français des archives<sup>14</sup>, apparaît en deuxième position derrière une communication autour de l'exposition consacrée à Simone Veil par les archives nationales.



FIGURE 7 – « Capitale du Dauphiné », résultats de recherche Google effectuée le 27 juillet 2024

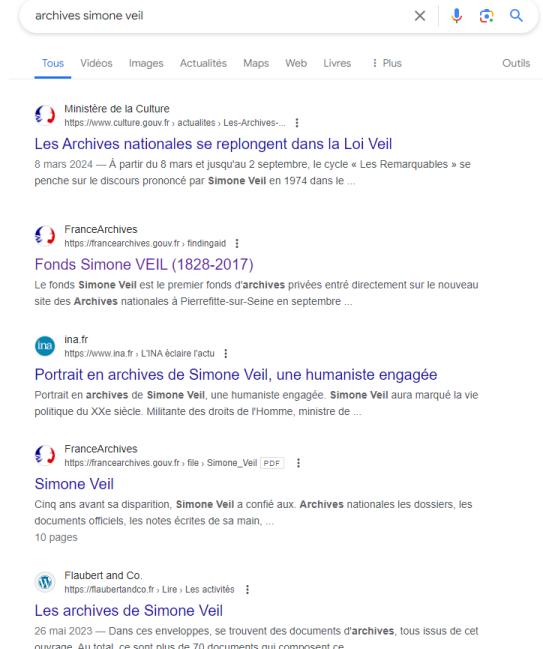


FIGURE 8 – « Archives Simone Veil », résultats de recherche Google effectuée le 18 juillet 2024

En observant les résultats, on note deux choses : d'abord, Google génère automatiquement des réponses aux questions des utilisateurs (on parle alors de réponse zéro clic), parfois en se basant sur les données de la BnF, car les données du Knowledge graph utilisées pour afficher ces questions utilisent les mêmes formats (JSON-LD)<sup>15</sup> que ceux mis en œuvre par data.bnf.fr, mais surtout, les deux reposent sur les principes du web sémantique. D'où une « prime » accordée à ces données dans le référencement (en plus de tout ce qui a déjà été dit). Notons aussi que le premier résultat pour notre recherche sur Simone Veil est un contenu éditorialisé « pour les humains », car tout ce que nous venons de décrire est surtout utile pour que la machine comprenne bien le contenu des pages, mais est rarement consulté réellement ; en revanche, le contenu éditorial l'est plus et ce sera l'objet de notre prochaine partie où nous détaillerons l'importance de la valorisation patrimoniale dans une stratégie de référencement en prenant l'exemple de la RTS.

14. Nous reviendrons en détails sur la question des portails dans notre partie 2

15. API Google Knowledge Graph Search / Knowledge Graph Search API, URL : <https://developers.google.com/knowledge-graph?hl=fr> (visité le 19/08/2024).

## 2. Parler aux humains : l'exemple des archives de la RTS

Si la stratégie technique de valorisation des contenus patrimoniaux est essentielle comme décrite plus haut, car elle permet aux machines de bien comprendre le contenu et les données, cette dernière n'aurait que bien peu d'intérêt si elle n'était pas accompagnée d'une stratégie de valorisation humaine : il est inutile de bien référencer une page dont le contenu est uniquement brut. Par ailleurs, les moteurs de recherches valorisent un contenu utile et de qualité et les réseaux sociaux sont bien souvent la porte d'entrée vers les sites web tout en améliorant leur référencement<sup>16</sup>. Dans cette partie, nous nous concentrerons sur la stratégie de valorisation des archives de la RTS, car elle nous semble rassembler les grands enjeux du domaine : un fonds au volume immense, des publics variés, et un environnement très concurrentiel.<sup>17</sup>

### a. La « Bibliothèque de l'Honnête Homme » comme stratégie de valorisation

Avec environ 1 million d'heures d'archives, dont les trois quarts sont audios, la RTS dispose d'une collection très riche. Cependant, ce n'est pas sans poser de problèmes, comme évoqués dans notre première partie : l'impossibilité d'appréhender dans leur totalité des objets culturels complexes générant une Fatigue muséale qu'il est difficile de contrer « much like death and taxes »<sup>18</sup>.

Même si elle en aurait la possibilité<sup>19</sup>, la RTS fait le choix de ne pas donner à voir toute sa collection : ni sur le site dédié, ni sur les réseaux sociaux qu'elle anime, consciente du fait que montrer la masse documentaire presque infinie noierait les documents dits intéressants. La stratégie est donc celle d'une éditorialisation et d'une contextualisation riche, le défi est donc, comme le notent F. Windhager et al. (trad.) « de rendre les collections compréhensibles malgré une vision limitée et à des capacités d'attention restreintes »<sup>20</sup>.

---

16. Laura, *5 impacts des réseaux sociaux sur le SEO en 2024 ?* - Redacteur Blog, avr. 2022, URL : <https://www.redacteur.com/blog/impact-reseaux-sociaux-seo/> (visité le 19/08/2024).

17. Josée Plamondon, Bien documenter pour favoriser la découverte en ligne : travailler avec les métadonnées, rapp. tech., Canada, Fondation Jean-Pierre Perreault, 2019, url : <https://numerique.banq.qc.ca/patrimoine/details/52327/4020619>, p. 14.cité dans : *Rapport - Mission franco-qubécoise sur la découvrabilité en ligne des contenus culturels francophones*, Ministères de la Culture de la France et du Québec, France, Québec, 2020, p. 60, <https://www.culture.gouv.fr/Media/medias-creation-rapide-ne-pas-supprimer/Rapport-Mission-franco-quebecoise-sur-la-decouvrabilite-en-ligne-des-contenus-culturels-francophones.pdf>

18. Bitgood, 2009, cité dans Windhager (Florian), Salisu (Saminu), Schreder (Günther) et Mayr (Eva), « Orchestrating Overviews : A Synoptic Approach to the Visualization of Cultural Collections », Open Library of Humanities, 4-2 (août 2018), doi:10.16995/olh.276.

19. Hors quelques archives dont les droits ne lui appartiennent pas.

20. F. Windhager, S. Salisu, G. Schreder, *et al.*, « Orchestrating Overviews... », p. 3.

Ainsi, le site<sup>21</sup> est organisé comme une « Bibliothèque de l’Honnête Homme »<sup>22</sup> : suivant quelques thématiques, avec à chaque fois un nombre relativement restreint d’archives toujours éditorialisées, parfois assez sommairement, parfois de façon détaillée suivant une écriture journalistique<sup>23</sup>, favorisant le référencement. Par ailleurs, les rebonds entre différents documents sont favorisés de deux manières : leur classement dans des dossiers thématiques et les recommandations, manuelles, faites par les documentalistes (nous reviendrons en détail sur la notion de recommandation).

### b. L’importance du SMO (social media optimisation)

En 2024, sur les 5,35 milliards d’utilisateurs que compte le web, 5,04 milliards disposent d’un compte sur un réseau social<sup>24</sup>. Il est évident qu’il est impossible de les ignorer dans une stratégie de repérabilité et de référencement. C’est doublement vrai, car, d’abord — comme évoqué plus haut — une présence efficace sur les réseaux sociaux améliore le référencement dans les moteurs de recherche, on parle de SMO (social media optimisation) ; ensuite, être visible sur ces derniers génère un nombre non négligeable de clics vers les contenus, car ils représentent un tiers du temps passé en ligne<sup>25</sup>.

Dans le cas des archives de la RTS, ce sont clairement les réseaux sociaux qui sont le principal canal de diffusion des archives et de réception. L’institution est présente sur Facebook (490 000 followers), Instagram (115 000 followers), YouTube (607 000 abonnés), suivant la fameuse phrase de Marshall McLuhan « The medium is the message »<sup>26</sup> : chaque plateforme a un contenu unique et adapté. Ainsi, Instagram est alimenté en contenus courts, YouTube est le canal des formats longs, et Facebook des formats de moyenne durée. Par ailleurs, les archives sont publiées au format horizontal (plus adapté pour une consultation sur ordinateur) sur toutes les plateformes sauf Instagram, qui cible clairement un public plus jeune, sur son smartphone.

---

21. <https://www.rts.ch/archives/>

22. Jean-Marc Chatelain, « La politesse des livres », dans *La Bibliothèque de l’honnête homme : Livres, lecture et collections en France à l’âge classique*, Paris, 2003 (Conférences et Études), p. 105-144, DOI : 10.4000/books.editionsbnf.2489.

23. <https://www.rts.ch/archives/grands-formats/9614551-on-a-tue-bob-kennedy.html>

24. *Internet et réseaux sociaux : nombre d’utilisateurs 2024* / Statista, URL : <https://fr.ista.com/statistiques/1350675/nombre-utilisateurs-internet-reseaux-sociaux-monde/> (visité le 19/08/2024).

25. *DIGITAL REPORT - LES DERNIERS CHIFFRES DU NUMÉRIQUE - OCTOBRE 2023* - We Are Social France, URL : <https://wearesocial.com/fr/blog/2023/10/digital-report-les-derniers-chiffres-du-numerique-octobre-2023/> (visité le 19/08/2024).

26. *Le médium c'est le message — Wikipédia*, URL : [https://fr.wikipedia.org/wiki/Le\\_m%C3%A9dium\\_c%27est\\_le\\_message](https://fr.wikipedia.org/wiki/Le_m%C3%A9dium_c%27est_le_message) (visité le 19/08/2024).

# Baignade interdite



▶

**Infrastructures et territoire** | **Vidéo 6 min.**

20 novembre 1968  
Affaires publiques

Quelques jeunes Genevois interrogés en ouverture de ce reportage en conviennent: tout le monde est responsable de la pollution des eaux. Le principe du tout-à-l'égout, qui prévalait jusque dans les années 1960, doit être extirpé de la conscience populaire.

Même si les stations d'épuration se mettent à fleurir sur les bords des lacs romands, l'effort doit être poursuivi et la bataille est loin d'être gagnée. Les réflexes de la population doivent aussi changer, pour alléger le travail de tri des stations d'épuration. Car les lacs sont en grand danger.

En une décennie, de 1960 à 1970, les stations d'épuration ont fleuri au bord des lacs et des rivières de Suisse. Seules quelques communes ont pris du retard en raison de querelles administratives. Mais le nouveau défi des STEPS est de faire face aux pollutions chimiques, en particulier par les phosphates, qui favorisent la prolifération des algues et privent ainsi d'oxygène les eaux profondes.

## Dans le dossier

### La bataille de l'eau



Pollution des eaux

**Sciences et Nature**

**Audio 24 min.**

24 janvier 1972  
Magazine Emission Info

Les industries et l'activité humaine menacent lacs et rivières.

## À consulter également



**Le long de nos cours d'eau**

**Sciences et Nature** | **Dossier**

8 documents vidéo à consulter

De sa source à son embouchure, avec sa faune, ses marais et sa flore, avec son rythme bien à elle aussi, la rivière est un lieu d'enchantement...

FIGURE 9 – « Baignade interdite », exemple de recommandation proposée par les documentalistes de la RTS



# Chapitre 4

## Émerger dans le lac d'une collection : la recommandation

### 1. Sérendipité : quand l'heureux hasard rencontre les algorithmes

« On ne trouve sans chercher que quand on a beaucoup cherché sans jamais trouver »<sup>1</sup>, cette citation illustre bien le concept de sérendipité qui se définit comme le « don de faire par hasard des découvertes fructueuses »<sup>2</sup>. Il est tiré de l'anglais *serendipity*, néologisme créé en 1754 par Horace Walpole à partir du conte oriental « les trois principes de Serendip », Serendip étant ici le nom ancien du Sri Lanka composé des deux mots sanscrits *Sri* « souveraineté, richesse, éclat » et *Lanka*, rapproché du grec *lagkanein* « obtenir par le sort »<sup>3</sup>. La sérendipité serait donc, étymologiquement, l'obtention de richesses grâce au sort, mais cette définition semble réductrice par rapport à l'usage qui a été fait de ce mot. Il est en effet utilisé pour désigner des découvertes fortuites certes, mais qui ne sont jamais le total fruit du hasard. Si Flemming a découvert, par sérendipité (il aurait oublié des cultures de moisissures à son départ en congé), la pénicilline : c'est qu'il la cherchait ; de même, Archimète s'écriant « Euréka » dans sa baignoire alors qu'il cherchait un moyen de prouver que la couronne d'Hiéron II était composée entièrement d'or<sup>4</sup>. Ces deux exemples illustrent le fait que la sérendipité est autant le fruit du hasard que de la « recherche sans jamais trouver » : c'est parce que Flemming et Archimète avaient dans

1. Francis Balle, *Sérendipité*, mars 2015, URL : <https://www.radiofrance.fr/franceculture/podcasts/1-alphabet-numerique/serendipite-4636636> (visité le 19/08/2024).

2. *Sérendipité / Académie française*, URL : <https://www.academie-francaise.fr/serendipite> (visité le 19/08/2024).

3. *Ibid.*

4. Géraldine Michel et Emmanuelle Le Nagard, « Favoriser la sérendipité pour des recherches plus créatives », *Décisions Marketing*, 93–1 (2019), p. 5-9, DOI : 10.7193/DM.093.05.09, Annexe 1.

leur saillance perspective<sup>5</sup> la recherche d'une solution à leur problème.

Si au même moment, et pour les mêmes raisons que le terme de découvrabilité, le terme de sérendipité réémergeait en 2011, selon Francis Balle, c'est bien que les deux termes sont liés : la découvrabilité comme la sérendipité ne sont pas inhérentes au web, les usagers des bibliothèques le savent bien, mais tout comme la découvrabilité, en mettant au jour d'incroyables perspectives de sérendipité (la masse non classée permet de voir des choses inattendues), le web et ses données massives semblent aussi poser le problème. D'une navigation riche en découvertes, on peut vite se « perdre dans l'hyperespace »<sup>6</sup> et de la sérendipité, on passe alors à la zemblanité : où toutes les découvertes ne viennent qu'enfoncer des portes ouvertes<sup>7</sup>. Il faut ici distinguer trois types de navigation sur internet : la première est celle où l'utilisateur souhaite trouver une information précise sur un sujet, il va alors saisir une équation dans un moteur de recherche, par exemple « sérendipité » ET « Web » (la sérendipité est alors quasi nulle)<sup>8</sup> ; la deuxième est une navigation à proprement parler en utilisant les liens hypertextes d'une page ou d'un article (sérendipité structurelle)<sup>9</sup> ; la troisième est basée sur la navigation, où l'utilisateur sait qu'il ne sait pas ce qu'il cherche (sérendipité associative)<sup>10</sup>. Ces liens hypertextes sont l'une des spécificités d'internet, inventés en 1960 par Ted Nelson, sur base des travaux menés dès 1945 de Vannevar Bush et son Memex (il écrit dans son article « *As we may think* » que le cerveau humain fonctionne par association d'idées et non de façon linéaire)<sup>11</sup>, ils viennent casser la linéarité de lecture traditionnelle d'un texte en ajoutant des liens sémantiques activables par le lecteur<sup>12</sup>. Cette rupture de linéarité est un élément fondamental de la sérendipité sur le web, selon Olivier Ertzscheid et Gabriel Gallezot grâce aux liens hypertextes « la mise en relation des unités informationnelles [...] peut permettre de découvrir des corrélations insoupçonnées »<sup>13</sup>. Insoupçonnées est ici un mot important, il ne s'agit jamais de hasard : ce dernier n'existe pas sur le web, les algorithmes, défini comme « suite finie et non ambiguë d'instructions et d'opérations permettant de résoudre une classe de problèmes »<sup>14</sup> rendent totalement impossible la création de hasard puisque chacune

---

5. Concept sémiologique qui s'illustre bien par l'exemple suivant : à l'achat d'un vélo, on devient tout de suite très sensible à toutes les potentialités pour l'accrocher (grilles, poubelles, plots dans la rue, etc.). in Marc Jahjah, introduction à la sémiologie, cours de 1ère année de DUT information et communication, 2018

6. Selon le livre éponyme de Quentin Quick et J. Schaherpenhuizen

7. *Ibid.*, § 10.

8. O. Ertzscheid et Gabriel Gallezot, « Chercher faux et trouver juste, » ( juill. 2003), p. 8.

9. *Ibid.*

10. *Ibid.*

11. Vannevar Bush, « *As we may think* », *Life Magazine* (, oct. 1945), p. 112-114, URL : [https://worrydream.com/refs/Bush\\_1945\\_-\\_As\\_We\\_May\\_Think\\_\(Life\\_Magazine\).pdf](https://worrydream.com/refs/Bush_1945_-_As_We_May_Think_(Life_Magazine).pdf) (visité le 21/08/2024).

12. 14.

13. Eva Sandri, *Record. La sérendipité sur Internet : égarement documenta... – Cygne noir – Érudit*, URL : <https://www.erudit.org/en/journals/cygnenoir/2013-n1-cygnenoir07153/1090992ar/abstract/> (visité le 19/08/2024).

14. « Algorithme », *Wikipédia* (, août 2024), URL : <https://fr.wikipedia.org/w/index.php?>

de leurs actions sont déterminées à l'avance, et même s'ils peuvent donner l'illusion de hasard (par la masse de données traitées notamment), ce dernier n'est jamais complet. Par ailleurs, il faut noter que les logiques marchandes du web, organisé en un « capitalisme linguistique »<sup>15</sup> et autour du concept d'Économie de l'attention semblent s'opposer à toute sérendipité.

Afin d'illustrer notre propos, prenons deux exemples, l'un tiré d'un site à but non lucratif : Wikipédia et l'autre tiré d'un site à logique marchande, Mix.com (ancien StumbleUpon). Le premier, qu'on ne présente plus, en plus de disposer d'une fonctionnalité « article aléatoire » est structuré de manière à favoriser la navigation entre les articles. Par exemple, en commençant notre lecture sur l'article « Sérendipité », nous avons eu connaissance d'un article écrit par Olivier Ertzscheid et Gabrielle Gallezot sur ce sujet en lien avec la recherche d'information. Connaissant préalablement bien les travaux d'Olivier Ertzscheid, nous avons décidé de consulter cet article qui s'est révélé déterminant. Wikipédia favorise donc la sérendipité par la présence nombreuse de liens hypertextes d'une part (sérendipité structurelle), mais aussi, de l'autre : par la présence des sources en bas de chaque article, souvent point de départ de fructueuses recherches.

Il nous faut en revanche présenter notre second exemple, le site Mix.com (ex-StumbleUpon). Ce dernier est basé sur un principe simple : proposer à ces utilisateurs des images/vidéos aléatoires selon leurs centres d'intérêt. Ainsi, à l'inscription sur le site, il est demandé à chaque utilisateur d'en choisir quelques-uns parmi des catégories pré-crées, le site lui propose ensuite une quasi-infinité d'images moissonnées depuis d'autres médias sociaux tels que Reddit ou X (ex-Twitter) qu'il peut, ou non « aimer » pour que l'algorithme lui propose plus d'images du même type. Le site lui propose, dans le même temps, des images liées à ce qu'il voit.

On a donc une sérendipité qui semble associative : l'utilisateur ne sait pas ce qu'il cherche, mais, à force de naviguer et d'affiner ses goûts, il finira par « tomber » sur quelque chose d'intéressant. Sauf qu'ici, le modèle économique, autrefois nommé *StumbleUpon paid discovery* propose à des annonceurs de payer pour voir leur contenu propulsé à des utilisateurs, cassant ainsi le principe de sérendipité au profit d'une logique marchande très puissante puisque l'utilisateur croira que la publicité lui est destinée personnellement et sera bien plus enclin à la consulter : c'est tout l'intérêt des algorithmes de recommandation<sup>16</sup>.

---

[title=Algorithme&oldid=217643543](#) (visité le 19/08/2024).

15. Ce concept sera traité dans la partie 3, il est issu de l'article de Frédéric Kaplan paru dans le Monde Diplomatique en 2011 : <https://www.monde-diplomatique.fr/2011/11/KAPLAN/46925>

16. *Get More Eyes on Your Content Using StumbleUpon*, déc. 2012, URL : <https://verticalresponse.com/blog/stumbleupon-gets-great-content-seen/> (visité le 19/08/2024).



FIGURE 10 – L'interface de Mix.com

Finalement, de même qu'une bibliothèque par son organisation physique suivant des classifications arbitraires (citons Dewey par exemple) créé en quelque sorte une « Sérendipité artificielle » où les lecteurs en déambulant peuvent faire de belles découvertes, mais uniquement s'ils s'ouvrent au hasard, la sérendipité comme décrite par Eva Sandri va « au-delà de l'heureux hasard, il s'agirait donc d'un état de disponibilité, de réflexivité et d'ouverture d'esprit qui ferait en sorte de considérer l'erreur comme constructive »<sup>17</sup>. Il semble qu'on puisse conclure de la même chose pour le web : si un utilisateur s'ouvre aux heureux hasards que peut lui proposer une navigation hypertextuelle, il pourra « tomber » sur des choses intéressantes. L'immense avantage du web est qu'il n'est justement pas organisé en grandes classifications arbitraires, la navigation est donc ici interdisciplinaire « car l'internet n'a pas de frontières »<sup>18</sup> ; son immense inconvénient est en revanche les risques pour l'utilisateur de se perdre totalement dans la masse des propositions de navigation qu'il reçoit sans cesse. Les algorithmes de recommandation peuvent alors être vus comme la solution à ce problème de la masse : en ciblant leurs utilisateurs de façon très précise et en leur proposant du contenu proche de celui qu'ils viennent de consulter, ce sont à la fois des outils de création de sérendipité, mais aussi des outils d'enfermement algorithmique régis parfois par des logiques marchandes. Ils seront l'objet de notre prochaine partie.

## 2. Les algorithmes de recommandation

Avant toute chose, il nous faut tâcher d'expliquer le fonctionnement technique des algorithmes de recommandation. Ces derniers ont pour objectif de rapprocher, selon des

17. Id., *Record. La sérendipité sur Internet : également documenta... – Cygne noir – Érudit...*, p. 14.

18. F. Balle, *Sérendipité...*, 8 minutes 34 secondes.

critères définis (genre, type d'utilisateur ayant regardé...), deux objets (films, musiques, textes...). Pour être le plus clair possible, prenons un cas d'usage : admettons que l'on souhaite rapprocher tous les programmes ayant la même thématique dans le fonds de la RTS ; nous avons pour cela à notre disposition trois choses : une transcription, un résumé et des mots-clés définis à partir d'un thésaurus. Par différentes opérations mathématiques, on va transformer ces trois éléments en deux chiffres entre 0 et 1<sup>19</sup>. Ensuite, on place ces deux chiffres dans un espace vectoriel, c'est-à-dire dans un espace mathématique (voir image ci-après), le tout pour chaque archive. Les points qui sont proches sont ceux partageant des caractéristiques communes, puisque le chiffre qui a été calculé à partir de leurs métadonnées spécifiques est proche. Si l'on souhaite voir les documents similaires, il suffit de prendre tous les points proches dans le graphique (ou les personnes en suivant leurs traces en ligne ou données démographiques)<sup>20</sup>.

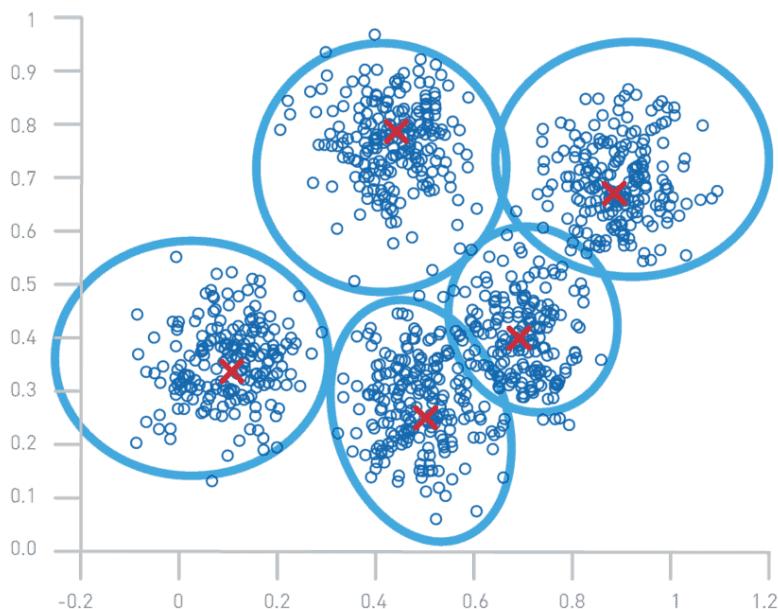


FIGURE 11 – Fonctionnement schématique d'un algorithme de clustering

<https://www.data-transitionnumerique.com/k-means/>

19. Dans notre cas, on utiliserait un algorithme de type TF-IDF qui calcule la fréquence (Term Frequency [TF]) d'un terme dans un document en calculant le nombre de fois où le mot apparaît divisé par le nombre de mots totaux et sa rareté dans tous les documents (Inverse document Frequency [IDF]) en calculant le logarithme du nombre total de documents divisé par le nombre de documents contenant le mot, on fait ensuite TF \* IDF. L'intérêt est d'identifier les mots signifiants importants pour un document en réduisant l'importance des mots vides (« le », « et »...) [Explications fournies par Chat-GPT et remaniées]

20. *Introduction to clustering / Machine Learning / Google for Developers*, URL : <https://developers.google.com/machine-learning/clustering> (visité le 19/08/2024).

Cette description est évidemment très simplifiée : comment délimiter les catégories entre elles ? Comment faire en sorte que mon algorithme classe tous les documents selon des thématiques définies et pas uniquement en prenant en compte, par exemple, leur champ lexical ? Le principe des algorithmes de recommandation est tout de même globalement celui décrit. Il a été expérimenté dès 1975 par Salton et al.(cité par Arnaud Claes)<sup>21</sup>. En 2002, Robin Burke proposait de les répartir selon cinq catégories<sup>22</sup> :

- **Recommandation collaborative** : les contenus sont proposés en fonction des préférences de l'utilisateur et des comportements d'autres utilisateurs similaires.
- **Recommandation basée sur le contenu** : Les suggestions sont faites en fonction des éléments similaires consultés par l'utilisateur dans le passé.
- **Recommandation démographique** : les recommandations sont établies sur la base de critères démographiques tels que l'âge, le sexe et la localisation.
- **Recommandation basée sur un modèle de connaissance** : ces algorithmes utilisent une base de connaissances, construite grâce aux réponses de l'utilisateur à des questions spécifiques, pour suggérer des objets en fonction des besoins exprimés.
- **Recommandation basée sur l'utilité** : les contenus sont proposés en fonction de leur utilité pour l'utilisateur. Par exemple, si un arbre de décision pour le choix d'un produit prend en compte le coût, l'impact carbone et les notes des autres utilisateurs, un produit répondant à ces trois critères sera recommandé.

Sans rentrer dans le détail, chacune de ces catégories a des avantages et inconvénients : par exemple faire des recommandations basées sur le contenu nécessite beaucoup de données d'entraînement et de capter les traces de l'utilisateur, les recommandations basées sur l'utilité sont statiques, etc. C'est pourquoi elles sont souvent combinées, c'est par exemple le cas de Netflix qui utilise huit algorithmes différents, chacun répondant à un cas d'usage spécifique<sup>23</sup>. Ce dont ces catégories témoignent, c'est aussi de deux visions : la première suppose que l'utilisateur peut explicitement donner ses préférences et la seconde, dite behavioriste, suppose qu'il faut observer ses actions pour lui proposer du contenu<sup>24</sup>. On observe clairement que la seconde vision décrite est celle qui est la plus représentée aujourd'hui, et ce, car les créateurs des algorithmes ont compris que « l'utilisateur n'est pas toujours la source la plus fiable pour éclairer ses propres intentions »<sup>25</sup>. Force est de

---

21. Arnaud Claes, *Arnaud Claes - Algorithme de service public et autonomie critique : Etude des effets de la contrôlabilité d'un algorithme de recommandation sur l'autonomie critique de ses usagers / UCLouvain*, thèse de doct., Belgique, Louvain-La-Neuve, 2022, URL : <https://uclouvain.be/fr/facultes/espo/evenements/arnaud-claes.html> (visité le 19/08/2024), p. 38.

22. *Ibid.*

23. *Ibid.*, p. 47.

24. *Ibid.*, p. 38.

25. *Ibid.*, p. 39.

constater l'incroyable puissance de ces algorithmes quand on parle de découvrabilité, ainsi, si l'on prend l'exemple de Spotify et ses 80 millions de titres au catalogue, on peut noter que les playlists générées par algorithme de recommandation « découvertes de la semaine » jouent bien leur rôle. Elles auraient, en effet, permis — quelques mois après leur lancement — à quarante millions de personnes de consulter 5 milliards de morceaux nouveaux<sup>26</sup>. Mais si le potentiel est immense, les enjeux le sont aussi, et notamment la transparence : comment savoir pour quelle raison tel contenu m'a été recommandé ? Surtout quand on voit à quel point les recommandations sont parfois grossières et fruits de clichés tenaces. Ainsi, en 2016, April Joyner, journaliste afro-américaine spécialisée dans les nouvelles technologies, se plaignait d'avoir vu, de façon soudaine, un tiers de ses recommandations sur son compte Netflix inclure des femmes afro-américaines dans les rôles-titres et l'apparition d'une catégorie « *African American Movies* » sur sa page d'accueil. Elle y voit un écueil majeur : l'invisibilisation, si l'utilisateur ne cherche pas à regarder un film de ce type et n'est pas catégorisé comme probablement de cette communauté (April Joyner vit à Harlem<sup>27</sup>), il n'en verra jamais<sup>28</sup>.

On a donc des algorithmes qui, clairement, offrent un potentiel énorme de découvervabilité, mais qui, s'ils sont utilisés à des fins commerciales, finissent par réduire le champ de la découverte. Pour que les institutions patrimoniales, et plus largement les acteurs publics, puissent s'emparer du potentiel de ces algorithmes tout en évitant les problèmes posés, on a depuis quelques années vu émerger la notion d'Algorithme de service public dont nous tâcherons d'observer les différences fondamentales avec ceux mis en œuvre par les acteurs privés.

#### a. La notion d'Algorithme de service public : « prenez les commandes », l'algorithme de recommandation de Radio France

Même si la société nationale de radiodiffusion française n'est pas un acteur patrimonial, l'ambition de son algorithme de recommandation est comparable à ceux évoqués par Irène Bastard et Arnaud Laborderie dans un article de juin 2023 réfléchissant à la mise en place d'un tel dispositif sur Gallica, la bibliothèque numérique de la Bibliothèque nationale de France<sup>29</sup>. C'est-à-dire : augmenter le taux de la collection qui est consultée

26. E. Durand, « Chapitre 5 - Le nouvel âge de la diversité », dans *L'attaque des clones*, Paris, 2016 (Nouveaux Débats), p. 73-88, URL : <https://www.cairn.info/1-attaque-des-clones--9782724619805-p-73.htm> (visité le 19/08/2024), § 2.

27. *About Me*, oct. 2017, URL : <https://www.apriljoyner.com/> (visité le 19/08/2024).

28. La question des bulles de filtre sera traitée dans la partie 3

29. Irène Bastard et Arnaud Laborderie, *La découvervabilité des collections numériques patrimoniales sous l'angle des usages de Gallica*, Text, juin 2023, URL : <https://bbf.enssib.fr/matières-a-penser/la-decouvrabilite-des-collections-numériques-patrimoniales-sous-l-angle-des->

par les individus (48 % sur Gallica)<sup>30</sup> ; améliorer les rebonds entre les items (seuls 1 à 3 documents consultés par session en moyenne sur Gallica)<sup>31</sup> dans des collections où il est difficile de se repérer tout en évitant les écueils des algorithmes de recommandation commerciaux : Bulle de filtre, effets de viralité (quelques contenus reçoivent tous les clics), manque de transparence, perte de contrôle<sup>32</sup>.

Ces ambitions et craintes, pensées avec les équipes éditoriales de Radio France, ont ensuite été transformées en cinq grands principes :

- Mettre l'humain au cœur de la démarche de recommandation ;
- Être totalement transparent ;
- Favoriser la découverte et la curiosité tout en restant efficace ;
- Laisser le contrôle à l'auditeur<sup>33</sup>.

La différence fondamentale avec les algorithmes de recommandation privés est ici l'humain : il est au cœur de la démarche de recommandation (équipe éditoriale et créatrice) ; il peut comprendre pourquoi tel contenu lui a été proposé et il peut refuser qu'on l'oriente algorithmiquement et orienter l'algorithme (en lui indiquant par exemple de favoriser une émission en particulier) : le tout, pour favoriser sa découverte, car aucun humain ne pourrait naviguer dans les deux millions d'heures du catalogue de Radio France pour recommander à chacun le programme qu'il est susceptible d'apprécier. La notion d'Algorithme de service public n'est donc pas tant technique ; certes les données d'usage (traces ou logs) collectées sont réduites ; certes aussi les algorithmes publics n'utilisent pas ou peu de données démographiques, mais ce qui est fondamentalement différent c'est qu'ils placent l'humain au cœur de leur démarche, il garde le contrôle sur ce qu'il voit, comprend pourquoi il le voit et peut décider de stopper à tout moment. Il reste donc le « pilote » de sa navigation<sup>34</sup>, ce qui constitue, si l'on suit l'analyse d'Olivier Ertzscheid, un retour en arrière : « Longtemps les technologies nous ont placées en situation de pilotage, avant de nous reléguer au rang de copilote, puis en nous laissant copilote, mais en supprimant le pilote au profit d'une seule fonction de pilotage automatique, et nous voilà désormais simplement, inexorablement, irrévocablement... passagers. Passagers par ailleurs exposés à la permanence d'un contrôle identitaire, et passagers sans autre bagage que l'acceptation naïve d'imaginer que nous pourrions encore être maîtres du choix de notre destination. »<sup>35</sup>

---

usages-de-gallica\_71295 (visité le 19/08/2024).

30. *Ibid.*

31. *Ibid.*

32. Bastien Luneteau et Valentin Lecomte, *Penser la découvrabilité des contenus culturels*, juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels> (visité le 19/08/2024).

33. *Ibid.*

34. O. Ertzscheid, *GPT-4 Omni : Chat Pantin(s)*. Mai 2024, URL : <https://affordance.framasoft.org/2024/05/gpt-4-omni-chat-pantins/> (visité le 19/08/2024).

35. *Ibid.*

Et c'est peut-être parce que Radio France est déjà un acteur majeur de la découvervabilité culturelle au travers de ses antennes, que la notion d'algorithme au service du public – où l'humain est au cœur de la démarche – y a été si bien comprise. Pensons par exemple à FIP (France Inter Paris), radio de l'éclectisme musical diffusant plus de 40 000 titres différents par an<sup>36</sup>, et dont le directeur écrivait en 2023 qu'il possédait le meilleur algorithme du monde : « Pourquoi ? Tout simplement, car il est humain. Chaque jour, nos programmateurs partent d'une page blanche et programment — manuellement — des tranches de vie musicale dans lesquelles toutes les musiques se doivent de se mélangier »<sup>37</sup>.

---

36. *La rentrée de Fip*, 2023, URL : [https://www.radiofrance.com/sites/default/files/2022-08/rentrée\\_2223\\_dp\\_fip\\_26082022.pdf](https://www.radiofrance.com/sites/default/files/2022-08/rentrée_2223_dp_fip_26082022.pdf) (visité le 19/08/2024).

37. *Ibid.*



## **Deuxième partie**

**Partie 2 : Nouveaux catalogues,  
nouvelles interfaces, nouveaux usages**



# Chapitre 5

## Les interfaces : nouvelles architectures ?

*2100, France, la Bibliothèque nationale vient d'achever la numérisation de l'entièreté de sa collection. Le site François-Mitterrand, reflet de « l'utopie numérique »<sup>1</sup> de son fondateur à savoir numériser et rendre accessibles tous les savoirs conservés et qui devait être l'objet d'une réfection globale ne sera finalement pas restauré, mais transformé en habitations, jugé inutile. Le conservatoire d'Amiens suffit à conserver l'entièreté du dépôt légal entrant, devenu entièrement dématérialisé. La consultation, seule vocation du site François-Mitterrand, ayant été déplacée en ligne, ce dernier n'a plus d'intérêt. La bibliothèque, en tant qu'emprise physique et Lieu de mémoire<sup>2</sup> n'est plus : remplacée par l'interface en ligne qui prend sa fonction symbolique, devenant dès lors une architecture de pouvoir au sens propre ; volonté de la prestigieuse institution d'être le reflet de son histoire, nouveau Lieu de mémoire, elle concentre toutes les attentions.*

Si évidemment cette uchronie est totalement fantasmée (cauchemardée ?) : il est inimaginable de voir les bibliothèques de consultation disparaître, elles qui mènent justement et avec brio des politiques centrées autour de l'accueil depuis des années. Il est tout aussi inimaginable de penser que le site François-Mitterrand pourrait devenir inutile face à une société totalement digitalisée : le relatif échec des livres numériques en est la preuve. Il est de toute manière impensable que la numérisation de la totalité des collections de la Bibliothèque nationale de France soit un jour une réalité, cela n'aurait pas d'intérêt

---

1. E. Bermès, "De l'écran à l'émotion, quand le numérique devient patrimoine"..., p. 20.  
2. En référence aux ouvrages parus sous la direction de Pierre Nora entre 1984 et 1992

et serait coûteux, autant en numérisation qu'en maintenance (et encore, par rapport aux archives nationales, la Bibliothèque nationale de France numérise beaucoup). Mais il nous semblait intéressant de pousser à l'extrême un mouvement qui est bien réel : les interfaces prennent peu à peu, mais sans jamais les remplacer totalement, le rôle des lieux de consultation et deviennent, de fait, des *Lieux de mémoire numériques* pour une immense partie des citoyens en tant que premier accès à la connaissance conservée. Elles se définissent comme la « jonction entre deux matériels ou logiciels leur permettant d'échanger des informations par l'adoption de règles communes physiques ou logiques »<sup>3</sup> c'est-à-dire qu'elles assurent la médiation de l'accès au savoir, dans le cas des institutions patrimoniales ; l'interface la plus courante est le catalogue. Cette question des interfaces prend donc une place centrale dans la découvervabilité des collections par leur rôle de médiation, et après avoir parcouru les enjeux autour de la notion de découvervabilité, il est intéressant de s'attarder sur ces dernières et d'analyser leur importance et leurs mutations récentes.

---

3. Centre national de ressources linguistiques et textuelles (CNRTL : Définition de INTERFACE, URL : <https://www.cnrtl.fr/lexicographie/interface> (visité le 19/08/2024).

# Chapitre 6

## « Vers de nouveaux catalogues »

*En référence au titre d'un ouvrage paru en 2016 sous la direction d'Emmanuelle Bermès.*

### 1. La transition bibliographique

Pour parler de nouveaux catalogues et tenter de montrer comment et par quels moyens ils améliorent la découvrabilité des collections patrimoniales, il nous semble important de commencer par le début en abordant les raisons ainsi que l'historique de ces mutations. Cela nous permettra de tenter de distinguer les pratiques réellement nouvelles et novatrices. Pour cela, nous commencerons par aborder la transition bibliographique que David Aymonin, directeur de l'Agence bibliographique de l'enseignement supérieur (Abes) présente ainsi : « On peut présenter la transition bibliographique simplement en expliquant que c'est une façon d'exprimer les métadonnées décrivant les documents sous forme d'entités et de relations. Cela fait presque 15 ans [en 2022, N.D.A] maintenant que les communautés de professionnels y travaillent, dans un monde de la documentation où tout est en transition. Nous avons le projet de partager les données de nos catalogues pour créer de nouveaux services [...] il s'agit de créer des données riches, liées et accessibles à tous et sur lesquelles chacun peut s'appuyer pour les enrichir et développer de nouveaux services, de nouvelles activités, de nouvelles industries »<sup>1</sup>. Ce programme a été mis en place conjointement par l'Abes et la Bibliothèque nationale de France et suit une logique mondiale impulsée par l'OCLC (la coopérative mondiale des bibliothèques).

Il s'appuie sur les *principes de Paris*, qui sont le cadre normatif du catalogage de-

---

1. Fabien Carré-Marillonnet et David Aymonin, « Transition bibliographique : 7 ans plus tard, où en sommes-nous ? », 357–7 (2022), Publisher : Serda Archimag, p. 36-37, DOI : 10.3917/arma.357.0036, §3 et §4.

puis 1961 avec en ligne de mire l’harmonisation des pratiques à l’échelle mondiale pour faciliter les échanges de notices et qui marquent la fin des catalogues sous forme de volumes papier et leur apparition sous forme de fiches catalographiques. Ces derniers ont été bouleversés en profondeur avec l’arrivée de l’informatique qui cassait la logique entre le contenu et sa forme matérielle (le livre en tant qu’unité intellectuelle étant confondu avec le codex, sa forme physique)<sup>2</sup> et posait le problème de la repérabilité des collections de bibliothèques décrites de façon peu adaptée aux logiques des moteurs de recherche<sup>3</sup>. Dans les années 1990, les limitations des Principes de Paris étaient donc importantes, c’est pourquoi l’IFLA (Fédération internationale des associations et institutions de bibliothèques) met en place un groupe de travail qui, plutôt que de remettre le livre en tant qu’unité intellectuelle au centre de sa réflexion, décide de poser la question de la modélisation de l’information bibliographique. En bref : qu’est-ce qu’un livre et qu’est-ce qu’une notice ? Le modèle FRBR (désormais renommé IFLA-LRM) est né. Comme nous l’avons déjà décrit dans notre partie 1, nous nous contenterons d’indiquer combien son approche est neuve pour les bibliothèques : désormais, c’est la notion d’entité qui est au centre du catalogue et l’importance est donnée à la structuration en réseau de ces dernières, suivant ainsi les principes du web en la matière (voir partie 1). Cela facilite aussi grandement les échanges entre les bibliothèques qui, en plus d’utiliser les mêmes formats (depuis les années 1970 et la mise en place du format MARC<sup>4</sup>, format de catalogage de nombreuses bibliothèques à travers le monde) peuvent désormais venir compléter leurs données avec celles des autres grâce aux standards du web tout en résolvant les problèmes posés par les principes de Paris. Notamment la difficulté à décrire une œuvre matérialisée dans différentes expressions<sup>5</sup>. Cela répond par ailleurs mieux aux demandes des utilisateurs qui privilégient l’information « brute » à une liste d’ouvrages quand ils font une recherche<sup>6</sup>. Toutes ces mutations, regroupées sous le nom de transition bibliographique, ont permis l’émergence de portails et des échanges de données plus importants (ainsi que la mise en place d’initiatives telles que data.bnf.fr décrit plus haut) qui seront l’objet de notre prochaine partie.

---

2. Françoise Leresche, « La Transition bibliographique », dans *Vers de nouveaux catalogues*, ISSN : 0184-0886, Paris, 2016 (Bibliothèques), p. 49-67, DOI : 10.3917/elec.berme.2016.01.0049, § 2.

3. *Ibid.*

4. Machine-Readable catalog

5. Pour rappel, selon le modèle LRM, une œuvre est l’objet intellectuel, par exemple « Notre-Dame de Paris » qui est matérialisée dans diverses expressions : livres ou audiolivre par exemple.

6. *Ibid.*, § 13.

## 2. Les portails et le moissonnage des données

Nous avons évoqué dans notre première partie que l'un des enjeux derrière le projet data.bnf.fr et le web sémantique de manière plus générale, outre le fait de sortir les données des bibliothèques du web profond, était de « casser les silos ». C'est-à-dire de passer au-delà de la matérialité documentaire. Car comme évoqué par Emmanuelle Bermès dans son article « Vers un catalogue orienté entités : la FRBRisation des catalogues »<sup>7</sup>, ce qui intéresse les utilisateurs, ce ne sont pas les livres, mais bien l'information qu'ils contiennent, la structuration des catalogues en tant que « listes de livres » n'étant que l'illustration de la contrainte physique qu'ils imposaient avant l'arrivée de l'informatisation en bibliothèque<sup>8</sup>. Ces derniers ne l'ont d'ailleurs pas totalement attendue pour tenter de dépasser cette limitation, notamment en proposant différents points d'entrée (auteurs, classification, etc.) vers leurs collections au moyen de fiches catalographiques<sup>9</sup>.

En passant du concept de documents à celui d'informations, les institutions patrimoniales, bibliothèques en tête, viennent casser les frontières : un utilisateur qui fera une recherche sur Exékias, peintre et potier athénien, se verra ainsi proposer en un seul et même point toutes les informations sur ce dernier : sa biographie sur Wikipédia, la liste de ses œuvres conservées au Louvre, la liste des ouvrages et articles qui lui ont été consacrés sur le catalogue général de la BnF... On sort ici du concept de catalogue « Énumération précise, méthodique, exhaustive des éléments d'une collection »<sup>10</sup> pour glisser vers celui de portail « site web qui offre une porte d'entrée commune à un large éventail de ressources et de services accessibles sur Internet »<sup>11</sup> où la notion centrale est celle de ressources.

De façon plus technique, au centre de la notion de portails est celle de moissonnage qu'il nous faut décrire ici. Pour ce faire, nous prendrons l'exemple du protocole OAI-PMH (pour Open access initiative, protocol metadata harvesting) qui reste très utilisé (notamment dans Gallica et Europeana) même s'il a tendance à être dépassé par d'autres. Créé à la fin des années 1990 par des institutions désireuses d'échanger leurs métadonnées descriptives, ce protocole « définit comment un site web peut exposer des métadonnées et permettre leur récupération par tout client<sup>12</sup> intéressé »<sup>13</sup>. Le moissonnage correspond à la

7. E. Bermès, « Vers de nouveaux catalogues ? Propos introductif », dans *Vers de nouveaux catalogues*, ISSN : 0184-0886, Paris, 2016 (Bibliothèques), p. 9-12, DOI : 10.3917/elec.berme.2016.01.0009.

8. *Ibid.*, § 2.

9. *Ibid.*, § 5.

10. CNRTL : *Définition de CATALOGUE*, URL : <https://cnrtl.fr/definition/academie9/catalogue> (visité le 19/08/2024).

11. « Portail web », *Wikipédia* (, juill. 2024), URL : [https://fr.wikipedia.org/w/index.php?title=Portail\\_web&oldid=217196741](https://fr.wikipedia.org/w/index.php?title=Portail_web&oldid=217196741) (visité le 19/08/2024).

12. Dans ce contexte, un client est un serveur souhaitant récupérer les données

13. Véronique Mesguich, « 5. De nouveaux chemins pour accéder aux ressources », dans *Bibliothèques : le Web est à vous*, ISSN : 0184-0886, Paris, 2017 (Bibliothèques), p. 105-143, URL : <https://cnrtl.fr/definition/academie9/catalogue>

récupération par le client. Pour que ce dernier soit effectif, il est essentiel que les données suivent un format normalisé. Par exemple, si je souhaite récupérer la liste des œuvres d'Exékias, si le Louvre structure ses données ainsi : <listOeuvres> Coupe à figure rouge n° 512, Amphore à figure noires n° 518 </listOeuvres> alors que le petit Palais les structure ainsi : <œuvres> Cratère à figure noires, œnochoé à figures rouges </œuvres>, même si les deux musées décrivent la même chose, l'éventuel portail (client) qui viendrait moissonner les sites de ces deux musées serait incapable de comprendre qu'il s'agit des mêmes données exprimées avec des noms différents. Ainsi, au cœur de la mise en place de portails se trouve la notion de données dites « FAIR », c'est-à-dire : facilement trouvables, accessibles, interopérables, réutilisables. Elle se situe plutôt du côté des choix institutionnels que des contraintes techniques. Pour que des données soient FAIR, il faut avant tout un choix politique fort de la part des institutions, qui sera ensuite traduit en choix techniques.

C'est ce qu'illustre très bien la mise en place du cadre d'interopérabilité IIIF (International image interoperability framework) au sein du portail France Archives déjà évoqué. Comme son nom l'indique, IIIF est un ensemble de normes techniques (utilisation du format JSON et d'une syntaxe normée notamment) pour décrire et accéder à des images sur le web par le biais de visionneuses spécifiques. Outre le fait qu'exposer des données en suivant les normes et recommandations techniques de la communauté IIIF améliore le référencement des images en permettant aux moteurs de recherche de mieux les indexer, cela permet aussi de les mettre à disposition de façon standardisée pour les utilisateurs (privés ou institutionnels) afin qu'ils puissent les modifier, les annoter ou simplement les afficher dans des interfaces de consultation (visionneuses) standardisées (par exemple <https://projectmirador.org/>)<sup>14</sup>. À l'échelle des institutions, la mise en place de IIIF peut permettre de créer des portails de consultations communs et fédérés et donc de mutualiser les moyens, mais aussi les collections. Par exemple, aux archives départementales du Lot-et-Garonne, un projet est en cours pour mettre en ligne, en suivant les principes de IIIF, le fonds Lauzun, du nom d'un érudit local ayant rassemblé des clichés archéologiques au cours du XIXe siècle afin que les images soient moissonnées par le portail France Archives. Outre tous les avantages déjà décrits plus haut, il faut noter qu'une partie de ce fonds est conservée par les archives départementales du Gers voisines ; le mettre à disposition dans un portail permettrait donc — si les archives départementales du Gers suivent le choix de celles du Lot-et-Garonne — de rassembler virtuellement un fonds qui a une unité intellectuelle, mais pas physique<sup>15</sup>. Mais c'est bien

---

//www.cairn.info/bibliotheques-le-web-est-a-vous--9782765415213-p-105.htm (visité le 19/08/2024), § 22.

14. Régis ROBINEAU et Cécile SAJDAK, *Le programme IIIF 360 pour les archives*, Journée d'étude internationale IIIF, 30 nov. 2023.

15. Isabelle Brunet, Stéphane Capot, Marc Buset et Charles Moreau, *les archives du Lot-et-Garonne*

parce que les archives départementales du Lot-et-Garonne ont fait le choix institutionnel de mettre leurs images numérisées à disposition de façon ouverte, en suivant un format interopérable pour favoriser leur réutilisation, que ces dernières se retrouvent accessibles et rayonnent à l'échelle nationale au travers de France Archives, portail français des archives. Cela permet donc aux utilisateurs cherchant une information de la trouver, sans égard pour le lieu qui la conserve, améliorant ainsi la repérabilité de cette dernière ainsi que son référencement : être sur un portail national, voire européen, peut faire sortir du web profond des collections qui n'en auraient, autrement, pas forcément eu les moyens techniques. Cela pose en revanche la question de l'invisibilisation des institutions qui ne deviennent que des puits de données, et c'est l'une des limites de ce type de pratique (car les financements vont aux établissements les plus visibles bien souvent).

### 3. Des catalogues aux politiques *data driven*

Et si les données, plutôt que d'être vues comme de vastes réservoirs parfois difficiles à gérer, étaient abordées comme un moyen d'être plus efficace ? Et si l'amélioration de leur découvrabilité rendait des services, non seulement aux usagers externes (dans le cadre patrimonial), mais aussi en interne ? Car l'exponentielle augmentation de la masse des données disponibles est aussi accompagnée d'une grande diversification de ces dernières, et le secteur patrimonial ne fait pas ici exception<sup>16</sup>. Ces dernières peuvent aller des métadonnées catalographiques classiques aux traces laissées par les usagers en ligne en passant par les données juridiques. On a vu plus haut combien les projets de portails permettaient de casser les silos de données, améliorant, de fait, la découvrabilité, mais seuls les silos documentaires sont ici brisés. Reste ceux internes aux institutions, en liant toutes les données entre elles, les institutions peuvent optimiser leur processus, et notamment documentaires. C'est par exemple le cas à la RTS, après le lancement de GICO<sup>17</sup>. La volonté a été d'y intégrer des données juridiques, l'idée attenante était de permettre aux documentalistes de voir, directement lors de leur recherche, quelles images étaient encore sous droits et quelles images étaient propriété de la RTS. Même si le projet a été au final abandonné, du fait de sa complexité et de problématiques internes, qu'il serait fastidieux de détailler ici<sup>18</sup>, l'idée était présente : casser les silos internes pour permettre une gestion plus efficace de l'information.

---

en route vers le IIIF, Journée d'étude internationale IIIF, 30 nov. 2023.

16. Gautier Poupeau, « La donnée : nouvelle perspective pour les bibliothèques », dans *Vers de nouveaux catalogues*, ISSN : 0184-0886, Paris, 2016 (Bibliothèques), p. 159-171, DOI : 10.3917/elec.berme.2016.01.0159, §15 à §18.

17. L'outil de gestion des données archivées par la RTS déjà évoqué dans la partie 1

18. D. BARCELLA, *Entretien avec Denise Barcella, experte patrimoine des archives de la RTS et ancienne enseignante de l'université de Lausanne en histoire de la télévision....*

Comme l'écrit Gauthier Poupeau dans « La donnée : nouvelle perspective pour les bibliothèques »<sup>19</sup> il s'agit pour les bibliothèques et institutions patrimoniales de manière générale « d'arrêter de faire du catalogue le centre de leur système d'information » et « de faciliter l'accès aux documents par l'utilisation de nouvelles données issues de l'exploitation du contenu lui-même et de l'analyse des traces laissées par les utilisateurs »<sup>20</sup>. C'est exactement cette démarche qui a été entreprise par l'Institut national de l'audiovisuel (INA), qui a mis en production un lac de données en 2022 pour répondre aux problématiques énoncées plus haut. Car les données de l'institut fondé en 1974 après l'éclatement de l'Office pour la radiotélévision française (ORTF) sont elles aussi très diverses : dépôt légal des flux télévisuels et radiophoniques (depuis 1995), d'une partie du web, base juridique, référentiels, données de production, traces, métadonnées moissonnées depuis diverses sources (Médiamétrie par exemple), bases commerciales...<sup>21</sup> Ce lac a eu pour vocation de briser les silos entre deux systèmes d'information très opaques entre eux : le dépôt légal et les métadonnées patrimoniales d'une part et de l'autre le système dit « professionnel »<sup>22</sup> contenant les outils de travaux de l'institut. Le modèle de données (manière dont les données sont organisées) se veut le plus simple possible avec à son origine un événement, par exemple la diffusion de « Quand les dieux rôdaient sur la terre » à la radio auquel on peut ajouter tout type de données : l'émission en tant que telle et ses métadonnées, le post Instagram réalisé pour en faire la promotion, ou encore une — hypothétique — captation vidéo de l'émission. Le tout, dans l'objectif d'être le plus souple possible et de répondre aux évolutions actuelles et futures de l'univers médiatique et de son archivage, mais aussi des technologies et des besoins des utilisateurs ainsi que des apports externes (notamment concernant les métadonnées) qui sont nombreux au sein de l'institution<sup>23</sup>. Cela permet à l'INA d'avoir à disposition plus qu'un lac, un véritable océan de données constitué de cinq milliards de lignes<sup>24</sup> de description dans lequel les usagers et les outils peuvent puiser à volonté, garantissant une gestion bien plus efficace et normée. Ainsi, chercheurs, commerciaux, documentalistes peuvent exploiter les données pour répondre à leurs besoins, et c'est exactement ce que fait l'Institut avec la mise en place d'outils de traitement des images par exemple qui alimentent encore d'avantage le lac.

Depuis « L'évolution des pratiques de description des archives... » page 199.

---

19. G. Poupeau, « La donnée... ».

20. *Ibid.*, § 3.

21. E. Alquier, *Journée de présentation de l'institut national de l'audiovisuel (INA)...*

22. Claire Marie Dribault Dujardin, Dominique Fackler et Jeannette Pichon, « L'évolution des pratiques de description des archives documentaires de l'Institut national de l'audiovisuel (INA) à l'ère du numérique », (, 2020), Publisher : Persée - Portail des revues scientifiques en SHS, DOI : 10.3406/gazar.2020.5948, p. 195.

23. *Ibid.*, p. 198.

24. E. Alquier, *Journée de présentation de l'institut national de l'audiovisuel (INA)...*

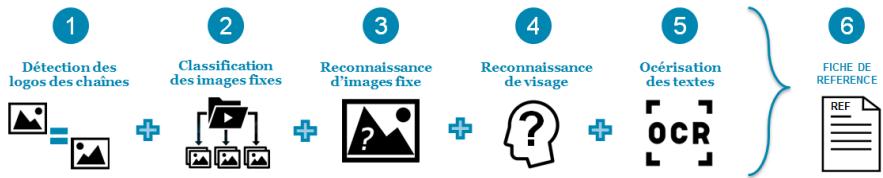


FIGURE 12 – Les traitements effectués par l'INA sur une image

L'institution a aussi la possibilité d'utiliser les données ainsi organisées pour réaliser des visualisations de données ; avoir pris le temps de les structurer rend en effet bien plus aisées et pertinentes ce type de réalisations. En témoigne le projet Data.INA.fr (qui sera évoqué dans notre troisième partie). Les visualisation de données seront ainsi l'objet de notre prochaine partie en tant que nouveau type d'interfaces d'accès au savoir.



# Chapitre 7

## La visualisation de données en tant que nouvelle interface au service de la découverabilité

### 1. Voir globalement : l'importance d'avoir une vue d'ensemble des collections

Comme décrit plus haut, la digitalisation du patrimoine a créé des volumes de données immenses et a, dans le même temps, changé notre rapport au patrimoine qui est devenu plus intangible<sup>1</sup>, plus « virtuel ». Aux salles de lecture d'archives saturées des années 1980, ont succédé des sites web qui le sont tout autant — si ce n'est plus. Dans le cas du patrimoine audiovisuel, massivement numérisé dans les années 2000, les interfaces sont très souvent les seuls moyens d'accéder aux objets patrimoniaux. Cette nouvelle approche d'un patrimoine intangible, accessible par le biais d'interfaces web basées sur les métadonnées, change les pratiques et usages, notamment le sens de recherche. Là où les chercheurs démarraient aux niveaux hiérarchiques hauts (fonds, collections, etc.), les moteurs de recherche donnent aujourd'hui accès au niveau de la pièce directement, rendant difficile l'appréhension des collections dans leur ensemble et rejoignant le concept de « fatigue muséale »<sup>2</sup>. Les interfaces web classiques, une barre de recherche et des filtres à facettes viennent reproduire, et même amplifier, cette problématique de fatigue muséale ;

---

1. F. Windhager, Paolo Federico, Gunther Schreder, Katrin Glinka, Marian Dork, Silvia Miksch et E. Mayr, « Visualization of Cultural Heritage Collection Data : State of the Art and Future Challenges », *IEEE Transactions on Visualization and Computer Graphics*, 25–6 (1<sup>er</sup> juin 2019), p. 2311-2330, DOI : 10.1109/TVCG.2018.2830759, p. 1.

2. B. I. Gilman, « Museum Fatigue »..., pp. 62-72.

les utilisateurs occasionnels étant souvent confrontés à un syndrome de la barre de recherche blanche. Sans vue d'ensemble sur les fonds, ils ne sont pas capables d'aller les explorer. C'est pourquoi, le concept d'interfaces dites généreuses est né<sup>3</sup>; elles partent du postulat que l'utilisateur n'est plus un chercheur en manque d'information, mais un flâneur qui souhaite découvrir le fonds. La priorité de telles interfaces, contrairement aux barres de recherche qui favorisent la « trouvabilité », est de favoriser la découvrabilité<sup>4</sup>. La visualisation de l'information (ou *data visualization*) prend alors une importance nouvelle puisqu'elle peut permettre d'améliorer la découvrabilité des fonds.

Prenons ici comme exemple l'expérience conduite par le laboratoire de recherche de la bibliothèque publique de New York « Le catalogue en réseau »<sup>5</sup>, dont l'objectif était de montrer la totalité du catalogue sur une seule image et de voir les relations qu'entretiennent les objets entre eux, comme si le catalogue avait un bouton « voir tout »<sup>6</sup>.

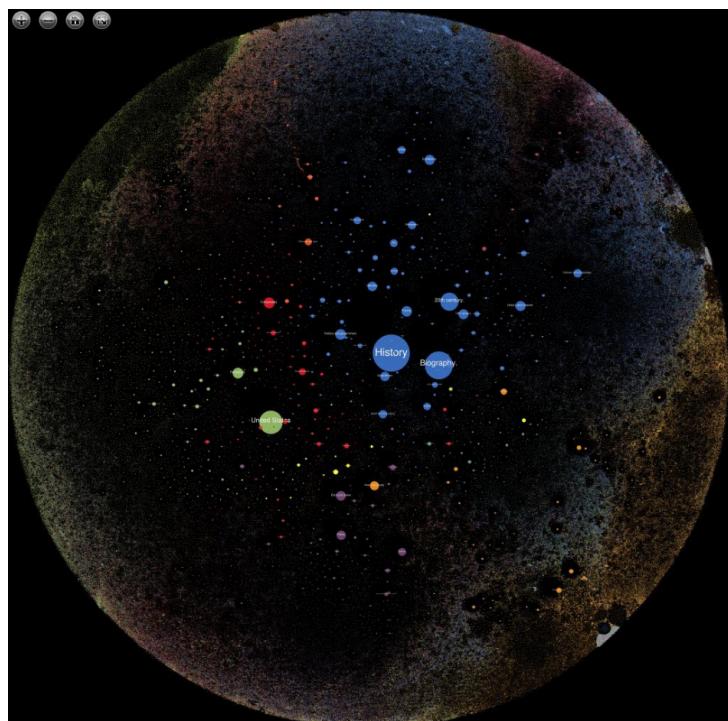


FIGURE 13 – Le catalogue de la bibliothèque publique de New York visualisé, depuis : <https://catalog-network.s3-website-us-east-1.amazonaws.com/>

3. F. Windhager, S. Salisu, G. Schreder et E. Mayr, « Orchestrating Overviews : A Synoptic Approach to the Visualization of Cultural Collections », *Open Library of Humanities*, 4–2 (13 août 2018), p. 9, DOI : 10.16995/olh.276, pp. 5-6.

4. Jeffrey J. Shen, *A Generous Interface for the Discoverability of Text Collections*, Accepted : 2023-07-31T19 :38 :10Z, Thesis, Massachusetts Institute of Technology, 2023, URL : <https://dspace.mit.edu/handle/1721.1/151417> (visité le 19/08/2024), p. 18.

5. Raphaëlle Lapôtre, « Visualiser les données du catalogue », dans *Vers de nouveaux catalogues*, ISSN : 0184-0886, Paris, 2016 (Bibliothèques), p. 37-47, DOI : 10.3917/elec.berme.2016.01.0037, §20 à §26.

6. Matt Miller, *The Networked Catalog / The New York Public Library*, 31 juill. 2014, URL : <https://www.nypl.org/blog/2014/07/31/networked-catalog> (visité le 19/08/2024).

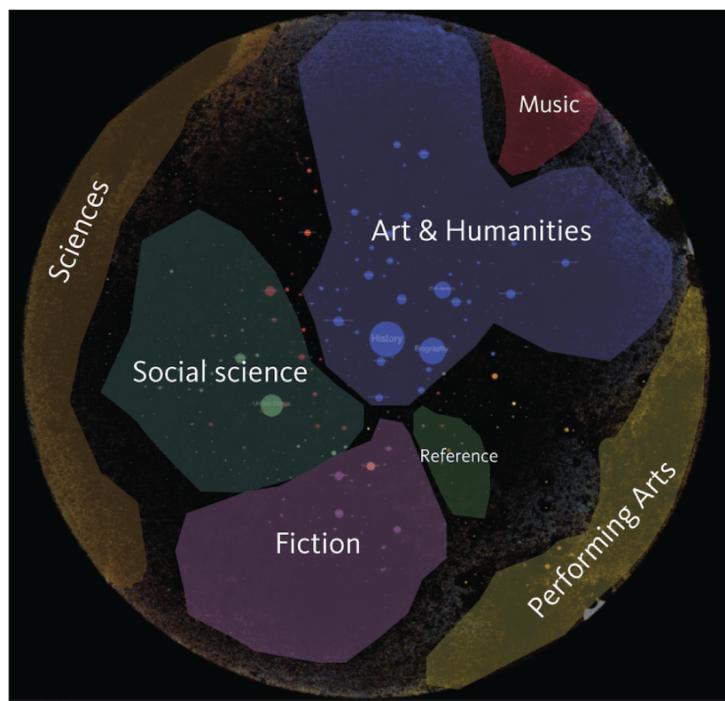


FIGURE 14 – Les grandes thématiques qui se dégagent de l’expérimentation de la bibliothèque publique de New York

Techniquement parlant, cette visualisation utilise les descripteurs *MARC* d’indexation de chaque item et les affiche sous forme de points colorés : plus un point est gros, plus il y a d’ouvrages le concernant dans la bibliothèque publique de New York ; si deux sujets sont souvent mentionnés ensemble, par exemple Jeux Olympiques et sport, on en déduit qu’ils sont liés d’une manière ou d’une autre et ils se voient attribuer la même couleur.

Outre le fait qu’elle soit fascinante et que l’explorer et s’y perdre soit passionnant<sup>7</sup>, elle permet, d’un coup d’œil, de se rendre compte des pans de la collection très représentés et centraux ainsi que des liens sémantiques, parfois étonnantes entre des entités. Cela permet de se rendre compte de ce qu’une bibliothèque, en tant que réceptacle du savoir à un instant donné, conserve le plus. La visualisation peut donc être, comme l’écrit Raphaëlle Lapôtre, « un moyen heuristique qui participerait à la production de connaissances »<sup>8</sup>. En plus de donner une vision d’ensemble et de favoriser la compréhension globale de la collection, elle permet d’en révéler de nouveaux aspects. On serait évidemment tenté de voir dans cette image une visualisation des connaissances, comme si une bibliothèque était le reflet du réel et des connaissances produites. Mais ce miroir est déformé : parce que le contenu d’une bibliothèque est le reflet des politiques documentaires de son époque ; parce que les données ne sont pas si fiables, qu’elles sont truffées d’erreurs humaines ; de choix d’indexation ; des migrations de données et des changements de vocabulaires. Par

7. La navigation interactive est disponible en suivant ce lien : <http://catalog-network.s3-website-us-east-1.amazonaws.com/>

8. R. Lapôtre, « Visualiser les données du catalogue »..., § 23.

exemple, le mot tsunami n'est employé que depuis récemment, on lui a longtemps préféré « raz-de-marée »<sup>9</sup>.

Éclairons notre propos avec l'exemple de la RTS où durant notre stage on a voulu effectuer une démarche similaire pour proposer un outil de navigation sous forme de treemap hiérarchique en utilisant les « codes contenus » qui sont des métadonnées fournies pour chaque document renseignant sa thématique de façon hiérarchique, par exemple un téléjournal aura le code contenu « Actualité ».

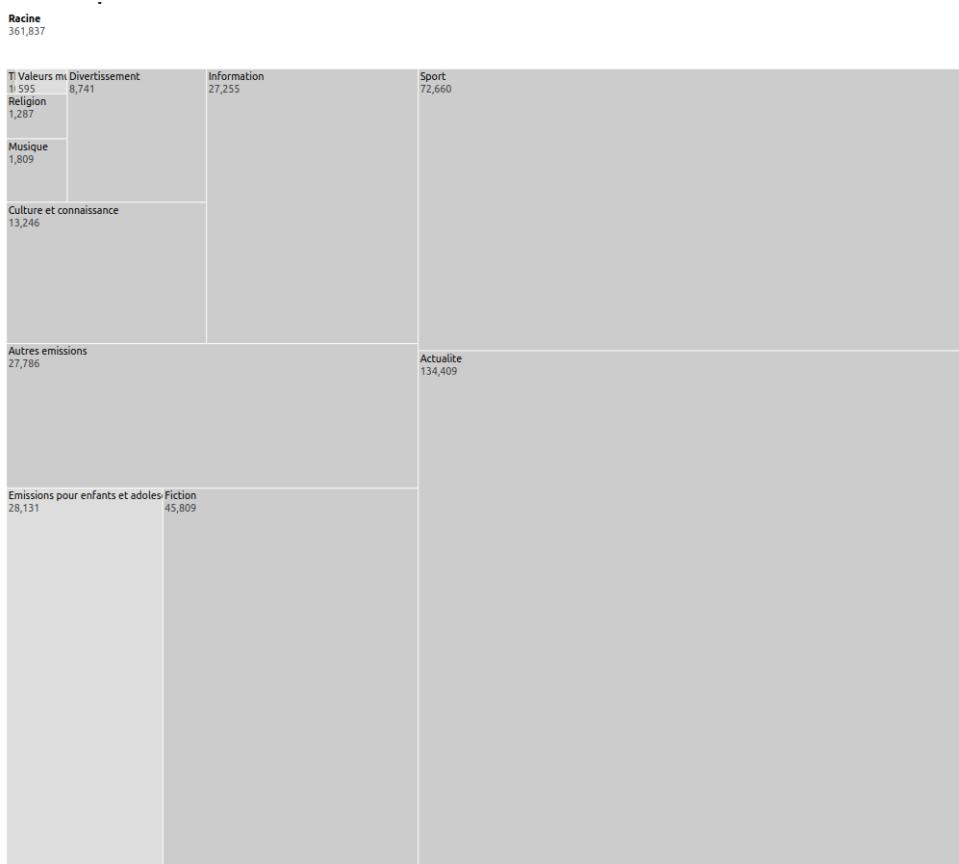


FIGURE 15 – Treemap interactive réalisée pendant le stage

Une fois la visualisation réalisée, nous nous sommes rendu compte qu'elle n'était absolument pas le reflet de ce qui était conservé à la RTS. D'abord, car seule une petite proportion des documents avait un code contenu renseigné (361 837 documents), ensuite car ce qui fait varier la taille des rectangles, qui est proportionnelle au nombre d'émissions ayant le même code contenu, ne reflète pas la réalité du fonds, mais des politiques documentaires. On retrouve par exemple énormément d'actualité – ce qui est en partie vrai – mais elle est aussi beaucoup représentée, car c'est la seule, depuis les années 1980, à être archivée de façon systématique. Quant au sport, dont on pourrait s'étonner de la forte présence au regard de ce qui a été écrit plus haut, cela s'explique par une description

9. Propos rapportés par Denise Barcella

assez détaillée des codes contenus pour le sport, qui est assez facile à catégoriser (selon la discipline), contrairement à d'autres type d'émissions ; par ailleurs, comme le sport est souvent acheté par la RTS, il est important qu'il soit bien décrit pour des questions de droits, les codes contenus sont d'ailleurs surtout utilisés pour cela. Comme la carte de la bibliothèque publique de New York était plus le reflet de son histoire institutionnelle et documentaire, cette visualisation est le reflet des pratiques documentaires de la RTS plus que de ce qui est conservé en son sein. Dans les deux cas, surtout à New York, l'objectif de donner une vision d'ensemble de la collection semble accompli. Les possibilités heuristiques offertes par la visualisation de données, une fois les spécificités et biais potentiels pris en compte, sont prometteuses. En effet, cela permet d'envisager de fournir aux utilisateurs des collections des clés de lecture différentes, qui feront l'objet de notre prochaine section.

## 2. Voir sous un autre angle : donner des clés de lecture différentes des collections

On vient de voir que la visualisation de l'information, en plus d'offrir une indispensable vue d'ensemble des collections, offre un potentiel heuristique nouveau. Elle permet en effet « d'opérer un “point de vue” sur un sous-ensemble de résultats pertinents afin d'en faciliter la compréhension »<sup>10</sup>. L'intérêt de visualiser des données est donc d'offrir aux regardeurs différentes clés de lecture<sup>11</sup> d'une collection. On peut séparer ces clés de lecture en trois catégories (qui peuvent se cumuler) : vues multiples (listes, mosaïques, etc.) ; encodage spatial (cartes géographiques, diagrammes de réseau, etc.) et encodage temporel (frises chronologiques, animations)<sup>12</sup>. À chaque catégorie correspondent des possibilités interprétatives différentes, par exemple : un diagramme en réseau permet d'explorer la proximité entre des objets culturels, une animation permet de donner à voir les évolutions temporelles des objets<sup>13</sup>.

La multiplication des interfaces de visualisation offre aux utilisateurs un accès riche et non restrictif aux collections culturelles, ce qui permet d'explorer des ensembles de données vastes. Ce faisant, ces différentes interfaces sont des outils précieux pour exposer la richesse et la diversité des collections culturelles afin que les utilisateurs puissent naviguer

10. Hakim Hachour, « De la fouille à la visualisation de données : un processus interprétatif », *I2D - Information, données & documents*, 52-2 (2015), Place : Paris Publisher : A.D.B.S., p. 42-43, DOI : 10.3917/i2d.152.0042, § 3.

11. « Concept ou angle d'approche permettant de comprendre, d'analyser, d'interpréter ou encore de critiquer un texte, une œuvre, ou un phénomène. » - Wiktionnaire

12. F. Windhager, P. Federico, E. Mayr, G. Schreder et Michael Smuc, « A Review of Information Visualization Approaches and Interfaces to Digital Cultural Heritage Collections » (), p. 76.

13. *Ibid.*, p. 77.

entre différentes perspectives. Pour les qualifier, F. Windhager et al. parlent d'« interfaces génératrices ».<sup>14</sup> qui se distinguent des interfaces classiques par une capacité à présenter de grandes quantités d'informations en soutenant les utilisateurs dans leurs tâches cognitives. De même qu'un bâtiment doit être généreux et offrir des espaces vides et des plafonds hauts pour être agréable à utiliser, les interfaces, en tant que substituts immatériels, doivent faire de même.

Elles doivent donc être conçues pour éviter la surcharge cognitive en offrant des représentations multiples des données, ce qui permet aux utilisateurs de construire une vision globale et cohérente des collections qu'ils explorent<sup>15</sup>. Elles se veulent des « anti barres de recherche », car, selon les auteurs, ces dernières sont construites selon deux suppositions préalables : le visiteur connaît, au moins vaguement, ce qu'il cherche et il ne souhaite pas « s'engager dans la complexité de l'espace de recherche qui leur est caché »<sup>16</sup>.

Afin d'illustrer notre propos, nous mettrons en parallèle un exemple issu d'une réalisation pendant le stage (carte interactive des contenus archivés par la RTS) et le tableau de bord réalisé par la Bibliothèque du Congrès pour visualiser la presse numérisée<sup>17</sup>.

---

14. Id., « Orchestrating Overviews... », p. 5.

15. *Ibid.*, pp. 5-6.

16. *Ibid.*, p. 6.

17. *Chronicling America Maps and Visualizations - National Digital Newspaper Program (Library of Congress)*, URL : <https://www.loc.gov/ndnp/data-visualizations/> (visité le 19/08/2024), tableau de bord accessible en suivant l'url suivante <https://public.tableau.com/app/profile/chronicling.america/viz/ChroniclingAmericaTemporalCoveragebyStateMap/TemporalStateCoverage>.

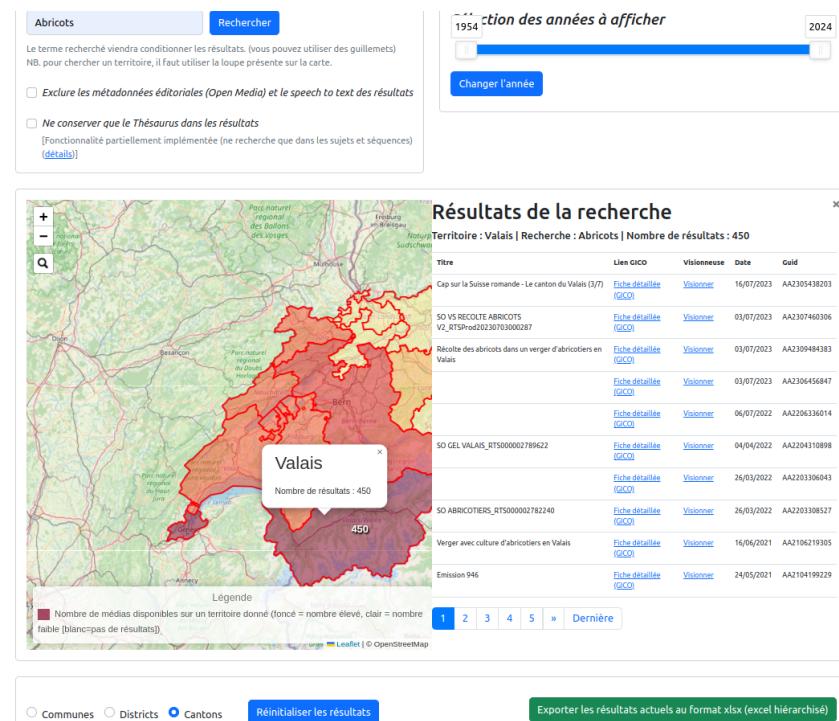


FIGURE 16 – Carte interactive des contenus archivés à la RTS réalisée pendant le stage

D'abord, donc, la carte interactive des contenus (visible sur cette page) qui se présente, comme son nom l'indique, sous forme d'une carte de la Suisse avec la possibilité de naviguer entre les différents niveaux territoriaux du pays : cantons, districts et communes. Elle permet, en un seul regard, d'observer les territoires pour lesquels la RTS conserve le plus d'archives et de cliquer sur ces derniers pour consulter les archives qui s'y réfèrent. Elle combine les niveaux de lecture spatiaux et temporels décrits plus haut en permettant aux utilisateurs de naviguer dans le temps pour observer les variations dans la collection. Par ailleurs, ils ont la possibilité d'inclure un terme de recherche pour observer la répartition géographique de ce terme. Par exemple, dans l'image ci-après, on a tapé « abricots » et on observe que le canton le plus représenté est le Valais<sup>18</sup>. Cette carte n'est donc pas uniquement un outil d'exploration, elle permet aussi de réaliser des statistiques à partir des recherches effectuées en proposant un export (au format Excel) de ce qui est visualisé. L'image est ici synoptique, elle permet de voir plusieurs temporalités et états dans le même temps, c'est un choix sémantique fort mais qui peu parfois être complexe pour l'utilisateur, c'est pourquoi d'autres projets préfèrent scinder les possibilités heuristiques en plusieurs visualisations. Tel est le cas de la bibliothèque du Congrès et de son tableau de bord.

18. Canton produisant 90 % des abricots Helvètes

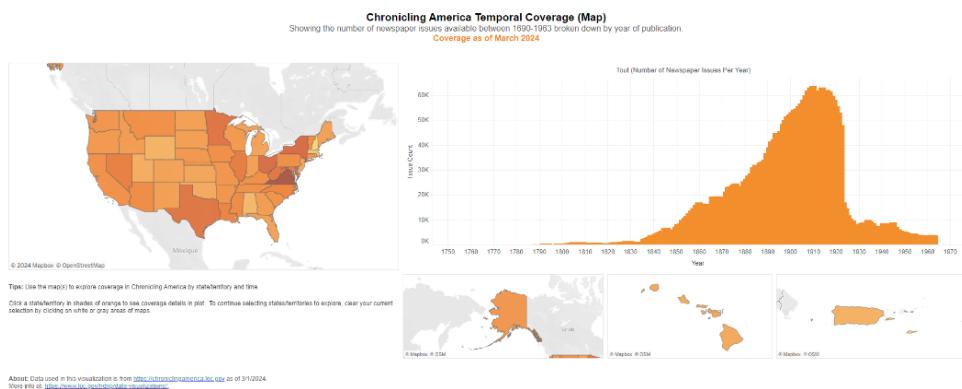


FIGURE 17 – Tableau de bord « Chronicling America Maps and Visualizations »

L'institution propose en effet un tableau de bord, lui aussi interactif. Il permet aux utilisateurs de voir le nombre de journaux numérisés disponibles dans chaque État. C'est là aussi une interface qui combine une lecture spatiale et temporelle, mais, ici, le choix a été fait de séparer ces deux clés de lecture, la carte permet de sélectionner l'État pour que l'utilisateur puisse visionner le nombre de titres de presse disponibles et numérisés à travers le temps. Cette interface ne permet, en revanche, pas de consulter directement les titres de presse.

On a donc ici deux approches similaires, mais avec des visées différentes, la première approche est plus du côté de l'interface de navigation dans les collections, la seconde est statistique. Dans les deux cas, on offre aux utilisateurs la possibilité de voir dans son ensemble un fonds extrêmement volumineux en proposant des clés de lecture variées. Soit elles sont combinées dans une seule visualisation à l'aide de filtres, soit elles sont séparées en deux visualisations différentes. Cette vision d'ensemble permet aux personnes consultant les fonds de ne pas tomber dans certains écueils. Par exemple, dans le cas de la RTS, étant une chaîne romande, la majorité des sujets concerne la région linguistique francophone. Si l'on souhaite effectuer une recherche sur des cantons italophones ou germanophones, ce ne sera pas l'endroit le plus pertinent. Ce type d'interface répond donc à de multiples problématiques : donner une vision d'ensemble et des clés de lecture différentes d'un fonds ; permettre une interprétation quantitative ; être utilisé dans des actions de valorisation tout en limitant le syndrome de la barre de recherche blanche. Par ailleurs, la multiplicité des filtres permet une granularité de navigation très importante donnant de nombreuses opportunités de se concentrer sur des documents spécifiques<sup>19</sup>. Combiner différentes clés de lecture (dans le cas de la RTS, nous avons ajouté à cette visualisation un *knowledge graph* visible plus bas) en prenant en compte le fait que chacune permet de capturer un aspect spécifique de la collection est donc une stratégie intéressante dans le cadre d'objets culturels complexes. Par ailleurs, cela permet de créer des possibilités

19. Id., « Orchestrating Overviews... », p. 7.

pour les utilisateurs de faire des découvertes par sérendipité, car ce type d’interface les laisse « flâner » dans les collections comme le notent Thudt et al.<sup>20</sup>. En revanche, comme le notent Florian Windhager et al., réaliser des interfaces génératrices combinant de nombreuses visualisations et possibilités de filtrage peut recréer la problématique de fatigue muséale en créant ce que les auteurs appellent le « split attention challenge »<sup>21</sup>. Les interfaces, de même que les bâtiments, auxquels elle prétendent se substituer, doivent donc – tout en restant génératrices – ne pas proposer trop de niveaux de lecture et rester simples d’utilisation, car dans les deux cas, cela résulte en un usager perdu : dans l’immensité de l’espace physique ou virtuel (ici aussi, le site François-Mitterrand est éclairant).




FIGURE 18 – *Knowledge Graph* réalisé pendant le stage

### 3. Voir pour aller plus loin

Dans la partie précédente, nous avons montré que les interfaces pouvaient permettre de se substituer aux bâtiments en proposant une vue d’ensemble des collections et une

20. *Ibid.*, (cité dans).

21. *Ibid.*, p. 9.

navigation dans cette dernière, à la manière des déambulations dans un lieu physique. Mais peuvent-elles permettre d'aller plus loin ? Peuvent-elles permettre de dépasser les capacités humaines en matière de découvrabilité ? Pour tenter de répondre à ces questions, nous allons explorer le projet de recherche Philherit présenté lors de la journée d'étude organisée par la Bibliothèque nationale de France le 20 juin 2023 « Penser la découvrabilité des contenus culturels »<sup>22</sup> et le projet *Impresso* (projet d'exploration de corpus de la presse écrite [images et textes])<sup>23</sup>.

Comment poser la question de l'héritage dans le domaine de la philosophie de nouveau ? C'est la question que pose le projet Philherit. Pour y répondre, le corpus à analyser est extrêmement vaste, car la question était centrale au XIXe siècle<sup>24</sup> du fait de sa proximité avec les questions de justice sociale entre autres. Ce corpus est constitué, par ailleurs, de sources très variées (périodiques, livres, journaux, etc.) et dans toutes les disciplines (économie, philosophie, etc.) réparties en sept bases de données textuelles extraites depuis Gallica. Le texte est ensuite réparti en différents thèmes identifiés par trois mots-clés grâce à l'intelligence artificielle (*BERT*)<sup>25</sup>. Ce qui est intéressant ici, pour revenir à la question des interfaces, c'est la mise en place d'un nuage de mots qui reprend les thèmes générés par l'intelligence artificielle et les donne à voir de façon synthétique : plus un mot est représenté dans le corpus, plus il sera gros dans la visualisation, ce qui permet de dégager de grands thèmes et d'aller consulter les ouvrages essentiels<sup>26</sup>. Mélanie Plouviez, dans son intervention, dégage trois impacts de l'utilisation des interfaces pour l'amélioration de la découvrabilité du corpus : premièrement, l'accélération de l'analyse, qui était avant réalisée sur *Excel* manuellement et est désormais possible d'un seul coup d'œil sur l'interface ; deuxièmement, l'amélioration de l'analyse dite « hypertextuelle », c'est-à-dire de l'exploration des liens entre les documents ; et, troisièmement, l'amélioration de la sérendipité<sup>27</sup>. La chercheuse conclut son intervention en citant Michel Foucault qui, dans son « archéologie du savoir »<sup>28</sup>, définissait les archives comme une « masse discursive » à laquelle les humanités numériques auraient mis fin tout en permettant de faire émerger de multiples points de vue d'une même collection grâce à diverses interfaces<sup>29</sup>.

---

22. Mélanie Plouviez, *Philosophie de l'héritage : le projet Philherit*, Penser la découvrabilité des contenus culturels, 20 juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels>.

23. *impresso / Media Monitoring of the Past*, URL : <https://impresso-project.ch/app/> (visité le 19/08/2024).

24. Id., *Philosophie de l'héritage : le projet Philherit*, Paris, France, juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels>.

25. En traitement automatique du langage naturel, BERT, acronyme anglais de Bidirectional Encoder Representations from Transformers, est un modèle de langage développé par Google en 2018 - Wikipédia

26. Il nous a été impossible de trouver une image de bonne qualité de cette interface, elle est tout de même visible dans la vidéo suivante : <https://youtu.be/4zaebvULdc4?t=4787> à 1h19 et 47 secondes.

27. *Ibid.*

28. Michel Foucault, *L'archéologie du savoir*, Paris, 2008 (Tel, 354).

29. M. Plouviez, *Philosophie de l'héritage : le projet Philherit...*

Les interfaces permettent-elles de dépasser les capacités humaines uniquement dans le cadre de projets spécifiques et de cas d’usages précis ? Attardons-nous sur le projet *Impresso*, dont l’objectif est d’améliorer la découvrabilité de la presse numérisée suisse et luxembourgeoise (donc en 4 langues)<sup>30</sup>. Il est mené par une équipe interdisciplinaire d’historiens, linguistes et informaticiens ainsi que des designers — essentiels pour la réalisation d’interfaces efficaces<sup>31</sup>. Ici, en plus de répondre à des cas d’usages « de chercheurs », le projet tente d’être accessible et utile pour les non-spécialistes en répondant à cinq cas d’usages : récupération du contenu utile, compréhension et contextualisation, comparaison des résultats, exportation pour analyse et transparence (documentation du code) et explicabilité de ce dernier<sup>32</sup>. L’interface répond donc à ces cas d’usages en offrant notamment la possibilité pour ses utilisateurs, une fois un terme recherché, de compléter leur recherche. Soit de façon thématique, avec des personnalités liées, ou bien des collections liées ; sans tenir compte de la langue de leur recherche.

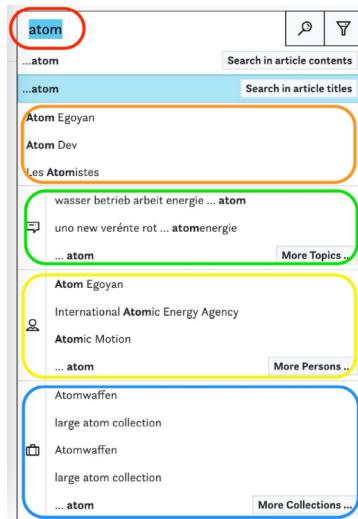


FIGURE 19 – Illustration de l’autocomplétion des recherches, depuis *Düring, Bunout, Guido...*

30. Dans 3 des 4 langues nationales suisses (Français, Italien, Allemand [le Romanche étant exclu]) et en Luxembourgeois

31. Maud Ehrmann, « Explorer la presse numérisée : le projet Impresso », 129/2021 (27 nov. 2021), p. 159-173, URL : <https://infoscience.epfl.ch/handle/20.500.14299/185588> (visité le 19/08/2024).

32. Marten Düring, Estelle Bunout et Daniele Guido, « Transparent generosity. Introducing the *impresso* interface for the exploration of semantically enriched historical newspapers », *Historical Methods : A Journal of Quantitative and Interdisciplinary History*, 57–1 (2 janv. 2024), p. 20-40, DOI : 10.1080/01615440.2024.2344004, pp. 5-7.

Elle permet aussi de voir les textes et images similaires pour un sujet donné et de voir sa distribution dans le temps en suivant le principe des *n-grams*<sup>33</sup>. Enfin, elle permet de comparer différents résultats pour observer leur traitement dans la presse. Par exemple, on peut choisir d'observer les résultats communs entre « abricots » et « Valais », et on se rendra compte que l'année du pic observé (1953) correspond à la « révolte des abricots »<sup>34</sup>.



FIGURE 20 – Recherche comparative entre « abricots » et « Valais »

Il semble, à en lire les évaluations des utilisateurs, que les fonctionnalités proposées et l'interface soient non seulement faciles d'accès, mais permettent en outre une grande finesse dans l'exploitation de ce type de corpus textuel. Par ailleurs, les auteurs concluent en énonçant le fait que les chercheurs déjà habitués aux recherches « *data-driven* » étaient très positifs sur les possibilités d'export et d'exploitation offertes, de même que les utilisateurs moins connaisseurs<sup>35</sup>.

Au regard de ces deux exemples, on peut noter que la création d'interfaces généreuses, tout en permettant de dépasser les capacités humaines des chercheurs (Philherit l'a bien montré), peut aussi être un excellent vecteur de valorisation des collections pour le grand public. Il semble donc que la création de tels outils pourrait être placée du côté des institutions, car, et *Impresso* le montre bien, s'ils sont bien faits et offrent de nombreuses possibilités allant de la plus simple, faire une recherche ; à la plus complexe, exporter les

33. Un n-gramme est une sous-séquence de n éléments construite à partir d'une séquence donnée - Wikipédia.

34. *La révolte des abricots de 1953 : des citoyens saxonains revalorisent un épisode de l'histoire agricole valaisanne*, Canal9, Section : ACTUALITES, 25 sept. 2018, URL : <https://canal9.ch/fr/la-revolte-des-abricots-de-1953-des-citoyens-saxonains-revalorisent-un-episode-de-lhistoire-agricole-valaisanne/> (visité le 19/08/2024).

35. Id., « Transparent generosity. Introducing the *impresso* interface for the exploration of semantically enriched historical newspapers »..., pp. 5-7.

données d'une visualisation au format *JSON*<sup>36</sup> pour les exploiter. Ils servent des publics très divers et permettent d'éviter aux chercheurs de créer, de leur côté, des outils dédiés. Ils peuvent alors réutiliser ceux proposés par les institutions pour servir leur cas d'usage ou les réadapter en utilisant les données fournies. Les auteurs de l'article « transparent generosity » sur *Impresso* notent toutefois un certain nombre de limitations à la mise en place de tels outils : silos institutionnels et d'information (causés par des restrictions légales souvent), doublons et mauvaises qualités des données notamment de l'*OCR*<sup>37</sup>, mais aussi, manque d'interfaces proposant aux chercheurs de découvrir les fonds pour en tirer d'éventuels questionnements<sup>38</sup>. Travailler à la correction de ces limitations, notamment celles concernant les données en elles-mêmes, peut aussi permettre aux institutions de gérer de façon plus efficace leurs fonds en ayant une approche dite *data-driven* comme évoqué plus haut.

---

36. JSON, pour javascript object notation est un format communément usé pour l'échange de données sur le web

37. Reconnaissance optique des caractères

38. *Ibid.*, pp. 1-2.



# Chapitre 8

## Nouvelles interfaces : nouveaux usages

### 1. À chacun son interface : l'exemple d'*InTaVia*

Comme rappelé par la Bibliothèque nationale de France (BnF) dans sa présentation de la journée d'étude sur la découvrabilité, le défi pour les institutions patrimoniales est bien souvent de réussir à concilier la trouvabilité, c'est-à-dire de laisser à l'usager qui sait ce qu'il cherche la possibilité de le trouver rapidement, et la découvrabilité qui lui permettra de trouver ce qu'il n'a pas cherché<sup>1</sup>. Que peuvent les interfaces pour faire face à cette tension ? Peuvent-elles concilier les différents usages et enjeux ? C'est ce que nous tenterons d'analyser en plaçant notre regard sur le projet *InTaVia* (*In/Tangible Cultural Heritage : Visual Analysis, Curation & Communication*), débuté en 2020 et financé par la Commission européenne.

Les objectifs du projet sont multiples : d'abord répondre aux enjeux d'atomicité des bases de données patrimoniales sur le web (*InTaVia* est donc un portail). Ensuite, faciliter la compréhension globale des objets historiques tangibles avec les données intangibles pour améliorer leur interprétation. Enfin, et c'est ce qui va nous intéresser ici, « comme les besoins de chaque audience varient [cette interface] devra satisfaire différentes exigences scientifiques et pratiques, mais aussi narratives et esthétiques »<sup>2</sup>.

---

1. *Penser la découvrabilité des contenus culturels*, juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels> (visité le 19/08/2024).

2. *Overall Aims – InTavia*, URL : <https://web.archive.org/web/20231207162031/https://intavia.eu/overall-aims/> (visité le 19/08/2024).

On a donc d'abord des enjeux forts de réconciliation de données provenant de sources très diverses et de repérabilité que nous laisserons de côté, car nous les avons déjà évoqués, pour nous concentrer sur la conciliation entre les usages des chercheurs et d'un public non expert.

Pour parler de ce sujet, nous nous baserons sur un article écrit par J. Liem et al., « A Workflow Approach to Visualization-Based Storytelling with Cultural Heritage Data »<sup>3</sup> dans lequel ils placent la narration comme une stratégie de *design* essentielle pour que l'information, parfois complexe et plurielle dans le cas du patrimoine culturel, devienne intéressante et attrayante pour son public. Les auteurs rappellent par ailleurs qu'actuellement, les outils permettent soit de faire de la narration (penser aux outils d'expositions virtuelles par exemple) soit de faire de la curation, mais jamais les deux ensemble. Ils distinguent aussi trois étapes dans la création d'une narration : collecte de l'information et organisation, création de l'histoire et mise en forme ; l'objectif d'*InTaVia* est de concilier toutes ces étapes dans le même outil<sup>4</sup>.

Pour ce faire, *InTaVia* est structuré comme suit : récupération des données tangibles (objets culturels, collections, etc.) et intangibles (métadonnées sur les objets, biographies) provenant d'institutions variées. Elles sont ensuite réparties en trois canaux : une base *graph* (*knowledge graph*), une base relationnelle où les métadonnées sont agrégées en fonction de l'évènement auquel elles font référence (suivant le modèle *CIDOC-CRM*<sup>5</sup>) une base tierce qui tente d'agréger « le reste ». Les données passent ensuite par des outils de traitement du langage naturel (*NLP*) pour en extraire les informations utiles aux visualisations<sup>6</sup>. Une fois les données agrégées et traitées, l'outil propose à ses utilisateurs un outil de narration qui se divise en deux parties : d'abord la création des histoires et des visualisations à ces dernières à partir des données provenant d'*InTaVia* directement ou d'imports externes ; ensuite, leur mise en forme à l'aide d'une interface la plus simple possible, mais non restrictive en suivant les trois types de clés de lectures décrites plus haut. Pour rappel : vues multiples des objets ; organisation spatiale et organisation temporelle. L'immense avantage est ici que quand l'utilisateur ajoute une entité (par exemple une personnalité) dans son histoire, l'outil lui propose directement les entités potentiellement liées grâce à la structure en *knowledge graph*<sup>7</sup>.

Depuis : Liem, Kusnick, Beck, Windhager, Mayr « A workflow approach... »

3. Johannes Liem, Jakob Kusnick, Samuel Beck, F. Windhager et E. Mayr, *A Workflow Approach to Visualization-Based Storytelling with Cultural Heritage Data*, 17 oct. 2023, arXiv : 2310.13718[cs], URL : <http://arxiv.org/abs/2310.13718> (visité le 19/08/2024).

4. *Ibid.*, introduction.

5. Le modèle CIDOC-CRM est l'équivalent d'IFLA-LRM pour les musées

6. *Overall Aims – InTavia...*

7. Qui fonctionne selon le même principe que celui de Google décrit dans notre partie 1

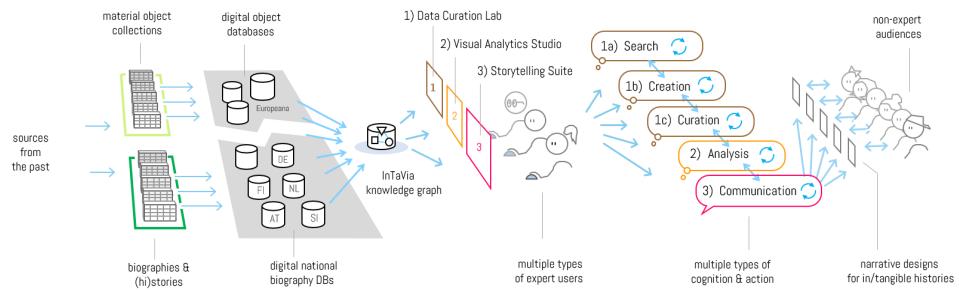


FIGURE 21 – Architecture du projet InTaVia

L’interface d’*InTaVia* (cf. images ci-après) concilie donc tous les usages : de l’utilisateur cherchant à connaître une thématique particulière, au conservateur de musée souhaitant créer une exposition en ligne en passant par le chercheur souhaitant simplement consulter les collections agrégées. Il parvient donc à concilier la tension entre trouvabilité et découvrabilité.

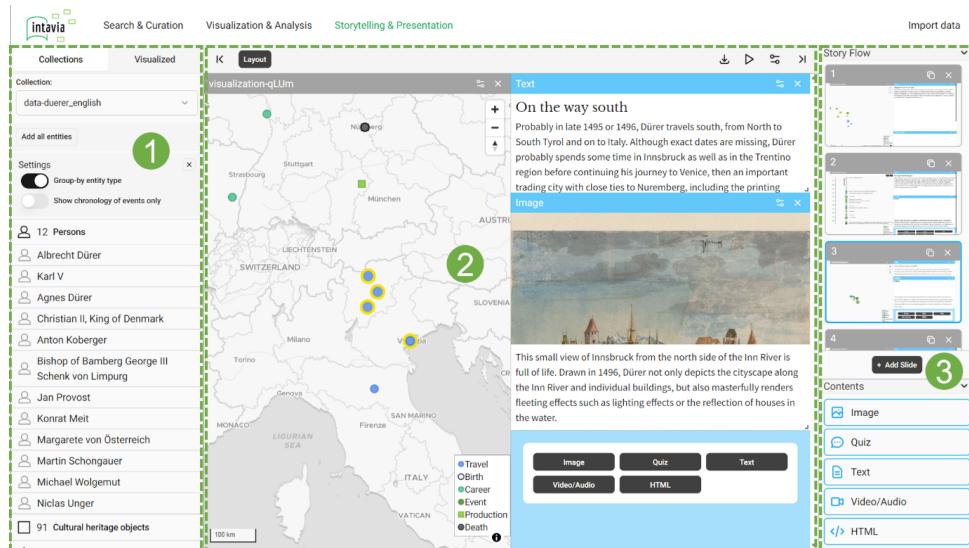


FIGURE 22 – L’interface de création des histoires d’InTaVia

Depuis : Liem, Kusnick, Beck, Windhager, Mayr « A workflow approach... »

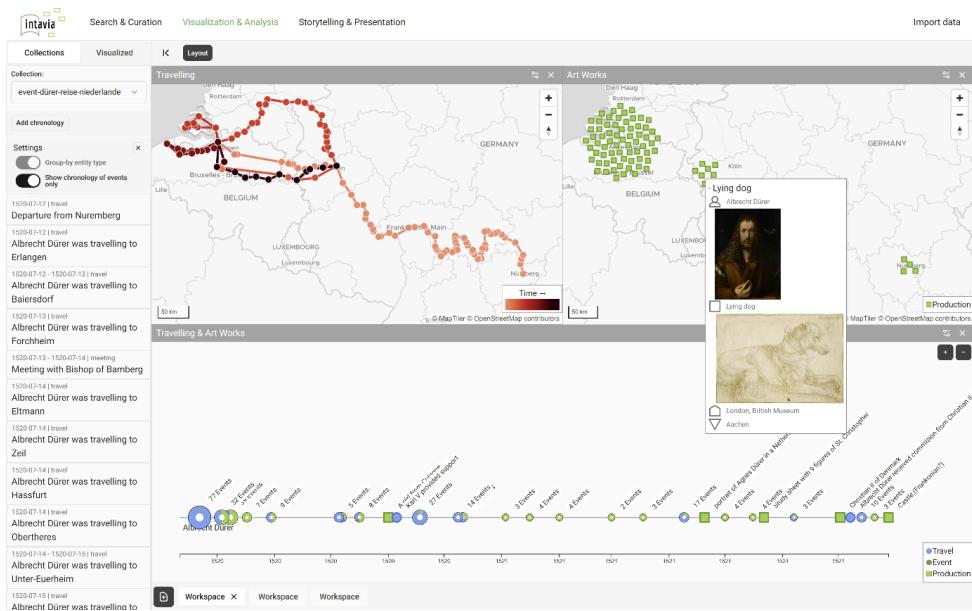


FIGURE 23 – Exemple d’histoire créée depuis l’interface d’InTaVia

## 2. Vers un nouveau *crowdsourcing* reposant sur l’ouverture des données

« Au Walters art museum, nous avons adopté cette approche [celle de l’*open data*, N.D.A] et nous avons mis nos manuscrits sur le web pour que tout le monde puisse les voir, toutes les données brutes, toutes les descriptions, toutes les métadonnées, sous une licence “Creative commons”. [...] Et le résultat, c’est que si vous lancez une recherche d’images dans Google en tapant “Illuminated manuscript Koran”, par exemple, 24 des 28 images que vous obtiendrez viennent de mon institution »<sup>8</sup>.

En avril 2012, William Noel, conservateur au Walter Art Museum, consacrait un *TED talk* au « Codex Perdu d’Archimède en apparence », mais en réalité, l’acmé de son intervention semble être le moment où il révèle que toutes les données du projet sont en accès libre. Et si l’on regarde la conférence avec cette clé de lecture en tête, on se rend compte qu’elle est parsemée de références à cette notion : des scribes médiévaux copiant les textes antiques, on passe aux internautes créant leur propre collection et s’emparant du patrimoine numérisé. Pour William Noel, non seulement l’*open data* est « un avantage pour l’humanité et ce genre de choses », mais aussi pour les institutions « parlons de choses égoïstes »<sup>9</sup>, selon lui : les gens vont au Louvre, car ils souhaitent y voir la Joconde, et ils veulent la voir, car ils la connaissent déjà, car ils ont déjà vu des milliers d’images

8. William Noel, *William Noel : Revealing the lost codex of Archimedes / TED Talk*, 12 mai 2021, URL : [https://www.ted.com/talks/william\\_noel\\_revealing\\_the\\_lost\\_codex\\_of\\_archimedes?subtitle=en](https://www.ted.com/talks/william_noel_revealing_the_lost_codex_of_archimedes?subtitle=en) (visité le 19/08/2024).

9. *Ibid.*, à 13 minutes 26secondes.

de l'œuvre, parfois détournées (on pense à l'œuvre de Duchamp<sup>10</sup>, mais aussi de façon plus contemporaine aux *memes*<sup>11</sup>). La constitution de « communs numériques »<sup>12</sup> revêt alors une importance capitale, non seulement dans la préservation, mais aussi dans la transmission<sup>13</sup> : permettre aux utilisateurs d'interagir avec le patrimoine (qui doit pour cela être ouvert) fait donc en sorte, entre autres choses, qu'il soit mieux repéré en ligne et plus visionné. On en effet est beaucoup plus enclin à suivre la recommandation de tiers de confiance (ici, d'autres internautes collaborant au projet) que celle d'une institution<sup>14</sup>.

Si nous intitulons cette partie « vers un nouveau *crowdsourcing* » c'est parce que nous avons observé que la participation en ligne des internautes avait évolué ces dernières années. Si avant les activités principales se résumaient plus en un *digital labor* : c'est-à-dire « la captation de la valeur générée par les activités des internautes en ligne »<sup>15</sup> avec des activités qu'Oomen et Aroyo classaient en six domaines en 2011<sup>16</sup> : correction/transcription, contextualisation, enrichissement, classification, co-curation et *crowdfunding*. Désormais, les activités en ligne des internautes semblent se tourner vers la notion de communs numériques<sup>17</sup>. On peut exemplifier ce propos avec le site *notrehistoire.ch* lancé en 2009 par la Fonsart<sup>18</sup> avec trois mots d'ordre : publier, participer et explorer<sup>19</sup>. Il propose à ses utilisateurs de participer à la création d'un patrimoine commun basé à la fois sur des archives institutionnelles et des archives personnelles. Il est structuré, ainsi que son interface, tel un réseau social en suivant les pratiques du *web 2.0* où l'on peut commenter, créer, partager et publier du contenu en utilisant les archives disponibles sur le site provenant d'une part d'institutions romandes et de l'autre de particuliers. L'interface permet donc de voir des publications d'internautes défiler toujours avec la possibilité d'interagir. On peut aussi choisir d'aller explorer différentes thématiques, voir celles qui sont les plus alimentées, profiter du classement chronologique ou des différents *tags* (identifiés par un

---

10. *L.H.O.O.Q.* - Centre Pompidou, URL : <https://www.centrepompidou.fr/fr/ressources/oeuvre/c5pXdk6> (visité le 19/08/2024).

11. Concept (texte, image, vidéo) massivement repris, décliné et détourné sur Internet de manière souvent parodique, qui se répand très vite - Larousse

12. E. Bermès, "De l'écran à l'émotion, quand le numérique devient patrimoine"..., p. 173.

13. *Ibid.*, p. 175.

14. O. Ertzscheid, *Économie des biens culturels, cours de 2e année de DUT information et communication option métiers du livre et du patrimoine...*

15. *Qu'est-ce que le digital labor ?*, URL : <https://larevuedesmedias.ina.fr/quest-ce-que-le-digital-labor> (visité le 19/08/2024).

16. Ariane Néroulidis, *Le crowdsourcing appliqué aux archives numériques : concepts, pratiques et enjeux*, Mémoire de Master, LYON, Université de Lyon, ENSSIB, 2015, URL : <https://www.enssib.fr/bibliothèque-numérique/documents/66008-le-crowdsourcing-appliquée-aux-archives-numériques-concepts-pratiques-et-enjeux.pdf> (visité le 19/08/2024), (cité par).

17. Un commun numérique est une ressource en ligne partagée, gérée collectivement par une communauté, qui repose sur des règles et des contributions ouvertes, favorisant l'accès et l'usage libre pour tous - Définition générée par Chat GPT et remaniée

18. Fondation pour la sauvegarde de la Radiotélévision, association créée en 2012 par la RTS

19. *À propos - notreHistoire.ch*, URL : <https://notrehistoire.ch/pages/a-propos> (visité le 19/08/2024).

mot-dièse dans les publications des internautes).

The screenshot shows a Facebook-style post by Claudio Abâcherli. The main image is a photograph of a rectangular stone sundial mounted on a wall. The sundial has '1621' at the top and various numbers and markings below. A black arrow points to a small hole in the center of the dial. Below the sundial, there's some foliage and a stone plaque with text that is partially visible. To the right of the image is a sidebar titled 'ACTIVITÉ RÉCENTE' (Recent Activity) which lists several users and their comments.

**ACTIVITÉ RÉCENTE**

- Armand Sin a publié [Course Sierre-Zinal 2014](#)
- Renata Roveretto a commenté [Sierre : l'Avenue](#)
- Renata Roveretto a publié [Fête des Vignerons 2019 avec la participation du canton de Soleure](#)
- Pierre-Marie Epiney a commenté [Sierre : l'Avenue](#)
- Charly-G. Arbelay a commenté [Sierre : l'Avenue](#)
- Claudio Abâcherli a commenté [Aubonne, Collège du Chêne](#)
- Claudio Abâcherli a commenté [Aubonne, Collège du Chêne](#)
- Renata Roveretto a commenté [Nouvelles motos](#)
- Michel Gasser a commenté [Locomotive de manœuvre CFF, Ee 3/4](#)
- Michel Gasser a commenté [Départ du train](#)

**Cadran solaire historique de la Grande Coronelle (qui a un petit frère)**

Ce très ancien cadran solaire, datant de 1621, se trouve sur une ferme du Jura bernois, sur le territoire de la commune de Sonvilier, dans la région dite de La Chaux-d'Ab...

FIGURE 24 – L’interface de notrehistoire.ch : un réseau social patrimonial

<https://notrehistoire.ch/feed>

Outre le fait que notrehistoire.ch brise les frontières, à la fois physiques entre des documents séparés et organisationnelles. Il faut, de fait, noter que les institutions perdent leur rôle de prescription et deviennent des contributrices à la constitution d'un *Lieu de mémoire commun*<sup>20</sup>. Comme Emmanuelle Bermès le rappelle dans son ouvrage : « leur nouveau défi [des institutions patrimoniales] est d'accompagner et de faciliter l'appropriation du patrimoine numérique par ses communautés bénéficiaires »<sup>21</sup>. Même si évidemment, les pratiques de *crowdsourcing* plus classiques identifiées plus haut ne disparaissent pas, il semble que ce nouveau type de pratique, grâce à des interfaces renouvelées, prenne une place de plus en plus importante.

20. Toujours en références aux ouvrages parrus sous la direction de Pierre Nora

21. E. Bermès, "De l'écran à l'émotion, quand le numérique devient patrimoine"..., p. 186.

### 3. L'intelligence artificielle comme porte d'accès au savoir, encore faut-il trouver la clé

Précisons ici que nous ne nous concentrerons que sur un seul cas d'usage de l'intelligence artificielle ici, le *RAG* (*retrieval augmented generation/génération augmentée de récupération*), car il nous semble le plus proche de notre sujet de découvrabilité dans le secteur patrimonial. Par ailleurs, nous avons déjà abordé un autre champ d'application de l'intelligence artificielle dans ce mémoire en parlant d'algorithmes de recommandation.

Comme pour ces derniers, une explication technique est indispensable pour cerner les enjeux autour de cette technologie. Un *RAG* est un grand modèle de langue (le plus connu étant *chat GPT*) qui, pour répondre à une question de l'utilisateur (on parle de *prompt*), utilise des données fournies préalablement en tant que source<sup>22</sup>. Cette approche combine donc les extraordinaires possibilités des modèles de langues dans la génération de réponses tout en corrigeant leur principal défaut : le manque d'indication des sources et le phénomène d'hallucination<sup>23</sup> ; en somme, leur manque de fiabilité. Pour les fonds patrimoniaux et leur découvrabilité, le potentiel d'une telle technologie est prometteur. Cela améliorerait grandement la recherchabilité en permettant aux utilisateurs de saisir, en langage naturel, leurs requêtes. De l'ère des équations de recherche, nous étions passés aux requêtes *Google-like* avec le *RAG*, nous passerions à l'ère du questionnement en langage naturel<sup>24</sup>. Car le changement de paradigme principal de l'intelligence artificielle dite générative est bien celui-là : ce ne sont plus les humains qui font l'effort de communiquer dans une langue adaptée aux ordinateurs, mais le contraire, ce qui marquerait un « passage de la communication homme-machine à la communication machine-homme »<sup>25</sup>. En termes de découvrabilité, cela signifierait qu'un chercheur/utilisateur du fonds de la RTS (par exemple) pourrait directement demander dans une interface (souvent un *chatbot* dans le cas du *RAG*) « tous les documents concernant l'histoire de la Radiodiffusion en Suisse » dans le fonds de la RTS, ce qui évidemment — outre le fait d'être un immense gain de temps — représente une perspective de recherchabilité incroyable, car une telle requête actuellement ne donnerait que peu de résultats, ce champ n'existant pas dans le

---

22. Stéphane Pouyllau et LLAMA2 + Ollama, *Quels usages du “Retrieval-augmented generation” en SHS ?*, HN Lab Log, Publisher : HN Lab, 17 mars 2024, URL : <https://hnlab.huma-num.fr/blog/2024/03/17/RAG/> (visité le 19/08/2024).

23. Dans le domaine de l'intelligence artificielle, une hallucination ou une confabulation est une réponse fausse ou trompeuse qui est présentée comme un fait certain ; par exemple, un chatbot qui génère un chiffre d'affaires pour une entreprise sans avoir de données à ce sujet. - Wikipédia

24. E. Bermès, *Le futur de la recherche documentaire : RAG time ! / Figoblog*, Figoblog, 30 mars 2024, URL : <https://figoblog.org/2024/03/30/le-futur-de-la-recherche-documentaire-rag-time/> (visité le 19/08/2024).

25. Hervé Pillaud, « Et si l'intelligence artificielle nous faisait changer de logique ? », *Paysans & société*, 405–3 (2024), Place : Paris Publisher : Revue Paysans et Société, p. 25-33, DOI : 10.3917/pes.405.0025, p. 7.

thésaurus.

## Les trois âges de la recherche documentaire

**Exemple :** besoin d'une archive illustrant le palais fédéral en été



FIGURE 25 – Les trois âges de la recherche documentaire, illustration réalisée par nos soins

Si la mise en place de *RAG* peut être vue comme une perspective passionnante pour les acteurs patrimoniaux, il n'en reste pas moins que cela pose de nombreux défis. Défi écologique (nous le détaillerons dans notre partie 3), défi éthique et juridique ensuite. La mise en place d'un *RAG* nécessite d'utiliser un grand modèle de langue (que les institutions patrimoniales ne développeront jamais en interne) provenant de sociétés privées, Google ou *Open AI* notamment, qui est ensuite adapté (« *fine tuné* ») avec les données internes pour être utilisé. Mais pour faire cela, il faut envoyer les données aux serveurs des entreprises (par le biais d'interfaces de programmation ou *API*), car il est très difficile d'entrainer localement ces modèles qui ont besoin d'une infrastructure importante et ne sont pas *open source*. Même si depuis peu *Open AI* et Google ont indiqué ne pas utiliser les données transférées pour entraîner leurs modèles<sup>26</sup>, ces dernières sont tout de même stockées sur leurs infrastructures ce qui pose des questions de gouvernance de la donnée et de confidentialité en cas d'attaque.

Notons d'ailleurs que pour ces sociétés, les données extrêmement bien structurées des institutions patrimoniales sont véritablement du pain bénit, en témoigne le récent partenariat qu'un consortium de trois sociétés spécialisées dans l'intelligence artificielle générative (*Mistral AI*, *Giskard* et *Artefact*) ont tissé avec la Bibliothèque nationale de France et l'Institut national de l'audiovisuel français<sup>27</sup>. La BnF précise d'ailleurs : « le monde a redécouvert que toutes les bibliothèques nationales comme la BnF sont des grands réservoirs de données. Le nôtre est probablement le plus grand réservoir de données propres et

26. Mathilde Rochefort, *OpenAI n'utilise plus les données des clients de son API pour former ses modèles*, mai 2023, URL : <https://siecledigital.fr/2023/05/09/openai-api-formation-modeles/> (visité le 21/08/2024).

27. Martin Clavey, *La BNF : un réservoir de données pour les IA*, Next, 27 juin 2024, URL : <https://next.ink/142051/la-bnf-un-reservoir-de-donnees-pour-les-ia/> (visité le 19/08/2024).

qualifiées au monde. D'un seul coup, ça intéresse donc nos petits camarades qui travaillent sur l'intelligence artificielle parce qu'au-delà du logiciel, il faut de la donnée pour les entraîner ». Ces « grands réservoirs » deviendront sûrement un enjeu très important dans les années à venir puisque les besoins en données de l'intelligence artificielle générative sont de plus en plus importants. Les chercheurs évoquent d'ailleurs la date de 2026 comme celle où toutes les données publiques de l'Internet auront été aspirées par les modèles en formation<sup>28</sup>. Même si beaucoup évoquent la possibilité de former ces modèles par des contenus générés par intelligence artificielle, il semble que cette piste ne donne pas de résultats très probants (pour l'instant, le domaine étant en évolution constante)<sup>29</sup>.

Il y a, enfin, un défi de repérabilité, ces technologies ne font pas de miracles : si une partie du fonds n'a que peu de métadonnées, elle ne sera pas renvoyée. Prenons l'exemple de la RTS ici, on a noté dans notre état des fonds que le sport et les émissions pour enfants ont été peu archivés, et quand c'est le cas avec des métadonnées minimales : si un modèle *RAG* est mis en place, ces collections resteront invisibilisées, car mal documentées et en petit nombre. Les algorithmes, conçus en grande partie dans les pays occidentaux, commettent bien plus d'erreurs sur des groupes ethniques moins représentés dans leurs données d'entraînement que les groupes majoritaires. Parmis les risques de l'IA, l'exemple de Robert Williams est ici tristement éclairant. En 2020, cet homme afro-américain, a été arrêté et a passé trente heures en détention parce qu'un logiciel d'intelligence artificielle l'avait identifié à tort comme un voleur de montre, sans que cette « preuve » ait été remise en question à temps<sup>30</sup>. Il y a ici un enjeu d'explicabilité algorithmique que nous traiterons aussi dans notre partie 3.

Au regard de ce qui a été écrit, il est essentiel, avant de se lancer dans la mise en production de *RAG* pour des collections patrimoniales, de réaliser un travail en profondeur sur les données et leur pondération. Dans le cas de la RTS, cela passerait par une transcription automatique de tous les programmes et la génération de résumés documentaires pour chacun (en utilisant comme données d'entraînement ceux déjà rédigés) ainsi que de mots-clés documentaires issus des thésaurus. Cela permettra un entraînement plus efficace (avec des coûts environnementaux et financiers réduits), car nécessitant moins

---

28. sans auteur, *Internet n'est pas assez développé pour former l'IA, mais une solution existe : les fausses données*, Forbes France, 29 juill. 2024, URL : <https://www.forbes.fr/technologie/internet-nest-pas-assez-developpe-pour-former-l-ia-mais-une-solution-existe-les-fausses-donnees/> (visité le 19/08/2024).

29. *Entraîner une intelligence artificielle avec des données générées par IA conduit à l'absurde - Le Temps*, URL : <https://www.letemps.ch/sciences/entrainer-une-ia-avec-des-donnees-d-ia-conduit-a-1-absurde?srsltid=AfmB0opRmg411Q16bXgFanx2YVuh7h6o3CeU05qkvmGvq9apQA1btIS> (visité le 19/08/2024).

30. *Etats-Unis : un Américain noir arrêté à tort à cause de la technologie de reconnaissance faciale*, URL : [https://www.lemonde.fr/international/article/2020/06/24/un-americain-noir-arrete-a-tort-a-cause-de-la-technologie-de-reconnaissance-faciale\\_6044073\\_3210.html](https://www.lemonde.fr/international/article/2020/06/24/un-americain-noir-arrete-a-tort-a-cause-de-la-technologie-de-reconnaissance-faciale_6044073_3210.html) (visité le 19/08/2024).

d’itérations tout en réduisant les biais d’invisibilisation décrits, car tous les documents seront documentés avec la même précision.

Concluons avec ce qu’écrit Emmanuelle Bermès dans un article de blog : « *Si ce genre de méthode doit révolutionner à terme la recherche documentaire et voir nos recherches par mots-clés disparaître au profit de prompts, comme la recherche par équation a disparu au profit de la recherche plein texte... On a intérêt à comprendre comment elles fonctionnent et à apprendre à les maîtriser. Car le prompting, c'est comme la recherche documentaire : ça pourrait paraître simple à première vue, mais c'est une compétence de la littératie numérique qui ne s'invente pas*<sup>31</sup>. »

---

31. E. Bermès, *Le futur de la recherche documentaire : RAG time ! / Figoblog...*

## **Troisième partie**

**Partie 3 : le code c'est la loi,  
régulations et limites à la  
découvrabilité**



## « Le code : c'est la loi »

« *Code is law* », le code, c'est la loi<sup>32</sup>. Dans un article paru en 2000, Lawrence Lessig met le doigt sur un enjeu central du web : sa régulation. Il explique : le web, à la différence de nos sociétés, n'est pas régulé par des textes de loi et une constitution. Non, ce qui régule le web c'est le code, c'est lui qui détermine s'il est facile ou pas d'accéder à un contenu, qui détermine si vous allez pouvoir découvrir cet incroyable vase grec, c'est lui encore qui décidera de votre orientation (l'exemple de *Parcoursup* le montre). Si les règlements européens récents, tel que celui sur la protection des données tentent de réguler cet écosystème, force est de constater qu'ils sont limités et ne touchent qu'une infime fraction des interactions que nous avons avec ce dernier. Et comme le souligne Laurence Lessig, cette absence de régulations est parfois bénéfique : c'est parce que le protocole *TCP/IP* (qui permet l'échange de données) rend difficile d'associer une adresse IP (celle d'un ordinateur) à une personne que le web est un espace sans précédent de liberté d'expression ; mais c'est aussi pour cette raison que la haine en ligne est difficile à endiguer<sup>33</sup>.

Revenons aux origines du web pour comprendre pourquoi l'écosystème a été pensé, dès son origine, de façon si libertaire. Si internet a d'abord été, dans le contexte de la guerre froide, vu comme un moyen de relier de façon décentralisée différents ordinateurs afin d'améliorer la résilience des États-Unis en cas de guerre nucléaire<sup>34</sup>, le projet sera, finalement, surtout utilisé par les universités américaines (en témoigne la première carte du réseau visible ci-après), notamment pour optimiser l'utilisation des très coûteux ordinateurs de l'époque.

---

32. Lawrence Lessig, *Code is Law – Traduction française du célèbre article de Lawrence Lessig – Framablog*, Framablog.org, janv. 2000, URL : <https://framablog.org/2010/05/22/code-is-law-lessig/> (visité le 19/08/2024), (nous avons consulté la version française disponible sur Framablog).

33. *Ibid.*, §8 et § 9.

34. « ARPANET », *Wikipédia* (, juill. 2024), URL : <https://fr.wikipedia.org/w/index.php?title=ARPANET&oldid=217010020> (visité le 19/08/2024).

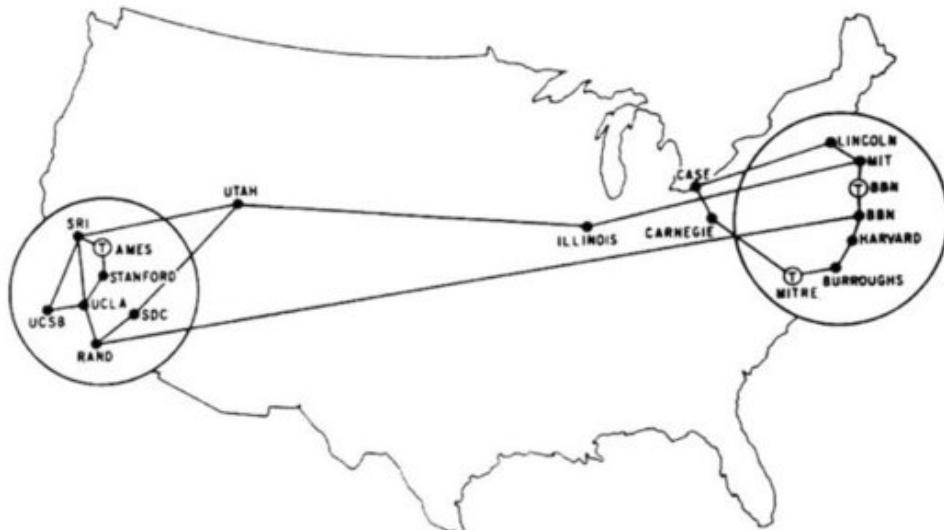


FIGURE 26 – Carte d'ARPANET en 1972

Depuis : [https://www.accessoweb.com/  
La-carte-de-Arpanet-en-1972-les-debuts-d-Internet\\_a8123.html](https://www.accessoweb.com/La-carte-de-Arpanet-en-1972-les-debuts-d-Internet_a8123.html)

Les mouvements libertaires, dont Stewart Brand<sup>35</sup>, l'un des pionniers d'internet faisait partie, s'intéressent à cette infrastructure, car ils se méfiaient des structures centralisées et voyaient dans Internet un potentiel d'interactions libres du fait qu'il était, dès sa conception, conçu sur un modèle décentralisé. Brand contribue à populariser l'idée que les ordinateurs personnels pouvaient contribuer à l'idéal libertaire en permettant à chacun de devenir autonome au sein d'un réseau mondial sans « tête »<sup>36</sup>.

Mais, pour revenir à l'article de Lessig, si Internet et le Web<sup>37</sup> ont été pensés dès leurs débuts comme des espaces libres, cette approche n'est pas figée, « car le code n'est pas figé »<sup>38</sup>. Par exemple, d'autres éléments peuvent être ajoutés pour permettre d'identifier à coup sûr l'auteur d'une publication. Comme le code détermine les valeurs d'internet, poursuit l'auteur, c'est en intervenant sur ce dernier qu'on peut les modifier. Laurence Lessig poursuit en contradisant les arguments très actuels (le patron de X s'en est fait le parangon), selon lesquels on devrait choisir entre une régulation (par l'État par exemple)

35. Il est l'objet du livre de Fred Turner, « Aux sources de l'utopie numérique. De la contre-culture à la cyberculture, Stewart Brand un homme d'influence », trad. de l'anglais par Laurent Vannini, Caen, C&F Éd., 2012, 432 p.

36. Samuel Goëta, « Fred Turner, Aux sources de l'utopie numérique. De la contre-culture à la cyberculture, Stewart Brand un homme d'influence : Trad. de l'anglais par Laurent Vannini, Caen, C&F Éd., 2012, 432 p. » *Questions de communication*–23 (31 août 2013), p. 493-495, DOI : 10.4000/questionsdecommunication.8619, § 5.

37. Internet désigne l'infrastructure physique qui héberge (notamment) le web

38. L. Lessig, *Code is Law – Traduction française du célèbre article de Lawrence Lessig – Framablog...*, § 6.

---

et son absence : or, le code régule. Soit il protège la vie privée. Soit il promeut la surveillance. Soit il laisse la haine en ligne être diffusée. Soit il tente de la limiter (X est un excellent exemple en la matière). L'auteur conclut son article précurseur (écrit en 2000), en expliquant que si l'État n'intervient pas, la régulation est placée du côté d'acteurs privés qui ont des objectifs bien différents<sup>39</sup>. L'article illustre bien trois enjeux essentiels, que ce soit pour la découverabilité et la diversité culturelle ou le web en général : le code c'est la loi, il faut donc comprendre ses biais et problématiques afin de les contrer ; le code c'est la loi, les institutions doivent donc s'en emparer, ou pour le réguler, ou pour utiliser son potentiel et ne pas passer à côté ; et enfin, le code c'est la loi, les personnes qui l'écrivent doivent donc être conscientes des enjeux que sous-tendent leurs actions. L'objet de cette partie sera donc d'explorer les éventuels biais et potentialités du web en matière de découverabilité (car nous ne pouvons explorer tous les enjeux liés à ce écosystème), les questions institutionnelles autour de ce dernier, pour finir, nous nous intéresserons aux angles morts de la notion.

---

39. *Ibid.*, § 28.



# Chapitre 9

## Le web : prison ou fenêtre ouverte sur le monde ?

### 1. L'hyperchoix

L'hyperchoix est une notion centrale pour commencer cette partie sur le web. On peut la définir comme le fait de faire un choix parmi un trop grand nombre d'options, le rendant, de fait, difficile. Dans son ouvrage « *L'attaque des clones* »<sup>1</sup>, Emmanuel Durand l'exemplifie avec *Gangnam Style*, vidéo sortie en 2012 et qui en un mois a battu tous les records de visionnages sur *YouTube*, devenant la première vidéo cumulant 1 milliard de vues qui, toujours selon l'auteur, vient révéler deux choses : l'incroyable possibilité de diffusion pour des artistes en dehors des circuits traditionnels et le caractère aléatoire de la notoriété « *buzz* » qui en découle parfois. Pour lui, cette notion illustre le potentiel presque infini du web à devenir diffuseur d'œuvres qui ne l'auraient pas été autrement, dans le monde entier<sup>2</sup>. C'est une révolution : avant l'arrivée d'internet, l'accès aux œuvres de l'esprit était limité, même avec l'émergence, dans le courant des XIXe et XXe siècles, des industries culturelles que sont la photographie, la presse ou encore le cinéma. Il était difficile pour des artistes d'acquérir une notoriété et d'être diffusé sans l'appui de grands éditeurs. Internet aurait donc accompli une véritable utopie : celle de l'accès pour tous et toutes (pas totalement, seuls environ 50 % de la population mondiale ayant accès à internet)<sup>3</sup> à des œuvres et à des savoirs de façon quasi illimitée. Cela contribue, si l'on

---

1. E. Durand, *L'attaque des clones...*

2. Id., « Chapitre 1 - L'ère de l'hyperchoix », dans *L'attaque des clones*, Paris, 2016 (Nouveaux Débats), p. 19-28, URL : <https://www.cairn.info/1-attaque-des-clones--9782724619805-p-19.htm> (visité le 19/08/2024), § 1 et § 4.

3. « Utilisation d'Internet », *Wikipédia* (, avr. 2024), URL : [https://fr.wikipedia.org/w/index.php?title=Utilisation\\_d%27Internet&oldid=214019107](https://fr.wikipedia.org/w/index.php?title=Utilisation_d%27Internet&oldid=214019107) (visité le 19/08/2024).

suit le rapport mondial de l'UNESCO intitulé « *Repenser les politiques culturelles* »<sup>4</sup>, à réduire les contraintes, à la fois sociales, géographiques et culturelles au sein des nations tout en ouvrant au niveau mondial le savoir et sa découverte.

Il est vrai que le web ainsi que l'essor de l'informatique personnelle permettent aux créateurs de publier de façon presque gratuite, tout en leur donnant la possibilité de créer différemment. Par exemple, nous avons tous la possibilité de nous improviser monteur de vidéos, créateur de musique, illustrateur... Le tout de façon très simple et avec des coûts très réduits. Cela a eu pour effet de remettre en cause (au moins en partie) le rôle des industries culturelles et notamment les diffuseurs, qui auparavant décidaient de ce qui serait ou ne serait pas dans le monde culturel<sup>5</sup>.

Mais cette facilité à publier et à mettre en ligne, déjà bien explorée dans ce mémoire, peut aussi être un problème : celui de la masse. Comment faire les bons choix ? Comment repérer les Mozart de demain ? Qui plus est quand chaque choix réalisé renvoie lui-même, avec le système d'hyperliens, vers d'autres choix potentiels<sup>6</sup> et à une époque où près de la moitié du trafic mondial serait assuré par des robots et où ils sont en capacité de générer des contenus à volonté<sup>7</sup> ?

Il faut donc poser la question de la sélection dans la prescription, qui était auparavant la distinction au sein d'une production, et qui devient un choix répondant aux attentes d'un consommateur au sein d'une offre pléthorique<sup>8</sup>. Mais aussi celle de l'évaluation, qui n'est plus l'avis d'un expert désignant une valeur en recommandant ou non un contenu, mais une liste d'avis motivés par des critères, soit qualitatifs, « les plus aimés », soit quantitatifs, « les plus vus ». Car si l'écosystème numérique a permis de court-circuiter les systèmes de diffusion traditionnels, ces derniers n'ont pas totalement disparu et ont été remplacés par des groupes, en immense partie américains, qui tentent de rassurer leur public avec des « discours d'ONG »<sup>9</sup>. Mais qui, quoiqu'on puisse en dire, ont besoin de trafic pour vivre, car ils reposent sur des modèles publicitaires et sur leurs capacités

---

4. *Re/penser les politiques culturelles : la créativité au cœur du développement, Rapport mondial Convention 2005, 2018 - UNESCO Digital Library*, URL : <https://unesdoc.unesco.org/ark:/48223/pf0000260601> (visité le 22/08/2024), cité dans Durand Emmanuel, *l'attaque des clones...* § 10.

5. Id., « Chapitre 1 - L'ère de l'hyperchoix »..., § 19.

6. *Hyperchoix et prescription culturelle*, URL : <https://www.fabula.org/actualites/64314/colloque-international-hyperchoix-et-prescription-culturelle.html> (visité le 19/08/2024).

7. O. Ertzscheid, *Du Web sémantique au Web synthétique*, oct. 2023, URL : <https://affordance.framasoft.org/2023/10/du-web-semantique-au-web-synthetique/> (visité le 23/08/2024).

8. *Ibid.*

9. Françoise Laugée, *La « viralité » ou l'illusion d'hyperchoix : « l'information qu'il nous faut »*, La revue européenne des médias et du numérique, Section : Articles & chroniques, 21 mars 2013, URL : <https://la-rem.eu/2013/03/la-viralite-ou-lillusion-dhyperchoix-linformation-quil-nous-faut/> (visité le 19/08/2024), p. 3.

à être prescripteurs. On parle de « capitalisme linguistique »<sup>10</sup>. C'est-à-dire, qu'au lieu de vendre un produit pour générer des profits, comme c'est le cas de manière classique, ces entreprises, et Google au premier chef, vendent des mots. Ces derniers ont aussi un cours en bourse : ainsi, être placé en haut des résultats de recherche concernant le mot « football » sera plus cher pendant la coupe du monde.<sup>11</sup>.

On a donc un hyperchoix d'une part caractérisé par une quantité informationnelle immense, et de l'autre, par une « hyperindividualisation »<sup>12</sup>, qui vient la canaliser (hyperindividualisation que les algorithmes de recommandation, qui nous connaissent parfois mieux que nous mêmes illustrent bien). La question qu'il convient de poser est celle de la réalité derrière la théorie : est-ce que le web a réduit ou augmenté la diffusion de la culture dans toute sa diversité ? C'est ce que nous tenterons d'observer dans notre prochaine partie en partant du concept de longue traîne (*long tail*).

## 2. Une longue traîne ou une courte tête ?

Le terme de longue traîne (*long tail*) a été proposé en 2004 par Chris Anderson qui constatait alors que le web pouvait favoriser l'augmentation de la diffusion des contenus peu ou pas diffusés auparavant : de niche<sup>13</sup>. Vingt ans après, il convient de tenter de l'analyser et de l'objectiver. Cela nous sera utile pour poursuivre notre réflexion sur l'écosystème qu'est le web et ses spécificités sur le plan de la découvrabilité. Ce que le concept de longue traîne vient exprimer, c'est la grande différence entre l'espace physique, limité, et l'espace numérique, affranchi de toute contrainte spatiale. Pensons à l'exemple d'une librairie : dans un espace donné, elle sera capable d'afficher une vingtaine de milliers d'ouvrages, souvent dans la langue locale<sup>14</sup>. On a donc : une offre qui s'élargit d'une part et de l'autre une recommandation qui devient plus personnalisée<sup>15</sup>.

Les chiffres semblent montrer que l'effet *long tail* serait fantasmé et que ce qui est plutôt à l'oeuvre est son exact contraire : l'effet *short head* : la majorité des consultations se feraient sur une partie infime des contenus. On avance souvent la proportion de 80/20 :

10. Frédéric Kaplan, *Quand les mots valent de l'or*, Le Monde diplomatique, 1<sup>er</sup> nov. 2011, URL : <https://www.monde-diplomatique.fr/2011/11/KAPLAN/46925> (visité le 19/08/2024).

11. *Ibid.*

12. F. Laugée, *La « viralité » ou l'illusion d'hyperchoix...*, p. 3.

13. Pierre-Jean Benghozi et Françoise Benhamou, « Longue traîne : levier numérique de la diversité culturelle ? », *Culture prospective*, 1–1 (2008), Place : Paris Publisher : Ministère de la Culture - DEPS, p. 1-11, DOI : 10.3917/culp.081.0001, § 8.

14. *Ibid.*, § 11 et § 12.

15. Marc Bourreau, Sisley Maillard et François Moreau, « Une analyse économique du phénomène de la longue traîne dans les industries culturelles », *Revue française d'économie*, XXX–2 (2015), p. 179-216, DOI : 10.3917/rfe.152.0179, § 17.

80 % des contenus rassembleraient 20 % des consultations et 20 % des contenus 80 % des consultations<sup>16</sup>. Il faut cependant nuancer ces chiffres : s'ils restent globalement vrais, il faut tout de même noter que 20 % des contenus sur le web représentent une diversité bien plus importante que ce qui pouvait être le cas avant l'informatisation. La proportion est restée sensiblement la même, mais elle masque le fait que la variété totale de contenus consultés a augmenté de façon très importante<sup>17</sup>. Dans tous les cas, il est très difficile de conclure à la réalité ou non de cet effet de longue traîne, les nombreuses études sur le sujet étant assez contradictoires et très dépendantes du secteur culturel concerné (on évoquera le cas spécifique du patrimoine culturel juste après)<sup>18</sup>.

On peut néanmoins expliquer les raisons de la limitation de l'effet *long tail* observées, grâce à l'article de Marc Bourreau, Sisley Maillard, François Moreau « Une analyse économique du phénomène de la longue traîne dans les industries culturelles »<sup>19</sup>. La première a été formulée par le sociologue MacPhee en 1963 : les gens moins familiers à un marché (par exemple la musique) qui représentent la majorité des consommateurs vont souvent diriger leur choix vers des valeurs plus sûres, déjà bien établies ; les experts, minoritaires, vont eux ventiler effectivement leurs choix vers des produits de niche, mais vont tout de même continuer à consommer des produits populaires. Donc *in fine*, les produits de niches resteront plus rarement consultés, comme dans l'univers physique<sup>20</sup>. La deuxième raison a déjà été évoquée dans ce mémoire : il s'agit du concept d'économie de l'attention, quand un utilisateur a trop de choix, cela impose un coût cognitif élevé, il va donc préférer se tourner par mimétisme, vers ce qui lui est recommandé : soit par un tiers (ou par son équivalent informatique que sont les classements « titres les plus vus » ou « titres les plus aimés » par exemple), soit par un algorithme.<sup>21</sup> Troisième raison au manque de visibilité des contenus de niches : le manque d'information (selon une étude d'Hendricks et Sorensen)<sup>22</sup>. Ce serait le symptôme visible d'une limite qui reste importante, celle de l'exposition médiatique des titres qui reste réservée à une petite partie des producteurs de contenus culturels, notamment dans les médias traditionnels (limités par leurs grilles) conservant toujours un rôle de prescripteurs important<sup>23</sup>.

Pour revenir au domaine qui nous intéresse, le patrimoine culturel, si les études le concernant sont peu nombreuses et le climat bien moins concurrentiel que celui de la musique par exemple ; on peut néanmoins tirer quelques conclusions grâce à un article

---

16. *Ibid.*, § 10.

17. *Ibid.*, § 15.

18. *Ibid.*, tableau 1.

19. déjà cité plusieurs fois

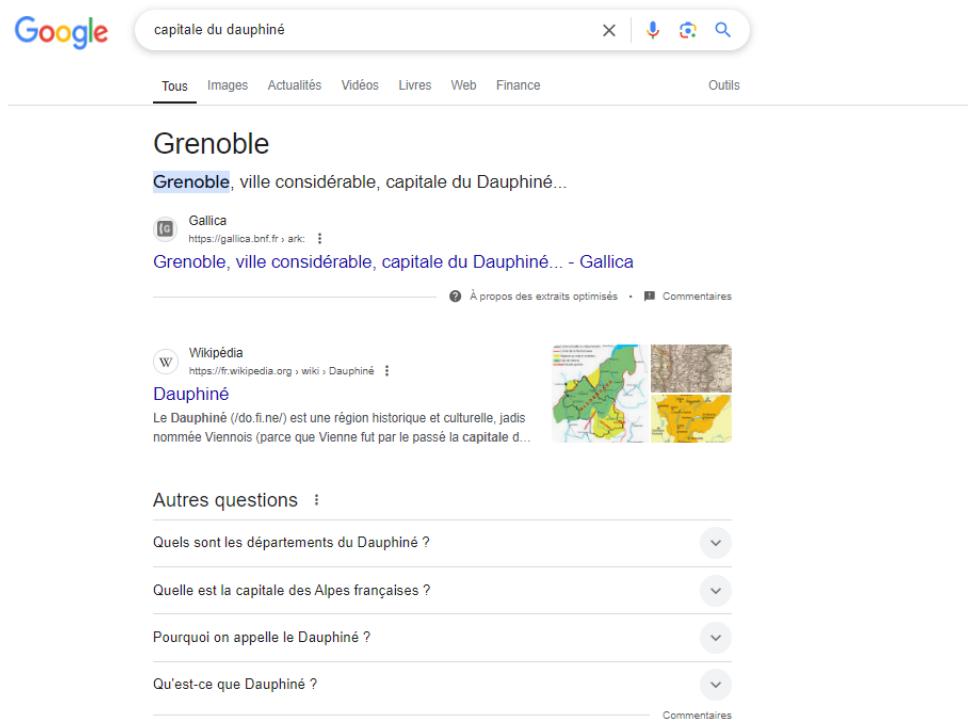
20. *Ibid.*, § 29.

21. *Ibid.*, § 39.

22. *Ibid.*, § 40.

23. *Ibid.*, § 41.

paru dans le *Bulletin des bibliothèques de France (BBF)* « La découvrabilité des collections numériques patrimoniales sous l'angle des usages de Gallica » (Bastard et Laborderie) <sup>24</sup>. Les auteurs y notent que 52 % de la collection disponible en 2021 n'avait pas été consultée au cours de l'année, ce qui peut paraître important quoique bien plus faible que le ratio de 80/20 évoqué plus haut. Sur une année, seuls 20 % des pages de presse (qui représente pourtant 76 % de la collection numérisée) a été consultée, alors que 79 % des livres numérisés l'ont été. La proportion documents consultés/documents disponibles atteint même 97 % pour les vidéos et 91 % pour les cartes<sup>25</sup>. Le phénomène de longue traîne est donc, semble-t-il, bien plus prégnant dans les usages numériques de Gallica que dans d'autres industries culturelles (les documents les plus consultés ont tout au plus 30 000 visites soit 1 % du trafic !), et l'on peut tenter de l'expliquer par plusieurs raisons. La première est l'excellente repérabilité des collections de la bibliothèque nationale en ligne, qui sont souvent recommandées par les moteurs de recherche (en témoigne l'image ci-après).



La deuxième raison que l'on peut noter est l'impossibilité pour les utilisateurs de voir les « documents les plus consultés », les documents mis en avant sur Gallica le sont par l'équipe éditoriale du site, jamais par rapport à leur audience rendant impossible l'effet de mimétisme décrit plus haut. Poursuivons avec le fait que Gallica est consultée en majorité par des experts ; de fait, selon une enquête de 2020 menée par l'Observatoire des publics de la Bibliothèque <sup>26</sup>, un tiers des usagers du site seraient des chercheurs, un autre tiers

24. I. Bastard et A. Laborderie, *La découvrabilité des collections numériques patrimoniales sous l'angle des usages de Gallica...*

25. *Ibid.*, § 8.

26. Comme l'écrivent les auteurs, ces résultats ne sont pas forcément le reflet des publics réels de

serait composé d'amateurs passionnés de science et de savoir (généalogistes, historiens amateurs, etc.) et le tiers restant se répartirait entre professionnels des bibliothèques et visiteurs ayant fréquenté l'établissement. Or, comme le montrent les travaux de MacPhee cités plus haut, les experts sont les plus enclins à consulter des contenus « de niche ». Enfin, comme l'exposition médiatique des contenus numérisés dans Gallica est quasi nulle comparée à d'autres secteurs culturels (même si le blog et les réseaux sociaux du site sont très actifs), cela ne contribue pas à en faire émerger certains au profit d'autres. On pourrait se risquer à écrire que la différence fondamentale entre Gallica et les autres industries culturelles – qui fait que l'effet longue traîne s'observe de façon assez clivante – est que le site n'est pas construit selon des logiques marchandes : l'objectif de la bibliothèque nationale n'est ni de vendre de l'espace publicitaire ni de faire rester les internautes sur son site, elle n'a donc aucun intérêt à favoriser un contenu plutôt qu'un autre. En effet, comme évoqué dans l'introduction, si le code est la loi, il s'agit bien de choix de la part des institutions ou des entreprises que de l'orienter vers telle ou telle direction. Nous verrons dans la partie suivante consacrée à la notion de bulle de filtres (et donc à la recommandation algorithmique) que cela s'applique aussi tout à fait.

### 3. Lutter contre la « bulle de filtre »

Depuis quelques années, le phénomène de « Bulle de Filtre » théorisé en 2011 par Eli Pariser, fait énormément parler de lui. Il se définit comme un enfermement algorithmique des personnes par le biais d'une personnalisation trop importante. Il nous semble important de nous attarder en détails sur ce concept, car la découvervabilité est souvent évoquée comme une réponse aux problèmes posés par la bulle de filtre et qui sont de deux ordres : premièrement un auto-renforcement des opinions politiques et clivages sociaux ; et deuxièmement, une perte de diversité culturelle.

Commençons par évoquer brièvement la problématique de radicalisation politique, qui est bien décrit par Antoinette Rouvroy et Thomas Berns en 2013 dans leur article sur la *gouvernementabilité algorithmique*, qu'ils définissent comme un double mouvement composé de la création d'un « double statistique » du monde « qui redessine les hiérarchies classiques » et « l'évitement de toute confrontation avec les individus dont les occasions de subjectivation se trouvent raréfiées »<sup>27</sup>. En d'autres termes, la création de régime de vérités pluriels qui ne se rencontrent très rarement car chaque individu sera enfermé algorithmiquement dans « son » régime de vérité. Ce phénomène s'est illustré lors du Gallica, mais plutôt de ceux désireux d'améliorer le service et qui le connaissent donc assez bien.

27. Antoinette Rouvroy et Thomas Berns, « Gouvernementalité algorithmique et perspectives d'émancipation. Le disparate comme condition d'individuation par la relation ? », *Réseaux*, 177–1 (2013), Place : Paris Publisher : La Découverte, p. 163-196, DOI : 10.3917/res.177.0163.

retentissant scandale dit « Cambridge Analytics » qui a éclaté au grand jour en 2018, révélant que les données d'entre 30 et 70 millions d'utilisateurs de Facebook ont été utilisées à leur insu afin d'influer sur leur vote à la présidentielle en ciblant la publicité électorale ou en modifiant les déplacements des candidats républicains<sup>28</sup>.

Poursuivons avec la seconde problématique posée par la bulle de filtre : la perte de diversité culturelle posée par l'enfermement des utilisateurs dans des groupes définis. Dans leur article de 2023, « De l'information aux industries culturelles, l'hypothèse chahutée de la bulle de filtre »<sup>29</sup>, Joëlle Farchy et Steven Tallec reviennent sur ce concept afin de tenter de voir si l'hypothèse formulée en 2011 par Eli Pariser « souvent sur base d'anecdotes »<sup>30</sup> est vérifiable par des travaux computationnels et empiriques. Il nous semble utile ici de résumer leurs conclusions, car avoir une compréhension fine de la notion de bulle de filtre est essentiel pour bien comprendre ce que peut, ou pas, la découvrabilité pour la contrer. Ils commencent par évoquer une étude de Robert Epstein et Ronald Robertson<sup>31</sup>, qui a prouvé que si l'on soumet un groupe d'individus à un moteur de recherche dont les résultats sont orientés vers un candidat en particulier, celui-ci sera plus enclin à voter pour ce dernier ; puis poursuivent avec une étude sur les réseaux sociaux<sup>32</sup> qui montre que, non seulement la principale source d'information des personnes étudiées sont les réseaux sociaux, mais qu'en plus ces derniers sont effectivement vecteurs de contenus avec lesquels l'utilisateur est en accord. C'est évidemment relié au concept d'économie de l'attention et au modèle économique des plateformes : puisque leur objectif est de faire rester le plus longtemps possible les utilisateurs, leur montrer des contenus avec lesquels ils sont en accord est profitable. En outre, cela permet d'alimenter de façon plus fine la publicité ciblée<sup>33</sup>. Les mêmes résultats sont observés sur *YouTube*, qui est décrit par Zeynep Tufekci comme un « grand radicalisateur »<sup>34</sup> qui amplifierait la visibilité de vidéos

---

28. « Ce qu'il faut savoir sur Cambridge Analytica, la société au cœur du scandale Facebook », (, 22 mars 2018), URL : [https://www.lemonde.fr/pixels/article/2018/03/22/ce-qu-il-faut-savoir-sur-cambridge-analytica-la-societe-au-c-ur-du-scandale-facebook\\_5274804\\_4408996.html](https://www.lemonde.fr/pixels/article/2018/03/22/ce-qu-il-faut-savoir-sur-cambridge-analytica-la-societe-au-c-ur-du-scandale-facebook_5274804_4408996.html) (visité le 19/08/2024).

29. Joëlle Farchy et Steven Tallec, « De l'information aux industries culturelles, l'hypothèse chahutée de la bulle de filtre », *Questions de communication*, 43–1 (2023), Place : Nancy Publisher : Éditions de l'Université de Lorraine, p. 241-268, URL : <https://www.cairn.info/revue-questions-de-communication-2023-1-page-241.htm> (visité le 19/08/2024).

30. *Ibid.*, § 5.

31. Robert Epstein et Ronald E. Robertson, « The search engine manipulation effect (SEME) and its possible impact on the outcomes of elections », *Proceedings of the National Academy of Sciences*, 112–33 (août 2015), DOI : 10.1073/pnas.1419828112 in J. Farchy et S. Tallec, « De l'information aux industries culturelles, l'hypothèse chahutée de la bulle de filtre »...§ 15

32. Eytan Bakshy, Solomon Messing et Lada A. Adamic, « Exposure to ideologically diverse news and opinion on Facebook », *Science*, 348–6239 (juin 2015), p. 1130-1132, DOI : 10.1126/science.aaa1160 in J. Farchy et S. Tallec, « De l'information aux industries culturelles, l'hypothèse chahutée de la bulle de filtre »...§ 16

33. *Bulles de filtre et chambres d'écho - Fondation Descartes*, URL : <https://www.fondationdescartes.org/2020/07/bulles-de-filtre-et-chambres-decho/> (visité le 19/08/2024).

34. Zeynep Tufekci, « Opinion | YouTube, the Great Radicalizer », *The New York Times* (, mars

sensationnalistes et complotistes pour capter l'attention de son public.

S'il est clair, pour les auteurs, qu'on ne peut nier le phénomène, ces derniers nuancent cependant son impact réel, car les études ne portent à chaque fois que sur un canal de communication et non sur l'environnement médiatique global des personnes, qui ont — de toute manière — tendance à s'enfermer d'eux-mêmes dans des bulles de filtres, car ils écartent les opinions qu'ils ne souhaitent pas voir<sup>35</sup>. De même qu'un lecteur de *L'Humanité* n'aurait jamais l'idée d'acheter le *Figaro*, il n'aura pas non plus envie de voir des articles qui vont à l'encontre de ses valeurs en ligne. Les auteurs de l'article évoquent aussi un article de 2015<sup>36</sup> qui, en s'appuyant sur un échantillon de 10 millions d'utilisateurs de Facebook, a démontré que ce sont les comportements individuels qui influencent le plus les opinions politiques. Notons toutefois que cet article a été écrit par des chercheurs de... Facebook ! Joëlle Farchy et Steven Tallec observent aussi le fait que les « internautes enfermés [sont] minoritaires » : 1 % des utilisateurs de Twitter ont ainsi consulté 80 % des fausses informations selon une étude de 2019<sup>37</sup> ; comme elles sont générées par la sphère complotiste, le phénomène de bulle de filtre fait que — justement — elles y restent.

En fin de compte, l'article confirme l'existence de bulles de filtres, mais en proposant une analyse méthodique, il remet aussi en question les craintes exprimées de radicalisation de la société. Il est en revanche intéressant de noter que la suite de l'article s'intéresse à la question de la diversité culturelle. Le principe est similaire : puisque l'objectif des plateformes (et sites marchands vendant des contenus culturels) est de conserver leur public, vont-elles donner à voir uniquement les choses dont elles sont sûres que leur public appréciera, et donc plutôt des choses très connues et peu diverses ? Par ailleurs, vont-elles mettre en avant certains contenus qu'elles produisent elles-mêmes (Netflix est aussi producteur par exemple) ?

Là encore, l'article nuance en prenant deux exemples : Spotify et Netflix, le premier au catalogue immense (80 millions de titres) et l'autre au catalogue plus réduit (5 272 titres) ; pour le premier, des études ont clairement démontré que les radios générées à la

---

2018), URL : <https://www.nytimes.com/2018/03/10/opinion/sunday/youtube-politics-radical.html> (visité le 22/08/2024) in J. Farchy et S. Tallec, « De l'information aux industries culturelles, l'hypothèse chahutée de la bulle de filtre »...§ 18

35. R. Kelly Garrett, « Politically motivated reinforcement seeking : Reframing the selective exposure debate », *Journal of Communication*, 59–4 (2009), p. 676-699, DOI : 10.1111/j.1460-2466.2009.01452.x in J. Farchy et S. Tallec, « De l'information aux industries culturelles, l'hypothèse chahutée de la bulle de filtre »...§ 26

36. E. Bakshy, S. Messing et L. A. Adamic, « Exposure to ideologically diverse news and opinion on Facebook »...

37. Quentin Grossetti, Cédric du Mouza et Nicolas Travers, « Community-Based Recommendations on Twitter : Avoiding the Filter Bubble », dans 2019, p. 212-227, DOI : 10.1007/978-3-030-34223-4\_14 in J. Farchy et S. Tallec, « De l'information aux industries culturelles, l'hypothèse chahutée de la bulle de filtre »...§ 27

demande de l'utilisateur ne favorisaient en rien la découverte ; en revanche les playlists « découvertes de la semaine » jouent bien leur rôle (comme vu page 37)<sup>38</sup>. Pour ce qui est du second, il faut noter que la page d'accueil ne propose qu'une petite fraction du catalogue (entre 11 et 20 %)<sup>39</sup> et qu'une part encore plus faible est réellement consultée. En revanche, les utilisateurs sont ciblés de façon extrêmement fine et catégorisés dans des « communautés », allant jusqu'à changer les vignettes illustrant les contenus en fonction des profils<sup>40</sup>. Il y a donc bien un effet bulle de filtre sur Netflix et Spotify, mais il est à nuancer : sur Spotify, les playlists créées par les équipes éditoriales (aidées par des algorithmes) permettent aux utilisateurs de consulter une assez grande part du catalogue et de « sortir de leur zone de confort », tout en restant il est vrai sur des titres majoritairement connus. Du côté de Netflix, s'il est vrai que les communautés voient des contenus très spécifiques, leur nombre très important (entre 1300 et 2000)<sup>41</sup> fait que le catalogue de la plateforme est visionné en grande partie : en revanche, chacun est enfermé dans « sa communauté »<sup>42</sup>.

Il semble que dans le cas du patrimoine, comme les institutions dans le domaine n'ont « rien à vendre », elles n'ont pas d'intérêt à faire en sorte que d'hypothétiques algorithmes de recommandation (car il faut reconnaître que les exemples manquent en ce domaine) favorisent un contenu plutôt qu'un autre. Fort est à parier que si ces dernières mettent en place de tels dispositifs, qui sont à l'origine plutôt un moyen d'objectiver la recommandation plutôt que de créer un enfermement algorithmique (relatif), ils seraient plutôt des facilitateurs de rebonds entre différents éléments des collections, car il est vrai que ce taux paraît assez faible (entre 1 et 3 par session de navigation) sur Gallica<sup>43</sup> plutôt que des facteurs d'enfermement. Mais alors pourquoi ne sont-ils pas plus massivement déployés dans les institutions qui auraient pourtant beaucoup, leurs usagers surtout, à gagner à cela ? Il semble qu'il faille aller poser la question de ce que peuvent les institutions en la matière, que ce soit pour réguler l'écosystème que nous venons de décrire, ou encore pour mieux le mettre à profit.

---

38. E. Durand, « Chapitre 5 - Le nouvel âge de la diversité »..., § 2.

39. **Chaire Pluralisme culturel et éthique du numérique (PcEn) ; mai 2022** in J. Farchy et S. Tallec, « De l'information aux industries culturelles, l'hypothèse chahutée de la bulle de filtre »...§ 47

40. Mathilde Serrel, *Algorithmes : comment sortir de sa "bulle culturelle" ?* / France Culture, URL : <https://www.radiofrance.fr/franceculture/podcasts/le-billet-culturel/algorithmes-comment-sortir-de-sa-bulle-culturelle-7342064> (visité le 19/08/2024).

41. Ashley Rodriguez, *Netflix divides its 93 million users around the world into 1,300 “taste communities”*, mars 2017, URL : <https://qz.com/939195/netflix-nflx-divides-its-93-million-users-around-the-world-not-by-geography-but-into-1300-taste-communities> (visité le 22/08/2024) in J. Farchy et S. Tallec, « De l'information aux industries culturelles, l'hypothèse chahutée de la bulle de filtre »...§ 48

42. Voir à ce propos le, déjà cité, témoignage d'April Joyner : <https://www.marieclaire.com/culture/a18817/netflix-algorithms-black-movies/>

43. I. Bastard et A. Laborde, *La découvrabilité des collections numériques patrimoniales sous l'angle des usages de Gallica...*



# Chapitre 10

## Difficultés institutionnelles

### 1. Une nécessaire acculturation au numérique et des tabous à lever

La découvrabilité des contenus culturels à l'ère numérique se heurte à plusieurs limitations institutionnelles, dont les manques d'acculturation numérique et la présence de certains tabous au sein du secteur culturel. Le rapport de la Mission franco-qubécoise sur la découvrabilité de 2020 en fait d'ailleurs l'un des leviers majeurs à activer pour les pouvoirs publics afin d'améliorer la découvrabilité des contenus culturels francophones.

Ce dernier note tout d'abord un fort besoin de mise en commun des expertises et bonnes pratiques dans tout le domaine culturel, par exemple, les professionnels du patrimoine, spécialisés dans l'indexation et les métadonnées pourraient apporter une expertise essentielle en matière de repérabilité et les professionnels de l'audiovisuel apporter la leur en matière de recommandation. Cela aurait pour effet d'améliorer la découvrabilité dans les deux sens.<sup>1</sup> On peut aussi imaginer casser les silos informationnels, non seulement sectoriels comme on l'a vu en parlant de portails et de politiques *data-driven* (cf. partie 2), mais aussi de façon plus large dans tout l'écosystème culturel en créant des synergies. C'est ce que met en place le Pass Culture, dispositif créé en 2019 qui propose aux jeunes de 15 à 18 ans un crédit de 500 € qu'ils peuvent dépenser dans le secteur culturel de leur choix (films, livres, patrimoine, musique...). Le dispositif est accompagné d'une application

---

1. Ministères de la Culture (France et Québec), *Rapport - Mission franco-qubécoise sur la découvrabilité en ligne des contenus culturels francophones*, rapp. tech., France, Québec, Ministère de la Culture, 2020, p. 60, URL : <https://www.culture.gouv.fr/Media/médias-creation-rapide-ne-pas-supprimer/Rapport-Mission-franco-quebecoise-sur-la-decouvrabilite-en-ligne-des-contenus-culturels-francophones.pdf>, p. 31.

qui a pour objectif principal de faire découvrir à son public des contenus les plus divers possibles. Outre le fait qu'elle soit dotée d'un algorithme de recommandation et qu'une équipe éditoriale vienne aussi assurer ce rôle, il faut noter la présence très intéressante d'un « score de diversification », visible par les utilisateurs, qui augmente avec le nombre de catégories différentes visitées.<sup>2</sup> On a donc, grâce à ce dispositif dit de « ludification »<sup>3</sup>, une augmentation de la diversité (observée depuis le début du dispositif) des contenus culturels consommés par les utilisateurs qui ne se soucie pas des frontières classiques évoquées plus haut, jouant ainsi le rôle de portail d'accès aux contenus culturels, quel que soit le domaine.

Le rapport revient aussi sur l'importance centrale de la formation à la découvervabilité, notion encore très mal connue (surtout du côté français) et aux enjeux qui la sous-tendent (pour rappel : disponibilité, repérabilité et recommandation) en créant une véritable culture de la donnée dans les institutions.<sup>4</sup> Cela passerait par la montée en compétence des agents dans la compréhension des technologies de l'information et de la communication (algorithmes au premier chef), des méthodes de promotion et de marketing numérique (référencement) et des sciences de l'information que sont l'indexation et la gestion des métadonnées (dans ce domaine, les institutions patrimoniales ont une avance certaine). Ces dernières sont réparties en 4 piliers visibles dans l'image ci-après, extraite du rapport sur la découvervabilité et recréée par nos soins.<sup>5</sup>

La formation des professionnels de la culture aux enjeux de découvervabilité est parfois réalisée directement par ces derniers qui ont à leur disposition en ligne des formations gratuites souvent proposées par les GAFAMS<sup>6</sup>, ce qui pose non seulement la question de la dépendance à ces outils, mais aussi celle de la pertinence de telles formations, pas toujours adaptées aux cas d'usages spécifiques des secteurs culturels.<sup>7</sup> Évidemment, cette question de la formation est avant tout celle des moyens mis à disposition des institutions pour accomplir leurs missions, car il faut des professionnels qualifiés pour les remplir et donc de l'argent pour les recruter. Par ailleurs, la stratégie de promotion des contenus culturels passe parfois par l'achat d'espaces publicitaires en ligne ou la mise en place de partenariats, par exemple avec des influenceurs dont le rapport note l'importance

---

2. Tristan Martin-Stocker et Cyrille Delabre, *Penser la découvervabilité des contenus culturels*, juin 2023, URL : <https://www.bnf.fr/fr/agenda/penser-la-decouvrabilite-des-contenus-culturels> (visité le 19/08/2024).

3. « Ludification », *Wikipédia* (, juill. 2024), URL : <https://fr.wikipedia.org/w/index.php?title=Ludification&oldid=217012791> (visité le 19/08/2024).

4. Ministères de la Culture (France et Québec), *Rapport - Mission franco-qubécoise sur la découvervabilité en ligne des contenus culturels francophones...*, p. 23.

5. *Ibid.*, p. 21.

6. Google Apple Facebook Amazon Microsoft

7. *Ibid.*, p. 22.

## Les quatre piliers de la découvrabilité

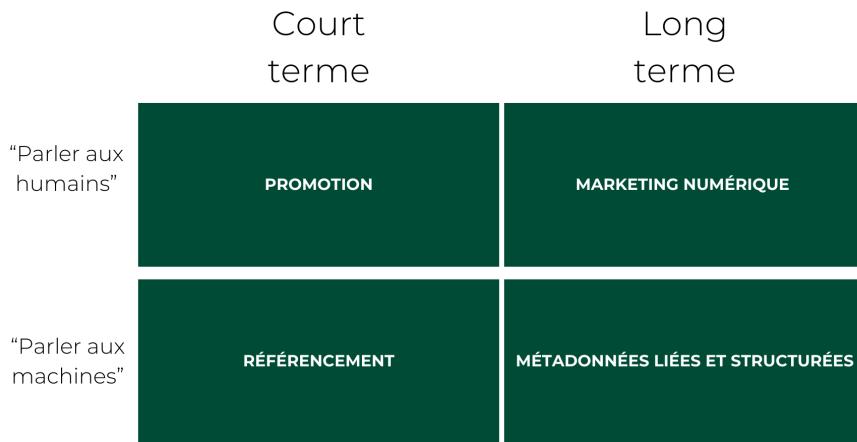


FIGURE 27 – Les quatre piliers de la découvrabilité

croissante.<sup>8</sup>

Il faut aussi noter un frein simplement mentionné dans le rapport : celui de pratiques professionnelles qui « méritent d'être reconnues ».<sup>9</sup> De fait, ces dernières et plus généralement le domaine du numérique, à cause de la complexité d'appréhension de leurs effets, parfois obscurs, surtout dans le cas de la recommandation, sont souvent assez mal perçues par les institutions patrimoniales et leurs usagers. En témoigne le fait que la seule institution patrimoniale lauréate de l'appel à projets pour la découvrabilité en ligne des contenus culturels proposé par le ministère de la Culture soit le projet, déjà cité, data.bnf.fr<sup>10</sup>; même s'il est vrai que l'institution est une tête de réseau qui fédère bon nombre d'acteurs au travers notamment du catalogue collectif de France ou de Gallica (tous deux moissonnés par data.bnf.fr). D'autres acteurs du secteur patrimonial pourraient bénéficier de ces moyens pour améliorer la découvrabilité de leurs contenus culturels et notamment les musées.

Quand bien même il est difficile, voire impossible pour les institutions culturelles de rivaliser avec les moyens des GAFAMS en matière de découvrabilité de leurs contenus (par exemple Netflix investit 3 milliards par an rien qu'en marketing digital)<sup>11</sup>, la mise en place de formations spécifiques, l'échange de bonnes pratiques et le recrutement de spécialistes pourra leur permettre d'améliorer sensiblement leurs pratiques. Ces dernières

8. *Ibid.*

9. *Ibid.*, p. 21.

10. *Découvrabilité en ligne des contenus culturels francophones*, 15 mai 2024, URL : <https://www.culture.gouv.fr/catalogue-des-demarches-et-subventions/appels-a-projets-candidatures/dcouvrabilite-en-ligne-des-contenus-culturels-francophones> (visité le 19/08/2024).

11. Id., *Rapport - Mission franco-québécoise sur la découvrabilité en ligne des contenus culturels francophones...*, p. 23.

ont par ailleurs des atouts qu'il ne faut pas négliger en la matière : la confiance des utilisateurs à leur égard bien sûr, mais aussi la possibilité de voir des régulations mises en place pour les favoriser, elles seront l'objet de notre prochaine partie.

## 2. Réglementer pour favoriser la découvrabilité

La question de la régulation dans le domaine de la découvrabilité des contenus culturels est complexe et souvent négligée. Bien que les ajustements réglementaires ne constituent pas une solution universelle, ils pourraient effectivement améliorer la visibilité des contenus culturels en ligne. Certains secteurs tels que la *musique* et le *cinéma* ont rapidement vu des réglementations sous forme de quotas mises en place. Tel est le cas par exemple de la loi Toubon, votée en 1994, qui impose aux radios de réserver une part variable (entre 40 et 10 %) à la chanson française et aux artistes émergents<sup>12</sup>. Plus récemment, le législateur européen s'est emparé de la question (*directive services de médias audiovisuels*, traduite en 2021 en droit français) en demandant aux *médias à la demande* de promouvoir les œuvres européennes en « facilitant l'accès à celles-ci ». Notamment, propose le texte, en les mettant sur la page d'accueil et en permettant aux utilisateurs de filtrer les œuvres européennes<sup>13</sup>. Ce texte s'attaque donc directement à l'enjeu de découvrabilité en imposant, en plus des quotas, de réserver une place facilement repérable aux contenus européens. Ce type de réglementation de marché, assez classique, doit être accompagné, selon Mira Bruni (dans un rapport sur la diversités des contenus à l'ère numérique) d'une réglementation par les algorithmes, c'est-à-dire « des interventions ciblées avec des outils qui favoriseraient l'exposition à la diversité des contenus en augmentant la visibilité et la découvrabilité de certains types de contenus au moyen de processus éditoriaux effectués par les algorithmes. »<sup>14</sup>. Son propos est complété par M. Napoli qui affirme l'importance de réglementer « l'intégration verticale »<sup>15</sup> dans le secteur culturel, car elle dernière favoriserait trop les contenus produits en propre par les plateformes. Par

12. « Comprendre les quotas de chansons francophones à la radio » (, 22 avr. 2016), URL : [https://www.lemonde.fr/les-decodeurs/article/2016/04/22/comprendre-les-quotas-de-chansons-francophones-a-la-radio\\_4907025\\_4355770.html](https://www.lemonde.fr/les-decodeurs/article/2016/04/22/comprendre-les-quotas-de-chansons-francophones-a-la-radio_4907025_4355770.html) (visité le 19/08/2024).

13. *Directive (UE) 2019/790 du Parlement européen et du Conseil du 17 avril 2019 sur le droit d'auteur et les droits voisins dans le marché unique numérique et modifiant les directives 96/9/CE et 2001/29/CE (Texte présentant de l'intérêt pour l'EEE.)* 17 avr. 2019, URL : <http://data.europa.eu/eli/dir/2019/790/oj/fra> (visité le 19/08/2024).

14. Patrimoine canadien, *Rapport — Rencontre internationale sur la diversité des contenus à l'ère numérique*, mai 2019, URL : <https://www.canada.ca/fr/patrimoine-canadien/services/diversite-contenus - ere - numerique / strategie - mobilisation - internationale / rapport .html> (visité le 25/08/2024).

15. L'intégration verticale est un concept dans lequel une entreprise contrôle plusieurs étapes du processus économique, par exemple, dans notre cas : Netflix est à la fois producteur de contenus mais aussi diffuseur par le biais de sa plateforme, favorisant ainsi, algorithmiquement, les contenus produits en propre. - Wikipédia, intégration verticale, consulté le 25/08/2024

ailleurs, selon les auteurs du rapport cité plus haut, « l'autorégulation des plateformes en ligne a révélé ses limites », il faut donc que les gouvernements aillent plus loin que l'incitation à la régulation et viennent directement réguler les plateformes, espaces privés dans la sphère publique qu'est le web ayant leurs propres règles.<sup>16</sup>.

Si les secteurs cités plus hauts, parfois qualifiés de privilégiés, bénéficient d'un encadrement législatif fort qui tend à préserver la diversité culturelle, même si elle n'est que relative puisqu'elle veut surtout soutenir les productions nationales. Si ces politiques sont poussées à l'extrême, la bulle de filtre pourrait alors être, non plus algorithmique, mais législative. Ce n'est pas le cas pour tous. Il est assez logique qu'une politique de quotas ne soit pas bénéfique dans le cas patrimonial où l'objectif est plutôt, on l'a déjà largement décrit, de briser les frontières entre les collections pour permettre leur diffusion à une large échelle, mais il faut tout de même noter que — et c'est plus une question de moyens financiers que de régulation — des institutions de petite taille voient le patrimoine qu'elles conservent invisibilisé par les « *superstars* » que sont les grandes institutions, souvent parisiennes pour le cas de la France.

La réglementation qui pourrait favoriser la visibilité et la découvrabilité des contenus de toutes les institutions serait plutôt sous forme de programmes d'aide à la numérisation, comme le plan de numérisation qui était au départ sous forme d'appels à projets annuels proposés par l'administration centralisée et qui a été déconcentré en 2018 dans les Directions régionales des affaires culturelles (DRAC) afin de cibler les institutions en région, plus en retard dans les chantiers de numérisation que les institutions centrales.<sup>17</sup> On peut aussi noter le Plan d'action pour le patrimoine écrit (PAPE) coordonné par la BnF et les pôles régionaux de coopération des acteurs du livre et de la lecture et région (par exemple Mobilis pour la région Pays-de-la-Loire) qui vise au signalement « des collections patrimoniales : manuscrits et archives sans limitation de date, livres imprimés jusqu'en 1830 pour l'ensemble des bibliothèques territoriales, livres imprimés jusqu'en 1914 pour les bibliothèques territoriales classées ou relevant d'une collectivité de plus de 500 000 habitants, fonds locaux et spécialisés, sans limitation de date. »<sup>18</sup>. Tous les ouvrages signalés ainsi sont intégrés au Catalogue collectif de France (CCFr), hébergé par la BnF, qui rassemble ainsi en un point d'entrée unique des collections éparses sur tout le territoire, permettant à des bibliothèques de taille très modeste d'avoir une visibilité à l'échelle nationale.

---

16. *Ibid.*

17. *Plan de numérisation : les collections en ligne*, URL : <https://www.culture.gouv.fr/Thematiques/Musees/Pour-les-professionnels/Conserver-et-gerer-les-collections/Numeriser-les-collections/Plan-de-numerisation-les-collections-en-ligne> (visité le 25/08/2024).

18. *Le CCFr et le signalement du patrimoine*, URL : <https://www.bnf.fr/fr/le-ccfr-et-le-signalement-du-patrimoine> (visité le 25/08/2024).

### 3. La question des droits d'auteurs

Concentrons-nous dans cette partie sur une réglementation absolument centrale en ce qui concerne la découvrabilité des contenus patrimoniaux : le droit d'auteur. Car comme le rappelle très bien le rapport sur la découvrabilité : « Vecteur indispensable de découvrabilité en ligne, les images sont, pour certains secteurs (*arts visuels et patrimoine*), souvent protégés par des droits d'auteur qui en empêchent l'exploitation en ligne, à moins de disposer de budgets considérables pour lever ces droits, ou d'une meilleure répartition de la valeur issue de l'exploitation de ces images par les plateformes. C'est un enjeu devenu encore plus névralgique depuis que Google propose toujours plus d'images dans les résultats de recherche pour tenir compte de cette préférence des utilisateurs »<sup>19</sup>.

Rappelons donc ici le cadre légal actuel brièvement (il concerne toute l'Union européenne, on parle de droit continental). Le droit d'auteur est divisé en deux parts : les droits moraux d'abord, qui sont perpétuels, inaliénables et imprescriptibles et qui incluent le droit de paternité (l'auteur d'une œuvre sera toujours reconnu comme tel) et le droit au respect de l'œuvre (qui la protège contre toute modification susceptible de la dénaturer). Les droits patrimoniaux quant à eux permettent à l'auteur de tirer des revenus de son œuvre, ils incluent le droit de reproduction (copie de l'œuvre) et de représentation (visibilité publique de l'œuvre). En France, ils durent 70 ans. Sauf à de rares exceptions (notamment pour les auteurs morts pour la France)<sup>20</sup>. Cet arsenal législatif est complété par la directive européenne sur le droit d'auteur et les droits voisins dans le *marché unique numérique* (adoptée en 2019 et transposée en droit français en 2021), qui renforce ces protections. Cette directive introduit des mécanismes pour que les créateurs soient équitablement rémunérés pour l'exploitation de leurs œuvres en ligne, en particulier lorsqu'elles sont utilisées par des plateformes comme *YouTube* ou *Google*<sup>21</sup>.

Maintenant que le cadre est posé, il faut noter quelques éléments importants. Premièrement, le droit d'auteur actuel constitue une limitation assez importante dans la disponibilité des collections culturelles en ligne, et notamment pour les musées d'art contemporain à l'image du *Centre Pompidou* qui a numérisé et mis en ligne une grande partie de sa collection et a pour cela dû faire un nombre très important de demandes d'autorisations, car la majeure partie des œuvres étaient encore protégées par des droits patrimoniaux<sup>22</sup>.

19. Ministères de la Culture (France et Québec), *Rapport - Mission franco-qubécoise sur la découvrabilité en ligne des contenus culturels francophones...*, p. 32.

20. *Droit d'auteur en France — Wikipédia*, URL : [https://fr.wikipedia.org/wiki/Droit\\_d'\\_auteur\\_en\\_France](https://fr.wikipedia.org/wiki/Droit_d'_auteur_en_France) (visité le 19/08/2024).

21. *Directive (UE) 2019/790 du Parlement européen et du Conseil du 17 avril 2019 sur le droit d'auteur et les droits voisins dans le marché unique numérique et modifiant les directives 96/9/CE et 2001/29/CE (Texte présentant de l'intérêt pour l'EEE.)...*

22. E. Bermès, *Des parcours de sens dans le Centre Pompidou virtuel*, 1<sup>er</sup> janv. 2013, URL : <https://www.centre-pompidou.fr/parcours-de-sens-dans-le-centre-pompidou-virtuel>

Si le musée a pu rassembler les ressources pour le faire, ce n'est pas le cas de toutes les institutions qui n'ont parfois que peu de personnel à leur disposition et qui doivent déjà faire face à des coûts de numérisation parfois (très) élevés. Pourquoi ne pas alors étendre la directive européenne citée plus haut pour que les plateformes visées paient une contribution, finalement assez logique, aux institutions patrimoniales dont elles diffusent les données afin que cela contribue aux frais de numérisation et de maintenance ? C'est d'ailleurs ce que fait Google avec *Wikipédia* en finançant l'association en échange d'un accès plus facile et perfectionné à la base de données « *Wikidata* »<sup>23</sup>.

Pour finir sur la question des réglementations, il faut aussi noter que les institutions ont souvent tendance à elles-mêmes s'en imposer et sont assez frileuses contrairement aux grands groupes. À l'image de Google qui, à travers son projet *Google Books*, a tenté de contourner les lois sur le droit d'auteur, notamment en ce qui concerne les œuvres orphelines qui sont des œuvres pour lesquelles le ou les détenteurs des droits d'auteur ne peuvent pas être identifiés ou retrouvés, rendant ainsi toute exploitation légale complexe. Google, en numérisant massivement des livres sans avoir toujours obtenu l'accord des titulaires des droits et en supposant, par défaut, que les ayants droit étaient d'accord pour voir leurs œuvres diffusées, charge pour eux d'indiquer le contraire (on parle d'OPT-OUT). Cependant, cette approche a rapidement rencontré une opposition farouche, notamment de la part des auteurs et des éditeurs qui voyaient dans cette démarche une atteinte directe à leurs droits. La justice américaine a fini par trancher en 2011, estimant que Google ne pouvait pas se permettre de publier ces œuvres sans un accord préalable<sup>24</sup>. Quel que soit le résultat, cet exemple illustre bien comment une entreprise de la taille de Google a tenté de « jouer » avec les lois existantes, dans l'espoir de créer un précédent favorable pour ses intérêts. Pour sortir d'une posture manichéenne où Google serait le « méchant », il faut tout de même noter que si l'entreprise avait gagné ce procès cela aurait été une formidable opportunité de diffusion d'œuvres qui jusque-là étaient totalement introuvables en plus, évidemment, de générer des revenus très importants à l'entreprise américaine. Un autre exemple tend à nuancer cela, celui d'un autre procès opposant *Internet Archive* (fondation archivant le web) et quatre grands éditeurs internationaux (*Hachette*, *HarperCollins*, *John Wiley & Sons* et *Penguin Random House*) qui a débuté en 2020, les éditeurs accusant la fondation de diffuser des livres sans respecter le droit d'auteur. Car la fondation effectue des sauvegardes de la quasi-totalité des sites *internet* depuis sa création, mais aussi des copies de livres. En 2020, elle avait mis en place un service de prêt gratuit (pendant la pandémie et la fermeture des bibliothèques) sans limites d'utilisateurs simultanés pouvant

---

//bbf.enssib.fr/consulter/bbf-2013-05-0052-013%20 (visité le 19/08/2024), § 10.

23. Google devient client de Wikipédia, 22 juin 2022, URL : <https://www.lefigaro.fr/flash-eco/google-devient-client-de-wikipedia-20220622> (visité le 19/08/2024).

24. O. Ertzscheid, *Économie des biens culturels, cours de 2e année de DUT information et communication option métiers du livre et du patrimoine...*

emprunter les ouvrages. Pour les éditeurs, il s'agit purement et simplement d'un piratage de masse là où la fondation argue de son respect du droit d'auteur en restant dans un « *fair use* » (usage raisonnable, notion de droit américain qui prévoit des exceptions au droit d'auteur pour faciliter la diffusion des idées)<sup>25</sup>. Au final, *Internet Archive* a perdu ce procès et a donc dû retirer ces livres de sa bibliothèque<sup>26</sup>.

Si ces deux exemples peuvent tout à fait justifier la peur qu'ont les institutions de « jouer » avec les règlementations, on peut tout de même parfois se désoler de leur pusillanimité en la matière. Même si, par définition, il est difficile de trouver des exemples de projets avortés par des institutions du fait de leur frilosité, on peut tout de même prendre un exemple vécu pendant notre stage. Nous avions noté que la carte interactive des contenus présentée en partie 2 était un excellent moyen de valoriser les collections de la RTS en ligne. La première recherche qui est bien souvent effectuée sur un site patrimonial est simplement le nom de notre commune de naissance, mais on nous a beaucoup dit — et à raison sûrement — qu'il n'était pas envisageable de la rendre accessible au public, car cela pourrait poser des problèmes pour l'institution. En effet, cela risque de rendre visible le fait que la majorité des sujets diffusés par la RTS concernaient les cantons de Genève et de Vaud, ce qui est assez logique compte tenu de la population de ces deux cantons (qui plus est, le canton du Jura n'est indépendant que depuis 1978 et n'existe pas avant cette date), mais par peur d'une réaction négative des auditeurs, dans un contexte assez tendu pour la RTS (qui devra faire face à une votation qui vise à réduire la redevance d'environ un tiers en 2025). Il est vrai que donner une vision d'ensemble des collections n'est donc pas forcément une bonne chose politiquement, car cela renseigne sur les pratiques de conservation. Mais tout de même, si l'on avait pris le temps de l'explication et de la justification, le public aurait sûrement très bien compris cette surreprésentation de certains territoires et l'outil aurait pu être très utile. Notons aussi, sans disposer d'informations précises sur le sujet, que le projet *data.ina.fr* qui vise à proposer des statistiques sur les contenus conservés par l'institution devait être lancé en juin de cette année<sup>27</sup> ne l'est toujours pas. Peut-être pour des raisons similaires à celles évoquées pour la RTS ? L'explication du fonctionnement des algorithmes et outils, surtout avec l'émergence des outils d'intelligence artificielle, revêt donc une importance capitale. Mais est-ce que la notion de découvrabilité peut aussi s'appliquer à découvrir de façon pertinente le fonctionnement des algorithmes et du code en général ? Ce sera l'objet de

25. « Aux Etats-Unis, Internet Archive poursuivi en justice par des maisons d'édition », (, 21 mars 2023), URL : [https://www.lemonde.fr/pixels/article/2023/03/21/aux-etats-unis-internet-archive-poursuivi-en-justice-par-des-maisons-d-edition\\_6166381\\_4408996.html](https://www.lemonde.fr/pixels/article/2023/03/21/aux-etats-unis-internet-archive-poursuivi-en-justice-par-des-maisons-d-edition_6166381_4408996.html) (visité le 19/08/2024).

26. Antoine Oury, *Condamnée, Internet Archive retire 500 000 livres de sa bibliothèque*, URL : <https://actualitte.com/article/117813/droit-justice/condamnee-internet-archive-retire-500-000-livres-de-sa-bibliotheque> (visité le 19/08/2024).

27. C'est en tout cas ce qui a été annoncé lors d'une visite à l'INA en janvier dernier

notre prochaine partie.



# Chapitre 11

## Les angles morts de la notion de découvrabilité

### 1. Découvrabilité appliquée au code : l'explicabilité

Dans sa revue des cinq grands enjeux de l'intelligence artificielle, le journal « Polytechnique insight » note l'importance de « justifier les décisions prises par un algorithme »<sup>1</sup>, ce qu'on peut tout à fait rapprocher de la notion d'explicabilité du code qui se définit comme suit : « capacité de mettre en relation et de rendre compréhensible les éléments pris en compte par le système pour la production d'un résultat. »<sup>2</sup>. Cette notion prend une importance croissante avec le développement de l'intelligence artificielle, en témoigne le rapport Villani (2018) et son intégration à la stratégie européenne en matière d'intelligence artificielle<sup>3</sup>. La notion est d'ailleurs existante dans le droit français, les algorithmes de service public déjà évoqués sont en effet, au même titre que les agents, rendables de leurs actions. « Les administrations qui conçoivent et utilisent des algorithmes publics doivent donc “rendre des comptes” de leur utilisation auprès des individus concernés, mais aussi de la société dans son ensemble. »<sup>4</sup>.

---

1. Isabelle Bloch, *Les nouveaux enjeux de l'IA*, Polytechnique Insights, 2021, URL : <https://www.polytechnique-insights.com/dossiers/digital/les-nouveaux-enjeux-de-lia/> (visité le 19/08/2024).

2. *Explicabilité (IA)*, URL : <https://www.cnil.fr/fr/definition/explicabilite-ia> (visité le 19/08/2024).

3. Winston Maxwell, « Comment améliorer l'explicabilité et la responsabilité des algorithmes ? », *Les cahiers Louis Bachelier* (, 2020), p. 14.

4. *Les algorithmes publics : enjeux et obligations / guides.etalab.gouv.fr*, URL : [https://guides.etalab.gouv.fr/algorithmes/guide/#\\_2-les-enjeux-des-algorithmes-publics](https://guides.etalab.gouv.fr/algorithmes/guide/#_2-les-enjeux-des-algorithmes-publics) (visité le 19/08/2024).

Le rapport « Flexible and Context-Specific AI Explainability : A Multidisciplinary Approach » écrit par Valérie Beaudouin, Isabelle Bloch *et al.*<sup>5</sup> distingue quatre facteurs d'explicabilité qui permettent de moduler son niveau contextuellement. Le destinataire (utilisateur, régulateur, expert...) ; le niveau de criticité de l'algorithme (besoins différents entre expliquer les raisons d'un crash de voiture autonome et les résultats de Google) ; le cadre légal et l'environnement de déploiement (application critique, besoin d'un usage facilité au maximum, etc.). Isabelle Bloch, titulaire de la chaire en intelligence artificielle de Sorbonne université, note (propos recueillis par Sophy Caulier)<sup>6</sup> à ce propos : « Je travaille, par exemple, avec des médecins-radiologues sur la mesure de l'épaisseur du corps calleux chez les prématurés. Les radiologues voulaient savoir d'où venaient les scores obtenus, quelle région avait été reconnue dans l'image, où avaient été faites les mesures, pour comprendre ce qui avait contribué à la décision et expliquer le résultat final. Ces étapes étaient nécessaires pour qu'ils aient confiance dans l'outil. »

De la même façon, dans le cas patrimonial, un chercheur souhaitant écrire un article sur l'iconographie de Clytemnestre dans *Gallica* souhaitera savoir pourquoi et comment le RAG fonctionne pour identifier les éventuelles lacunes et biais (par exemple l'oubli d'un vase grec où elle n'est représentée que de façon incertaine) ; une personne cherchant simplement à consulter une image de la femme d'Agamemnon sera satisfaite du résultat sans avoir besoin de comprendre ses tenants et aboutissants. Il s'agit donc de trouver, parmi des milliards de paramètres d'entrée (données), celui qui aura influencé le résultat d'une requête ou d'une recommandation. Cette problématique rejoint totalement celle posée depuis le début de ce mémoire autour de la notion de découvrabilité. Dans les deux cas, le niveau d'explicabilité requis va dépendre des quatre facteurs cités plus haut.

L'explicabilité est l'un des enjeux pris en compte dans le projet *Archival*, qui vise à poser la question du rôle de l'intelligence artificielle dans l'interprétation de fonds d'archives<sup>7</sup>. Son principe est de créer une interface de résultats alimentée par l'intelligence artificielle qui donnerait à voir, en plus des résultats à proprement parler, le processus de génération<sup>8</sup>. Cinq algorithmes sont mis à disposition du chercheur qui devra sélectionner celui adapté à son cas d'usage, ils sont vus comme « les outils de la suite bureautique »<sup>9</sup>

---

5. Valérie Beaudouin, I. Bloch, David Bounie, Stéphan Clémentençon, Florence d'Alché-Buc, James Eagan, W. Maxwell, Pavlo Mozharovskyi et Jayneel Parekh, *Flexible and Context-Specific AI Explainability : A Multidisciplinary Approach*, mars 2020, DOI : 10.48550/arXiv.2003.07703, arXiv : 2003.07703 [cs] in W. Maxwell, « Comment améliorer l'explicabilité et la responsabilité des algorithmes ? »...p. 14

6. I. Bloch, *Les nouveaux enjeux de l'IA*...

7. *Valorisation d'archives multimédia : Compréhension automatique multimodale du langage pour de nouvelles interfaces intelligentes de médiation et de transmission des savoirs*, Agence nationale de la recherche, URL : <https://anr.fr/Projet-ANR-19-CE38-0011> (visité le 19/08/2024) in *Penser la découvrabilité des contenus culturels...*

8. Éléonore Besnéhard, « Évaluer une interface documentaire augmentée : étude de cas sur le projet ANR Archival » (), p. 46.

9. Michel Agnola, Ghislaine Azémard et Samuel da Silva, « IA et SHS : un dialogue indispensable »,

choisis par les utilisateurs en connaissance leurs fonctionnements et leurs avantages.




FIGURE 28 – Les différents algorithmes à l'oeuvre dans *Archival*

Depuis : Agnola, Azémard, de Silva

L'approche est dite de la « boîte transparente » (*glass box*)<sup>10</sup>, dans laquelle l'enjeu n'est plus uniquement le résultat, mais le processus qui y mène<sup>11</sup>. L'objectif pour l'équipe du projet est d'expliquer en détail ce que fait chaque algorithme pour que les usagers comprennent les biais et problématiques posées. De même qu'on a appris que pour trouver le journal « le voleur » dans un moteur de recherche il fallait, pour éviter les problématiques d'homonymie ajouter, « journal » à notre requête, les chercheurs auront à apprendre les biais et problématiques de l'intelligence artificielle grâce à une démarche d'explicabilité des projets. Cette notion est donc autant du côté des producteurs et des créateurs d'interfaces qui doivent les rendre les plus transparentes possibles que du côté des utilisateurs qui doivent s'acculturer au numérique et comprendre ses écueils. On a là un exemple d'explicabilité dite globale, c'est-à-dire que ce qui est donné à comprendre à l'usager est le fonctionnement général de l'algorithme, à la différence du niveau local où on expliquerait chacune des décisions que ce dernier prendra<sup>12</sup>.

## 2. L'accessibilité numérique

Dans le rapport sur la découvrabilité en ligne des contenus culturels francophones, déjà cité plusieurs fois, une notion est presque totalement absente : l'accessibilité numérique. Elle n'est mentionnée qu'une seule fois à la page 25 : « Par ailleurs, les métadonnées dans *EUTIC 2022 “A l'intersection de l'art, de la science et de la technologie : dialogues entre les hommes et les machines”*, Corfou, Greece, 2022, URL : <https://hal.science/hal-04220079> (visité le 19/08/2024), p. 9.

10. Par opposition à l'effet boîte noire (black box) souvent décrit pour évoquer la difficulté de compréhension des processus liés à l'intelligence artificielle.

11. É. Besnehard, « Évaluer une interface documentaire augmentée : étude de cas sur le projet ANR Archival »..., p. 47.

12. W. Maxwell, « Comment améliorer l'explicabilité et la responsabilité des algorithmes ? »..., p. 15.

renseignant les fonctionnalités d'accessibilité disponibles avec le contenu (par exemple, une composante d'audiodescription associée à une vidéo) sont essentielles pour la découvrabilité de ces contenus auprès des personnes en situation de handicap (mental, auditif, visuel, moteur, etc.). » Si ce qui est écrit est tout à fait vrai, il nous semble que c'est une vision un peu restrictive de la question des métadonnées d'accessibilité et de leur intérêt pour la découvrabilité. Mais avant de poursuivre, prenons le temps de définir ce qu'est l'accessibilité numérique et ce que cela implique. Selon « mon parcours handicap », site d'information pour les personnes en situation de handicap et leurs aidants, l'accessibilité numérique est ce qui permet aux personnes en situation de handicap d'accéder aux contenus d'un site web sans difficulté<sup>13</sup>. Cela implique donc quatre vecteurs importants : la perception par tous les publics (textes alternatifs aux contenus non textuels par exemple) ; l'utilisation (navigation simple et « logique » pour trouver le contenu même sans le voir) ; la compréhension (création de pages prévisibles, aides à la saisie) et la robustesse (optimisation de la compatibilité)<sup>14</sup>. L'accessibilité ce n'est donc pas simplement le fait de rajouter des textes de remplacements aux images sur un site, c'est un processus qui doit être abordé depuis le design du projet et pendant toute sa durée de vie<sup>15</sup> pour prendre en compte tous les publics. Alors qu'entre 4,3 % et 13,8 % de la population est en situation de handicap en France, soit entre 2,8 et 9 millions de personnes (selon le degré de handicap pris en compte, les nombres sont très différents)<sup>16</sup>, une politique de découvrabilité ne peut donc se passer d'une politique d'accessibilité.

Loin d'être uniquement une contrainte, l'accessibilité doit être vue comme une opportunité pour les créateurs de sites. Car avoir une démarche de mise en accessibilité d'un site les oblige à poser la question de sa navigation. Elle doit être la plus simple et la plus logique possible pour que, notamment, les lecteurs d'écran<sup>17</sup> ne s'y perdent pas. Or, un lecteur d'écran fonctionne exactement de la même manière qu'un *crawler*, ces petits robots qui parcourent automatiquement les sites web pour les indexer afin que les moteurs de recherche puissent les afficher. Plus un site est clair, sa navigation fluide et aisée, mieux le lecteur d'écran pourra le lire et mieux le *crawler* en comprendra la structure, et donc meilleure sera l'indexation de votre site et donc son référencement<sup>18</sup>. Par ailleurs, le fait

---

13. Accessibilité numérique / Mon Parcours Handicap, URL : <https://www.monparcourshandicap.gouv.fr/accessibilite-numerique> (visité le 19/08/2024).

14. Notion d'accessibilité numérique - RGAA, URL : <https://accessibilite.numerique.gouv.fr/obligations/notions-accessibilite-numerique/> (visité le 19/08/2024).

15. Accessibilité numérique / Mon Parcours Handicap...

16. Les personnes handicapées en France, 2022, URL : <https://drees.solidarites-sante.gouv.fr/sites/default/files/2022-12/AAS22-Fiche%202019%20-%20Les%20personnes%20handicap%C3%A9es%20en%20France.pdf> (visité le 19/08/2024).

17. Dispositifs utilisés par les personnes malvoyantes qui parcourent les pages Web et les lisent à voix haute pour leur permettre de naviguer.

18. adminiat, *Et si l'accessibilité numérique et le SEO étaient liés ?*, Product for Good, 1<sup>er</sup> sept. 2023, URL : <https://productforgood.fr/et-si-laccessibilite-numerique-et-le-seo-etaient-lies> (visité le 19/08/2024).

de renseigner les fameux textes de remplacement sur les images permet aussi aux moteurs de recherche de les indexer, et donc de les afficher, améliorant ainsi le référencement de ces dernières.

Autre objectif important, rendre un site accessible : c'est-à-dire souvent plus clair et plus facile dans sa navigation. Cela est aussi utile pour une catégorie de gens souvent oubliés : ceux souffrant de ce qu'on appelle la fracture numérique ou l'illectronisme, qui toucherait plus de 15 % de la population française en 2021<sup>19</sup>. Donc, la mise en accessibilité permet aussi à ces publics qui ont des difficultés à comprendre l'univers numérique de naviguer et d'utiliser plus facilement les sites. Dernier élément à prendre en compte, l'accessibilité doit aussi se placer du côté des machines et des connexions *internet* : un site web accessible doit donc améliorer son temps de chargement (ce qui améliore aussi son référencement). En plus de le rendre plus facilement consultable pour tous, cela permet d'économiser des ressources matérielles et informatiques et donc de réduire l'impact carbone grandissant du numérique.

### 3. Et la planète dans tout ça ?

Formulée il y a bientôt 60 ans (1965) par le co-fondateur d'Intel Gordon Moore, la loi éponyme se résumait en une phrase : « le nombre de transistors dans les semiconducteurs [les processeurs] va doubler tous les deux ans à coût constant »<sup>20</sup>. Si l'on veut résumer grossièrement, un transistor est une espèce d'interrupteur manipulable électriquement. Plus ils sont nombreux plus un processeur peut faire de calculs, puisqu'ils sont responsables de ces derniers : les 0 et 1 du binaire sont en fait l'état des transistors selon qu'ils sont éteints ou allumés<sup>21</sup>. La fin de la loi de Moore est-elle un motif d'espoir ? C'est en tout cas ce qu'écrit Tristan Nitot, ex-président de Mozilla Europe et personnalité influente du monde du numérique<sup>22</sup>. Nuançons tout de suite, elle se vérifie toujours si l'on considère le nombre de transistors, qui a atteint actuellement 50 milliards dans nos processeurs. Cependant, en observant plutôt la puissance de calcul, elle ne se vérifie plus, car si le nombre de transistors est effectivement relié à cette variable, d'autres paramètres entrent en ligne de compte. En effet, des facteurs tels que les limites thermiques, la dissipation de chaleur, et l'architecture des processeurs influencent désormais de manière significative

19. Selon des chiffres de l'INSEE <https://www.insee.fr/fr/statistiques/7633654>

20. *Loi de Moore* — Wikipédia, URL : [https://fr.wikipedia.org/wiki/Loi\\_de\\_Moore](https://fr.wikipedia.org/wiki/Loi_de_Moore) (visité le 19/08/2024).

21. « Transistor », Wikipédia (, juill. 2024), URL : <https://fr.wikipedia.org/w/index.php?title=Transistor&oldid=217237046> (visité le 19/08/2024).

22. Tristan Nitot, *La loi de Moore est morte et c'est une bonne nouvelle - OCTO Talks!*, OCTO Talks!, 27 juin 2024, URL : <https://blog.octo.com/la-loi-de-moore-est-mort-e-t-c'est-une-bonne-nouvelle> (visité le 19/08/2024).

la capacité réelle de calcul, limitant ainsi la croissance exponentielle prévue par la loi de Moore.

Au final, comme l'écrit Tristan Nitot, la fin de cette croissance peut devenir un motif d'optimisme. Car le corollaire de la loi de Moore, la loi de Wirth, qui se résume elle aussi en une phrase « ce qu'Intel vous donne, Microsoft le reprend ». Nous montre que l'augmentation de puissance des processeurs observée depuis des années s'est toujours accompagnée de l'augmentation des performances requises par nos applications et pages web qui sont, par exemple, 150 fois plus lourdes qu'il y a 25 ans<sup>23</sup>. Par ailleurs, si la loi de Moore stipulait que le coût des processeurs (en énergie et à l'achat) allait rester constant ; ce n'est plus vraiment le cas. On observe en effet que la consommation électrique des processeurs est en constante augmentation de même que leurs prix<sup>24</sup>. On assiste donc à une fuite en avant avec des processeurs qui sont de plus en plus puissants avec des applications de plus en plus gourmandes. Ce n'est évidemment pas soutenable scientifiquement parlant (la réduction des tailles de transistors ayant tout de même des limites de même que leur refroidissement qui est le principal problème aujourd'hui), mais aussi écologiquement. On préfère, de fait, développer des fonctionnalités supplémentaires à des applications, sans jamais prendre le temps de les optimiser, ces dernières sont donc de plus en plus lourdes et de moins en moins optimisées. Ce que la loi de Moore rendait avant possible ne le sera plus bientôt<sup>25</sup>. Ce faisant, nos ordinateurs personnels, qui étaient avant constamment ralenti et mis au ban, car trop peu performants, pourraient dans le futur être plus durables.

90 % de l'impact carbone du numérique était causé en 2021 par son cycle de fabrication, qui en plus nécessite des matériaux rares, extraits souvent dans des conditions inhumaines<sup>26</sup>. Dans cette situation, la conservation de nos terminaux personnels le plus longtemps possible est essentielle. Quant au reste de l'impact carbone du secteur, il est lié à son usage, et 80 % sont le fait du visionnage de vidéos. Il ne faut donc pas éluder cette question de l'usage, car, par ailleurs, entre 2021 et 2024, la tendance est en train de s'inverser avec un impact carbone de 78 % du côté de la fabrication et de 22 % du côté de la phase d'utilisation<sup>27</sup>. Les causes ? L'explosion de la vidéo à la demande et sur les réseaux sociaux (penser à *Tik Tok* par exemple) d'une part, et d'autre part, l'impact grandissant de l'intelligence artificielle générative. Ces dernières, et leurs milliards de para-

---

23. *Ibid.*, § 8.

24. *Ibid.*, § 4- § 6.

25. *Ibid.*, § 9.

26. Valérie Guillard, *Chapitre 3. De la sobriété à la sobriété énergétique, numérique, matérielle / Cairn.info*, Paris, 2021 (Comment consommer avec sobriété ?), URL : <https://www-cairn-info.proxy.chartes.psl.eu/comment-consommer-avec-sobriete--9782807331891-page-55.htm> (visité le 19/08/2024), § 16.

27. *Quelle est la part du numérique dans les émissions mondiales de gaz à effet de serre en 2024 ?*, URL : <https://ekwateur.fr/blog/enjeux-environnementaux/emissions-co2-numerique/> (visité le 19/08/2024).

mètres (1000 milliards dans GPT-4<sup>28</sup>) consomment des quantités d'énergie extrêmement importantes, car elles ont besoin d'une puissance de calcul immense pour fonctionner. Cela est particulièrement pertinent lors de la phase d'entraînement des modèles. Par exemple, GPT-3, avec ses 175 milliards de paramètres, a généré 552 tonnes d'équivalent CO<sub>2</sub><sup>29</sup>. Ce chiffre est à mettre en relation avec l'interprétation des Nations Unies dans leur rapport « Emission Gap Report 2020 »<sup>30</sup>, pour limiter le réchauffement climatique à 1,5°C, et ainsi respecter l'accord de Paris, chaque individu devrait émettre environ 2 tonnes de CO<sub>2</sub> par an. Bien que 552 tonnes puissent sembler raisonnables pour un outil développé à l'échelle mondiale, il est essentiel de garder à l'esprit que GPT-3 dispose de dix fois moins de paramètres que les modèles actuels à la pointe de la technologie. De plus, OpenAI<sup>31</sup> est en concurrence avec de nombreuses autres entreprises, dont Google, qui développent également des modèles massifs. Chaque itération d'entraînement fait croître les émissions de CO<sub>2</sub> de manière exponentielle. Cet impact environnemental ne doit donc pas être pris à la légère.

C'est évidemment aussi valable pendant la phase d'utilisation (et sûrement bien plus) des modèles, et ici aussi les chiffres font défaut, on peut noter que Google a augmenté l'année dernière son empreinte carbone de 48 % et Microsoft (qui héberge *OpenAI*) de 39 % (alors que les émissions du géant américain étaient en baisse depuis quelques années)<sup>32</sup>. Quand on sait que les émissions mondiales du secteur représentaient 3,7 % en 2021 et devraient représenter 9 % d'ici à 2052, c'est-à-dire autant que les voitures, il ne faut pas négliger cet aspect, même dans une politique de découvrabilité. Dans la poursuite des objectifs développés dans ce mémoire, il ne faudrait pas que les institutions se lancent dans une fuite en avant, en numérisant l'intégralité de leurs collections sans distinction, mais plutôt – comme c'est plutôt le cas actuellement – de façon raisonnée et sobre. « Combien faut-il numériser de missels du XIX<sup>e</sup> siècle pour témoigner de la piété de la société à cette époque ? »<sup>33</sup>. Dans le cas du patrimoine audiovisuel par ailleurs, cela questionne aussi le choix de la qualité de diffusion des images numérisées, qui doit être reliée avec les besoins des utilisateurs et leurs support de lecture. Cette qualité doit par ailleurs tenir compte des contexte de diffusion de l'époque.

---

28. Selon les estimations les plus probables (*in* Wikipédia, GPT-4)

29. *Pourquoi ChatGPT est une bombe environnementale*, Le Nouvel Obs, Section : Economie, 18 sept. 2023, URL : <https://www.nouvelobs.com/economie/20230918.OBS78305/pourquoi-chatgpt-est-une-bombe-environnementale.html> (visité le 19/08/2024).

30. [inhttps://bonpote.com/objectif-2-tonnes-vrai-defi-ou-mauvaise-cible/](https://bonpote.com/objectif-2-tonnes-vrai-defi-ou-mauvaise-cible/)

31. Entreprise responsable de Chat GPT

32. Bruno Texier, + 48% : l'intelligence artificielle pèse lourd dans le bilan carbone de Google / Archimag, 3 juill. 2024, URL : <https://www.archimag.com/numerique-responsable/2024/07/03/48-intelligence-artificielle-pese-lourd-bilan-carbone-google-0> (visité le 19/08/2024).

33. E. Bermès, "De l'écran à l'émotion, quand le numérique devient patrimoine"..., p. 21.



# Conclusion

À l'heure où s'achève cette réflexion, une nouvelle interrogation surgit : la découvrabilité, n'était-elle qu'un prétexte ? Tout au long de notre étude, nous avons présenté cette notion comme une réponse aux défis posés par ce que nous avons qualifié de big data patrimonial. Pourtant, il ne s'agit que d'un mot, un concept, loin d'être performatif. Bien que fréquemment invoqué pour résoudre les enjeux contemporains tels que les mégadonnées, la bataille de l'attention ou encore la fatigue muséale, la découvrabilité n'est qu'un subterfuge, un point d'entrée pour aborder une multitude de problématiques sous-jacentes. Son émergence ne signale pas un problème nouveau, mais plutôt les possibilités qui s'offrent aux institutions pour y faire face.

L'émergence des contenus culturels est ici la question centrale<sup>34</sup>. Émergence au sein de nos moteurs de recherche, grâce à une double stratégie visant, en premier lieu, à « parler aux machines », par le biais des principes du web sémantique, mais aussi, dans un second temps, à « parler aux humains » en leur proposant du contenu utile et de qualité. Émergence au sein des plateformes, en provoquant une « sérendipité artificielle » par l'intermédiaire des algorithmes de recommandation. Émergence au sein des catalogues aussi, et que grâce à la visualisation de l'information émergent de nouveaux questionnements, qu'ils soient intellectuels or organisationnels. Émergence pour découvrir les collections patrimoniales sous un autre angle et en allant plus loin grâce à des interfaces devenues génératrices. Émergence active enfin, guidée par l'intelligence artificielle, capable de révéler des trésors insoupçonnés mais dont il faut se méfier. Car malgré toutes ses promesses, et tel Orphée, elle peut finir par égarer ce qu'elle conduit, souvent de manière inexplicable. Orphée s'est-il retourné par désir de voir Eurydice avant de rejoindre la surface, ou était-ce elle qui l'a appelé, scellant ainsi sa propre perte ? Guide, comme suiveur, peuvent y avoir leur part de responsabilité. Cette émergence, aussi impressionnante soit-elle, nécessite une vigilance constante et une compréhension mutuelle pour ne pas se perdre en chemin.

---

34. Pour rappel, la découvrabilité se définit comme la capacité d'un contenu culturel à émerger parmi un vaste ensemble

Corollaire de l'émergence, l'effacement. Que devient ce qui n'a pas été rendu visible par les algorithmes et les interfaces ? Car l'émergence parmi un vaste ensemble conduit inévitablement à l'effacement. Effacement de ce que les machines, le code, n'ont pas choisi de montrer. Le web, en tant qu'intercesseur vers le savoir et la découverte, se doit donc de rester impartial. Il aura alors atteint l'incroyable utopie numérique qu'il rendait possible à sa création. Mais en tant qu'écosystème de l'hyper : utopie de l'hyperchoix qui se transforme en une hyperindividualisation algorithmique ; utopie de l'hyperdiversité qui devient hyperstandardisation culturelle, l'hyperespace a grand besoin d'être pris en main par les acteurs patrimoniaux. Ces derniers doivent non seulement le comprendre et y être formés, mais ils doivent aussi être conscients de ses failles, sans tomber dans d'irrationnelles craintes qui limiteraient les actions mises en place. Ils ont par ailleurs à leur disposition des moyens de lutte : la réglementation et leur réputation d'excellence.

La découvrabilité doit donc occuper une place centrale dans les politiques culturelles, mais il est essentiel de se rappeler qu'elle n'est qu'un point de départ. Ce qui importe véritablement, ce sont les implications qu'elle porte en elle. Bien que cette position soit cruciale, il ne faut pas perdre de vue que, même si la découvrabilité se situe au carrefour d'enjeux fondamentaux, elle doit évoluer en empruntant des chemins alternatifs. Le premier chemin est celui de l'accessibilité, qui doit être vue non comme une contrainte, mais comme une opportunité : celle de rendre les contenus accessibles à tous et de les rendre plus facilement repérables par les machines. Vient ensuite le chemin encore incertain de l'intelligence artificielle, dont les décisions, à l'image d'Orphée, échappent parfois à notre compréhension et nous mènent finalement vers un dernier chemin : celui de la viabilité écologique, un enjeu que cette technologie, plus que toute autre, met en péril.

Concluons en revenant à Borges, dont l'œuvre a servi de point de départ à notre réflexion :

« La Bibliothèque est totale, et [...] ses étagères consignent toutes les combinaisons possibles des vingt et quelques symboles graphiques [...], c'est-à-dire tout ce qu'il est possible d'exprimer, dans toutes les langues. Tout : l'histoire minutieuse de l'avenir, les autobiographies des archanges, le catalogue fidèle de la Bibliothèque, des milliers et des milliers de catalogues mensongers, la démonstration de la fausseté de ces catalogues, la démonstration de la fausseté du catalogue véritable. »<sup>35</sup>

Borges avait saisi l'essence même de la découvrabilité : non seulement l'identification au sein d'une masse d'informations, mais aussi la question des régimes de vérité, qui se

---

35. J. L. Borges, *La bibliothèque de Babel...*, p. 3.

multiplient dans notre monde contemporain. L'enjeu de la découvrabilité est l'émergence d'un régime de vérité commun, vérifiable et explicable.

Nous pensons, et c'est une forme d'hommage au vu du lieu de notre stage, que les médias publics ont un rôle crucial à jouer dans ce domaine. À l'instar des institutions patrimoniales, ils ne sont pas intrinsèquement biaisés, car ils ne sont pas soumis aux contraintes des logiques marchandes.

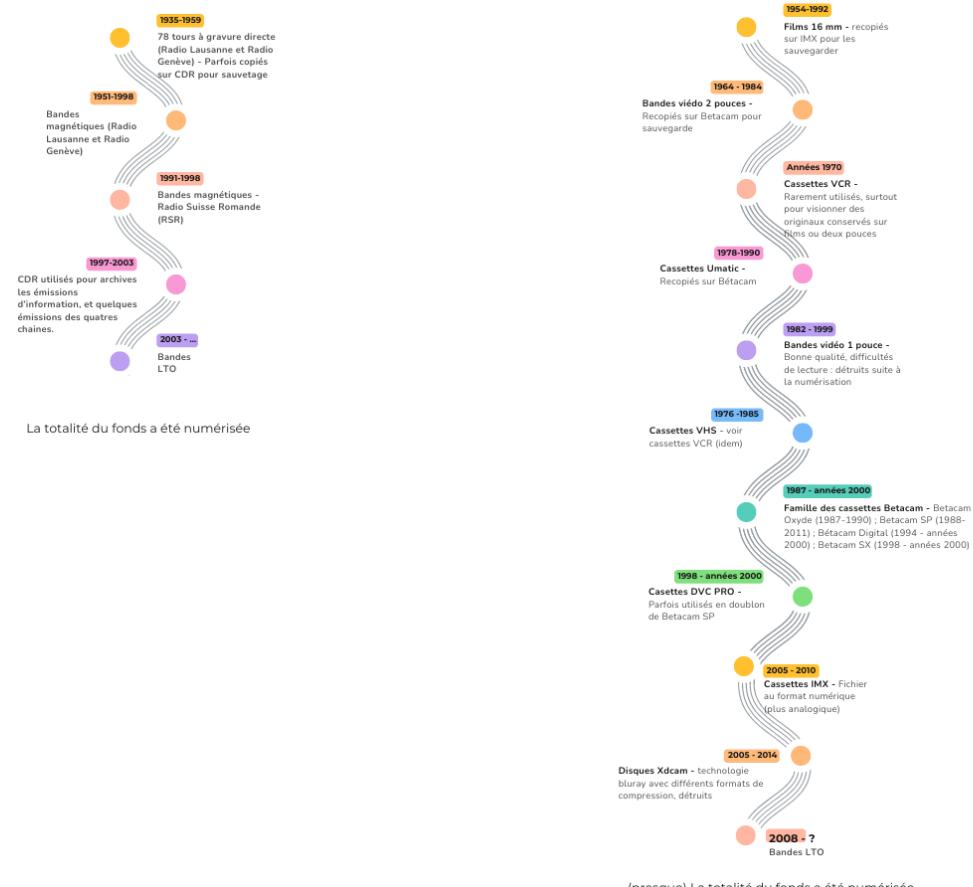
Le code, c'est la loi ; veillons donc à ce qu'il nous permette de bâtir une société fondée sur des vérités partagées.



# Annexe A

## Chronologie des supports Radio - RTS   Chronologie des supports TV - RTS (hors musique)

Graphisme Yadira Inza (Canva)  
Contenu : Denise Barcella (RTS)





# Index thématique (grandes notions)

- Accessibilité, 107–109
- Algorithme de service public, 39, 40
- Big data, 5, 6
- Bulle de filtre, 7, 40, 90–93
- Catalogue, 27, 39, 40, 46, 48, 49, 52, 56, 92, 93, 97, 99
- Clé de lecture, 59, 62, 70
- Code is law, 83
- Courte tête, 87
- Crowdsourcing, 73, 74
- Data driven, 51
- Disponibilité, 9, 24, 36, 96, 100
- Données massives, 4, 34
- Droit d'auteur, 100–102
- FAIR, 50
- Fatigue muséale, 5, 29, 55, 63
- Hyperchoix, 85, 87
- IIIF, 50
- Intelligence artificielle, *voir* IA, 64, 75–77, 102, 105–107, 110
- RAG, 75–77, 106
- Interface, 45, 46, 55, 62–66, 69–71, 75, 106
- Interopérabilité, 26, 50
- Knowledge graph, 28, 62, 63, 70
- Littératie numérique, 78, 95
- Longue traîne, 87–90
- Modèles de données
- CIDOC-CRM, 70
  - FRBR, 25, 48
  - IFLA-LRM, 25, 48, 70
- Open data, 72
- Portail, 5, 27, 28, 49–51, 69, 96
- Recommandation, 30, 35, 36, 38–40, 73, 75, 87, 90, 93, 95–97, 106
- Repérabilité, 9, 23, 30, 48, 51, 70, 77, 89, 95, 96
- Référencement, 23, 24, 26–30, 50, 51, 96, 108, 109
- Régulation, 81, 83, 99
- Sérendipité, 33–36, 63, 64
- Trouvabilité, 56, 69, 71
- Économie de l'attention, 6, 35, 88, 91

# Table des figures

1	La logique « à plat » de Gesima et la logique hiérarchique de GICO (illustration réalisée par nos soins) . . . . .	19
2	Exemple de fiche importée depuis l'outil GESIMA, on observe bien l'ancienne structuration des dates, des champs en majuscules et les problématiques que cela peut créer (information en double voire en triple) . . . . .	20
3	L'interface de Yahoo qui était au départ un annuaire . . . . .	24
4	Illustration schématique du modèle FRBR/LRM . . . . .	26
5	Affichage pour l'utilisateur grâce aux données du <i>knowledge graph</i> . . . . .	27
6	Les données en question, affichage pour les machines . . . . .	27
7	« Capitale du Dauphiné », résultats de recherche Google effectuée le 27 juillet 2024 . . . . .	28
8	« Archives Simone Veil », résultats de recherche Google effectuée le 18 juillet 2024 . . . . .	28
9	« Baignade interdite », exemple de recommandation proposée par les documentalistes de la RTS . . . . .	31
10	L'interface de Mix.com . . . . .	36
11	Fonctionnement schématique d'un algorithme de clustering . . . . .	37
12	Les traitements effectués par l'INA sur une image . . . . .	53
13	Le catalogue de la bibliothèque publique de New York visualisé, depuis : <a href="https://catalog-network.s3-website-us-east-1.amazonaws.com/">https://catalog-network.s3-website-us-east-1.amazonaws.com/</a> . .	56
14	Les grandes thématiques qui se dégagent de l'expérimentation de la bibliothèque publique de New York . . . . .	57
15	Treemap interactive réalisée pendant le stage . . . . .	58
16	Carte interactive des contenus archivés à la RTS réalisée pendant le stage .	61
17	Tableau de bord « Chronicling America Maps and Visualizations » . . . . .	62
18	<i>Knowledge Graph</i> réalisé pendant le stage . . . . .	63
19	Illustration de l'autocomplétion des recherches, depuis <i>Düring, Bunout, Guido...</i> . . . . .	65
20	Recherche comparative entre « abricots » et « Valais » . . . . .	66

21	Architecture du projet InTaViA . . . . .	71
22	L'interface de création des histoires d'InTaVia . . . . .	71
23	Exemple d'histoire créée depuis l'interface d'InTaVia . . . . .	72
24	L'interface de notrehistoire.ch : un réseau social patrimonial . . . . .	74
25	Les trois âges de la recherche documentaire, illustration réalisée par nos soins	76
26	Carte d'ARPANET en 1972 . . . . .	82
27	Les quatre piliers de la découverabilité . . . . .	97
28	Les différents algorithmes à l'oeuvre dans <i>Archival</i> . . . . .	107

# Table des matières

Résumé	i
Remerciements	iii
Introduction	xxv
<b>I Partie 1 : Historique et enjeux de la découvrabilité</b>	<b>1</b>
<b>1 Aux origines était la disponibilité</b>	<b>3</b>
1. La nouvelle bibliothèque de Babel : vers un Big data patrimonial . . . . .	3
2. Quand la « Fatigue muséale » rencontre « l'économie de l'attention » . . . . .	5
3. La naissance de la découvrabilité . . . . .	7
<b>2 Un fonds massif aux métadonnées complexes : état des fonds conservés par la Radio-Télévision Suisse (RTS)</b>	<b>11</b>
1. Un « dépôt légal » audiovisuel en Suisse ? . . . . .	11
2. Le fonds radio et ses métadonnées . . . . .	12
a. L'origine de la Radiodiffusion en Suisse romande . . . . .	12
b. Histoire du fonds et de ses lacunes . . . . .	13
c. La numérisation du fonds radiophonique . . . . .	14
d. Métadonnées du fonds radiophonique . . . . .	14
3. Le fonds télévisuel et ses métadonnées . . . . .	15
a. Histoire du fonds et de ses lacunes . . . . .	15
b. La numérisation du fonds télévisuel . . . . .	17
c. Métadonnées du fonds télévisuel . . . . .	18
<b>3 Être repéré dans un vaste ensemble : la repérabilité</b>	<b>23</b>
1. Naviguer dans l'océan du web : l'importance du référencement . . . . .	23
a. Data.bnf.fr : sortir les données du web profond . . . . .	25
2. Parler aux humains : l'exemple des archives de la RTS . . . . .	29

a.	La « Bibliothèque de l'Honnête Homme » comme stratégie de valorisation . . . . .	29
b.	L'importance du SMO (social media optimisation) . . . . .	30
<b>4</b>	<b>Émerger dans le lac d'une collection : la recommandation</b>	<b>33</b>
1.	Sérendipité : quand l'heureux hasard rencontre les algorithmes . . . . .	33
2.	Les algorithmes de recommandation . . . . .	36
a.	La notion d'Algorithmie de service public : « prenez les commandes », l'algorithme de recommandation de Radio France . . . . .	39
<b>II</b>	<b>Partie 2 : Nouveaux catalogues, nouvelles interfaces, nouveaux usages</b>	<b>43</b>
<b>5</b>	<b>Les interfaces : nouvelles architectures ?</b>	<b>45</b>
<b>6</b>	<b>« Vers de nouveaux catalogues »</b>	<b>47</b>
1.	La transition bibliographique . . . . .	47
2.	Les portails et le moissonnage des données . . . . .	49
3.	Des catalogues aux politiques <i>data driven</i> . . . . .	51
<b>7</b>	<b>La visualisation de données en tant que nouvelle interface au service de la découvrabilité</b>	<b>55</b>
1.	Voir globalement : l'importance d'avoir une vue d'ensemble des collections . . . . .	55
2.	Voir sous un autre angle : donner des clés de lecture différentes des collections . . . . .	59
3.	Voir pour aller plus loin . . . . .	63
<b>8</b>	<b>Nouvelles interfaces : nouveaux usages</b>	<b>69</b>
1.	À chacun son interface : l'exemple d'InTaVia . . . . .	69
2.	Vers un nouveau <i>crowdsourcing</i> reposant sur l'ouverture des données	72
3.	L'intelligence artificielle comme porte d'accès au savoir, encore faut-il trouver la clé . . . . .	75

---

<b>III Partie 3 : le code c'est la loi, régulations et limites à la découvrabilité</b>	<b>79</b>
<b>9 Le web : prison ou fenêtre ouverte sur le monde ?</b>	<b>85</b>
1. L'hyperchoix . . . . .	85
2. Une longue traine ou une courte tête? . . . . .	87
3. Lutter contre la « bulle de filtre » . . . . .	90
<b>10 Difficultés institutionnelles</b>	<b>95</b>
1. Une nécessaire acculturation au numérique et des tabous à lever . .	95
2. Règlementer pour favoriser la découvrabilité . . . . .	98
3. La question des droits d'auteurs . . . . .	100
<b>11 Les angles morts de la notion de découvrabilité</b>	<b>105</b>
1. Découvrabilité appliquée au code : l'explicabilité . . . . .	105
2. L'accessibilité numérique . . . . .	107
3. Et la planète dans tout ça? . . . . .	109
<b>Conclusion</b>	<b>113</b>
<b>A Supports conservés</b>	<b>117</b>